
Entwicklung einer webbasierter Applikation zur Bearbeitung von PDF Dateien

Bachelorarbeit zur Erlangung des akademischen Grades
Bachelor of Science
im Studiengang Technische Informatik
an der Fakultät für Informations-, Medien- und Elektrotechnik
der Technischen Hochschule Köln

vorgelegt von: Janina Schroeder
Matrikel-Nr.: 11132206
Adresse: Laurentiusweg 10
50321 Brühl
janina_jessika_jelena.schroeder@smail.th-koeln.de

eingereicht bei: Prof. Dr. Chunrong Yuan
Zweitgutachter: Prof. Dr. René Wörzberger

Köln, 04.03.2024

Bachelorarbeit

Titel: Entwicklung einer webbasierter Applikation zur Bearbeitung von PDF Dateien

Gutachter:

- Prof. Dr. Chunrong Yuan
- Prof. Dr. René Wörzberger

Zusammenfassung: Für die Bachelorarbeit habe ich eine Open Source offline Webseite zur Bearbeitung von PDF Dateien im Firefox Browser programmiert. Seit Adobe den PDF Standard entwickelt hat, tauchten zahlreiche meist kostenpflichtige PDF Anwendungen, um PDF Dateien zu bearbeiten auf dem Markt auf. Ich habe den Markt an PDF Programmen analysiert und diese mit meiner Webapplikation verglichen. Daraufhin beleuchte ich den aktuellen Stand der Technik des PDF Standards. Im späteren Verlauf erkläre ich die Implementierung meiner Webapp und meine Erfahrungen mit anderen Browsern, sowie auf MacOS, Linux, Android und iOS. Die Javascript Libraries PDF.js und PDF-LIB sind das tragende Fundament meiner PDF Webapp. Die PDF Webapp vereint alle Funktionalitäten, die man für gängige PDF Bearbeitung benötigt. Man kann PDFs lesen, splitten, mergen, erstellen, sowie mit Texten, Bildern, Geometrie und Zeichnungen versehen. Am Ende diskutiere ich, was man hätte besser machen können, welche Funktionalitäten fehlen und welche Features in Zukunft noch geplant sind.

Stichwörter: PDF Bearbeitung, Adobe, Javascript, Vue JS 3, auf PDF zeichnen, Splitten, Mergen, PDF.js, PDF-LIB

Datum: 04. März 2024

Inhaltsverzeichnis

Tabellenverzeichnis	V
Abbildungsverzeichnis	VI
Abkürzungsverzeichnis	VII
1 Grundlagen	2
1.1 PDF Vorstellung	2
1.2 Wichtigste Features	3
1.2.1 What You See Is What You Get (WYSIWYG)	3
1.2.2 Fonts	3
1.2.3 Bilder	4
1.2.4 3D-Daten	5
1.2.5 Kommentare	5
1.2.6 Verweise	5
1.2.7 Formulare	6
1.2.8 Inkrementelles Update	6
1.2.9 Kompression	7
1.2.10 Ebenen	8
1.2.11 Portfolio	8
1.2.12 JavaScript	8
1.3 PDF Dateiformate	8
1.3.1 PAdES	9
1.3.2 PDF/X	9
1.3.3 PDF/A	13
1.3.4 PDF/E	14
1.3.5 PDF/H	15
1.3.6 PDF/VT	15
1.3.7 PDF/UA	16
1.3.8 PDF/R	16
1.3.9 Searchable PDF	17
1.4 PDF Dateiversionen	17
1.4.1 PDF 1.0	17
1.4.2 PDF 1.1	18

1.4.3	PDF 1.2	18
1.4.4	PDF 1.3	18
1.4.5	PDF 1.5	19
1.4.6	PDF 1.4	19
1.4.7	PDF 1.6	20
1.4.8	PDF 1.7	20
1.4.9	PDF 2.0	20
1.5	PDF Implementierung	21
1.5.1	PostScript	21
1.5.2	Adobe Imaging Model	22
1.5.3	Dateiformataufbau	23
1.5.4	Implementierung von Fonts	26
1.6	PDF Sicherheitsaspekte	27
1.6.1	Digitale Signatur	27
1.6.2	PDF Signature Spoofing	28
1.6.3	PDFex PDF Encryption Attacks	30
2	PDF Programme auf dem Markt	33
2.1	Die Firma Adobe Systems Incorporated	33
2.2	Aktueller Stand von Forschung und Technik	33
2.3	Freie PDF Programme und Onlinedienste	33
2.3.1	PDFCreator	33
2.3.2	LibreOffice	34
2.3.3	OpenOffice	34
2.3.4	ghostscript	34
2.4	Kostenpflichtige PDF Programme und Onlinedienste	34
2.4.1	Adobe Acrobat	34
2.4.2	Adobe Acrobat Pro	34
2.4.3	Onlinetools von Acrobat	35
2.4.4	Acrobat Distiller	35
2.4.5	Microsoft Word	35
2.5	PDF zu Word Konvertierung	35
2.6	PDF zu Latex Konvertierung	36
2.7	Relevanz von PDF in verschiedenen Marktbranchen	36
2.8	Rolle von PDF in der Druckvorstufe und Designbranche	37
3	Open Source PDF Web App	43
3.1	Problemstellung und Anforderungen	43
3.2	Konzept und Methodik	43
3.3	Funktionalität der PDF Web App	43
3.4	Bedienung der PDF Web App	43

3.5	Implementierung der PDF Web App	43
3.6	Testdurchführung der PDF Web App	43
3.6.1	Funktionale User Tests	43
3.6.2	Stress Tests	43
4	Diskussion und Kritik	44
	Literatur	46
	Anhang	51

Tabellenverzeichnis

Abbildungsverzeichnis

Abkürzungsverzeichnis

- AES** Advanced Encryption Standard. 20, 31, 32
- ASCII** American Standard Code for Information Interchange. 22, 23
- BITV** Barrierefreie-Informationstechnik-Verordnung. 16
- CAD** Computer-Aided Design. 5, 14
- CAeS** CMS Advanced Electronic Signatures. 9
- CBC** Cipher Block Chaining. 30–32
- CEPS** Cisco Enterprise Print System. 18
- CID** Character Identifier Font. 4, 18
- CIE** Commission Internationale de l'Éclairage. 18
- DCS** Desktop Color Separation. 11
- ECB** Electronic Code Book. 32
- EPS** Encapsulated PostScript. 41
- ETSI** European Telecommunications Standards Institute. 9
- GDI** Graphics Device Interface. 21
- ICC** International Color Consortium. 11–13, 15, 18, 41
- ISA** Incremental Saving Attack. 28
- ISO** International Organization for Standardization. 2, 6, 9, 11–20, 40, 41
- MAC** Message Authentication Code. 31, 32
- MIME** Multipurpose Internet Mail Extension. 15, 21

- MITM** Man-in-the-middle. 30
- OCR** Optical Character Recognition. 17, 34
- OPI** Open Prepress Interface. 10, 18
- PAdES** PDF Advanced Electronic Signatures. 9, 36
- PCS** Profile Connection Space. 11
- PDF** Portable Document Format. 33
- PDL** Page Description Language. 21, 23
- PPD** PostScript Printer Description. 21, 34
- ppi** Pixels per inch. 23
- RIP** Raster Image Processor. 21, 22, 40–42
- RLE** Run Length Encoding. 7
- SWA** Signature Wrapping Attack. 28, 29
- USF** Universal Signature Forgery. 28, 29
- WCAG** Web Content Accessibility Guidelines. 16
- WYSIWYG** What You See Is What You Get. 2, 3, II
- XAdES** XML Advanced Electronic Signatures. 9
- XFA** XML Forms Architecture. 6, 19, 20
- XML** Extensible Markup Language. 6, 20, 38
- XMP** Extensible Metadata Platform. 13, 14
- ZSA** Zeitstempel-Anbieter. 27

Einleitung

Motivation

Aufbau der Arbeit

1 Grundlagen

1.1 PDF Vorstellung

Das PDF Dateiformat steht für Plattformunabhängigkeit, Hardwareunabhängigkeit, Konsistenz in Formatierung und Layout und soll ein möglichst originalgetreues Druckergebnis liefern. Der Leser soll ein PDF Dokument immer nach dem Prinzip WYSIWYG (What You See Is What You Get) in der Form betrachten und ausdrucken können wie es vom Ersteller des Dokuments festgelegt wurde.

PDF wurde im Jahr 1993 von dem 1982 gegründeten amerikanischen Softwareunternehmen Adobe Inc. veröffentlicht und ging aus dem 1991 von Adobe-Mitbegründer John Warnock gestarteten „Project Camelot“ hervor. [1], [2] Ziel des Projekts war es, ein Dateiformat für elektronische Dokumente zu kreieren, sodass dieses Anwendungsprogramm, Betriebssystem und Hardware unabhängig sowie originalgetreu wiedergegeben werden kann.

Anfangs war der Adobe Reader noch kostenpflichtig und PDF war für einen langen Zeitraum ein proprietäres Dateiformat, welches offengelegt im PDF Reference Manual von Adobe dokumentiert ist. Die Spezifikation von PDF ist seit 1993 kostenlos einsehbar. [3] Die International Organization for Standardization (ISO) übernahm PDF im Jahr 2007 in den Standardisierungsprozess und seit der Veröffentlichung von PDF Version 1.7 am 1. Juli 2008 gilt PDF als Offener Standard als ISO 32000-1:2008. [2], [3] Vorher war PDF ein proprietäres Dateiformat von Adobe. Der Begriff Offener Standard bezeichnet einen Standard, der für alle Teilhaber am Markt besonders leicht zugänglich, weiterentwickelbar und einsetzbar ist. Das bedeutet, dass der Standard von einer gemeinnützigen Organisation eingeführt, veröffentlicht sowie weiter bearbeitet wird und gleichmäßige Einflussnahme aller interessierten Parteien ermöglicht. [4]

Im gleichen Jahr publizierte Adobe eine Public Patent Licence zum ISO Standard 32000-1, also PDF Version 1.7, die royalty-free Rechte einräumt, um PDF-Implementierungen zu programmieren, verkaufen und verbreiten. [3] Royalty-free bedeutet hierbei, dass Computerherstellerfirmen pro verkauftes Endgerät keine Gebühren (royalties), sowie keine fixe Jahrespauschale bezahlen müssen. [5] Heute wird PDF seit 2006 von der PDF Association weiterentwickelt. [2]

1.2 Wichtigste Features

Die in den Unterkapiteln genannten Operationen auf dem PDF-Dateiformat beziehen sich hauptsächlich auf Adobe Acrobat-Werkzeuge. PDFs können Texte, Tabellen, Bilder, Pfade, Links, Buttons, Formulare, Audio-, Videoelemente und Funktionen enthalten. Rich Media-PDFs ermöglichen interaktive Inhalte, die eingebettet oder verlinkt werden können. Solche Elemente sind Bilder, Audio, Video oder Buttons, z.B. als digitaler Katalog. [3] Fonts und Bilder sollten grundsätzlich immer eingebettet werden.

In PDFs werden alle Informationen als nummerierte Objekte gespeichert. Objekte können zu Gruppen kombiniert werden. Der aktuelle Farbmodus im Dokument kann in andere Farbmodi konvertiert werden. Um die Navigation innerhalb eines PDF Dokuments zu erleichtern kann man anklickbare Inhaltsverzeichnisse und miniaturisierte Seitenvorschauen (Thumbnails) verwenden. Optional ist eine Gliederung als hierarchische Baumstruktur in Form von Lesezeichen möglich, mit der der Betrachter leichter durch das Dokument geführt werden kann.

PDF-Dateien enthalten grundsätzlich Metadaten. Bei Metadaten oder Metainformationen handelt es sich um strukturierte Daten, die sich auf Merkmale anderer Daten beziehen. Beispiele für Metadaten sind Name, Titel der Datei, Autor, Stichwörter zum Inhalt, das Datum der Speicherung. PDF-Dateien können Dateianhänge enthalten, die geöffnet und im lokalen Dateisystem abgespeichert werden können. [3]

1.2.1 WYSIWYG

Ein PDF-Dokument hat ein festes Layout und eine feste Anzahl von Seiten. Unabhängig von der Software mit der das Dokument angezeigt wird oder mit welcher Hardware es ausgedruckt wird bleiben alle Elemente auf den Seiten immer exakt an derselben Position. Alle Layout- und Formatierungsangaben stammen aus der Erstellungsanwendung. Bei der Konvertierung von Dokumenten mit variablem Layout zu PDF, wie z.B. .txt-Dateien oder HTML muss der Inhalt auf die vorhandenen Seiten und den verfügbaren Platz verteilt werden.

1.2.2 Fonts

Jedes Textzeichen ist ein abstraktes Symbol und ein Schriftzeichen beruht auf einer graphischen Darstellung. Eine Schriftart ist in PDF als Objekt enthalten. Die Schriftart kann mit Werkzeugen in Acrobat bearbeitet werden. Der Text muss ausgewählt sein und es können darauf folgende Operationen angewandt werden: Farbveränderung in RGB, Transparenzen, Verschiebung, Löschen, Skalierung, Verzerrung bzw. Scherung,

Spiegelung, Drehung, Beschneidung oder Ersetzung. Der RGB-Farbraum eignet sich lediglich für die Bildschirmdarstellung und beschreibt die für den Menschen 16,7 Millionen sichtbaren Farben mit Hilfe von additiver Farbmischung mittels Rot, Grün und Blau. Ein Farbraum umfasst die mathematischen Parameter als Daten für die Gesamtzahl der Farben, die auf einem Monitor, Druckmaterial, usw. darstellbar sind. [6]

In Adobe Acrobat Pro kann der gesamte Text pro Seite in Pfade konvertiert werden. Pfade sind mathematisch berechnete Linien, die aus gekrümmten Segmenten bestehen. Der Anfang und das Ende jedes Segments werden als Ankerpunkte bezeichnet und Pfade können geschlossen oder geöffnet sein. Die Form des Pfads kann durch die Griffpunkte an den Ankerpunkten modifiziert werden und Pfadsegmente können somit verformt werden. [7] Auf diese Weise kann man komplexe Formen für z.B. Firmenlogos oder auch eigene Schriftarten designen. Solche manuellen Pfade kann man vor allem in Adobes Illustrator, InDesign oder Photoshop erstellen.

PDF unterstützt Type-1-Fontformate, Multiple-Master-Fonts, TrueType-Fontformate, OpenType-Fontformate, Dfonts, Character Identifier Font (CID) codierte Fonts und Composite-Fonts. Seit PDF 1.3 werden CID-Schrifttypen als Abkömmlinge von Composite-Fonts unterstützt. CID ist ein Synonym für das PostScript Type-0-Format, das eine Adressierung von mehr als 256 Zeichen ermöglicht und für Fonts mit einer großen Zeichenanzahl verwendet wurde. [8] Composite-Fonts sind Basisschriften mit hierarchischem System. Die oberste hierarchische Ebene stellt den root font dar. Alle folgenden Fonts sind descendant fonts. Sie ermöglichten die Einführung von Type-1-Schriften im asiatischen Markt. [9] Falls die Schriftart nicht im Dokument eingebettet wurde, wird sie aus der Ursprungsdatei möglicherweise durch eine Ersatzschrift des Benutzersystems im PDF-Programm substituiert. [9]

1.2.3 Bilder

Generell sollte für das Bearbeiten von Bildern ein externes Bildbearbeitungsprogramm verwendet werden, z.B. Photoshop oder das kostenlose Gimp. Dafür kann für die Bearbeitung in Photoshop das Bild mittels Acrobat Pro aus dem PDF extrahiert werden und später wieder im in Acrobat Pro geöffneten PDF ersetzt werden. Vektorgrafiken als Pfadobjekte und Rasterbilder als Pixelobjekte (Bitmap) können nach Auswahl verschoben, gelöscht, skaliert, verzerrt, gespiegelt, gedreht, die Deckkraft verändert, beschnitten oder ersetzt werden. [9] Der Mehrwert an Vektorgrafiken liegt in dessen Eigenschaften, dass sie auflösungsunabhängig sind, da sie beliebig groß ohne Qualitätsverlust skaliert werden können und dass sie wesentlich weniger Speicherplatz benötigen als Rasterbilder.

Die Auflösung von Bildern kann in Acrobat neu berechnet werden. Niedrig aufgelöste Bilder behalten ihre Auflösung bei. Ein guter Neuberechnungsalgorithmus heißt

bikubische Neuberechnung. Bei Schwarzweißbildern kann eine Neuberechnung zu unschönen Artefakten führen. [10] Generell führt eine Neuberechnung der Auflösung in Bildbearbeitungsprogrammen zu besseren Ergebnissen als in Acrobat. Etwaige Pixelbearbeitungen wie Tonwertkorrekturen oder das Schärfen von Bildern können ausschließlich in Bildbearbeitungsprogrammen vorgenommen werden.

1.2.4 3D-Daten

PDFs mit 3D-Inhalten bestehen aus dem U3D-Flächenmodell oder dem BREP/Flächenmodell PRC. Diese Flächenmodelle werden vorwiegend bei der Visualisierung von Computer-Aided Design (CAD) Daten verwendet. Beide Formate können im Adobe Reader angezeigt, animiert, geschnitten und gemessen werden. Viele Drittanbieter PDF-Reader und die PDF-Viewer im Browser können eingebettete 3D-Daten meist nicht darstellen. Einige CAD-Programme ermöglichen einen 3D-PDF-Export oder Import. [2]

1.2.5 Kommentare

Ein Kommentarobjekt, das mit Dokumentenseiten verlinkt ist, besteht aus 2 technisch separaten Bausteinen. Zum einen werden Kommentare durch ein grafisches Element auf den zugehörigen Seiten symbolisiert, zum anderen wird der Kommentarinhalt in einem rechteckigen Kommentarbereich dargestellt. Ein Anwender kann die Darstellung des Kommentarobjekts je nach Geschmack modifizieren. Unüblicherweise kann ein Kommentar sogar als Video-Kommentar abgespielt werden. Die wichtigsten Kommentartypen sind Notizzettel, Textmarkierung, Stempel, Wasserzeichen, Textboxen, Formen, Freihand-Markierung, Audio, Video und 3D-Illustrationen. Kommentare können optional mit ausgedruckt werden. [11]

1.2.6 Verweise

Technisch gesehen sind Verweise oder Hyperlinks spezialisierte Kommentare ohne Symboldarstellung. Auf der Seite wird ein Ausschnitt zur Platzierung des Verweises gewählt, der über einem Inhaltselement (Text oder Bild) liegt. Der Verweis zeigt auf eine Seite oder Seitenbereich im geöffneten Dokument, eine andere PDF-Datei, eine E-Mailadresse oder URL. Man kann sogar Zielobjekte mit einem im gesamten Dokument eindeutigen Namen einstellen. [11]

1.2.7 Formulare

In PDFs kann man Formularfelder vom Typ Textfeld, Kontrollkästchen, Auswahlknopf, Kombinationsfeld, Auswahlliste, Schaltfläche, Barcode- oder Unterschriftsfeld erstellen. Ein Formularfeld ist ein Objekt zum befüllen und speichern von Felddaten. Die unterschiedlichen Formularfeldtypen weisen verschiedene Eigenschaften in Bezug auf Interaktivität und Gestaltung auf. Jedes Feld hat einen eindeutigen Namen im gesamten Dokument. Mit diesem unikalen Namen können Namensgruppen realisiert werden. Durch eine hierarchische Struktur mittels Teilnamen, die mit einem Punkt voneinander getrennt sind mit dem äußersten Gruppennamen zuerst geschrieben werden, können Felddaten noch besser und logischer beschrieben bzw. strukturiert werden. Jedes Feldobjekt geht Hand in Hand mit einem Widget, welches ein spezielles Kommentarobjekt zur Steuerung darstellt. Diese Widgets stehen für Werte oder Zustände der Felder und sind dafür verantwortlich, dass man Formulare im PDF-Dokument mit dem Computer, Tablet oder Smartphone ausfüllen kann. Außerdem ist es möglich unsichtbare Feldobjekte, die ohne das Widget platziert werden können, zu erstellen, um die PDF-Software anzusprechen. Häufiger werden mehrere Widgets mit einem Feldobjekt gekoppelt. [11]

Um elektronisch ausfüllbare Formulare zu verwenden müssen zusätzlich in Acrobat Formularfelder auf die entsprechenden Stellen platziert werden. Falls ein Listenfeld verwendet wird, sollte man eine Schrift für die Listeneinträge im PDF einbetten. Formulare können einen druckbaren und nicht druckbaren Teil enthalten. In der Druckvorstufe müssen vor dem Druck alle Formularfelder eliminiert werden, damit alle Schriften eingebettet werden können. [9] Es gibt 2 verschiedene Möglichkeiten von PDF Formularen: AcroForms (Acrobat Forms) oder Adobes proprietäre XML Forms Architecture (XFA) forms, welche mit Version 2.0 von der ISO als veraltet markiert wurden. XFAs Haupterweiterungen zu Extensible Markup Language (XML) sind rechnergestützte, aktive Tags und sein Datenformat ist kompatibel mit anderen Systemen, Anwendungen und Technologiestandards. [12] XML ist eine Sprache zur Markierung von Inhalten mit Hilfe von Tags, um die Struktur zu beschreiben und Elemente zu identifizieren. [9] AcroForms unterstützen das Abschicken (submit), Zurücksetzen und Importieren von Daten. Die submit-Aktion transferiert die Namen und Werte eines ausgewählten interaktiven Formularfelds zu einer vordefinierten URL. In der Praxis werden Formulare in einem Grafik- oder Layoutprogramm gestaltet und als PDF exportiert.

1.2.8 Inkrementelles Update

Die ursprüngliche Version einer PDF-Datei bleibt erhalten, während das inkrementelle Update die Änderungen im Dokument enthält. Professionelle PDF-Programme können

ähnlich einer Versionsverwaltung jede geänderte Version des Dokuments laden. Bei einfacheren PDF-Programmen wird lediglich die letzte Version geladen. Bei Verwendung von inkrementellen Updates kann man digital unterschriebene Dokumente ändern ohne dass die Unterschrift ungültig wird, da die Dokumentversion mit der digitalen Unterschrift ein andere Version ist als die nachträgliche Änderung. Dabei muss die digitale Unterschrift als inkrementelles Update gespeichert werden, sonst würde sie bei nachträglicher Dokumentenmodifikation unabhängig von der Änderungsart verfallen. Folglich sollten mehrfach signierte Dokumente ebenfalls mit der Option inkrementelles Update gespeichert werden. [11] Alle Änderungen in einem inkrementellen Update werden am Ende der Datei angehängt. Hingegen werden gelöschte Seiten aus dem Katalog, nicht aber aus der PDF-Datei entfernt. Folglich steigt der Speicherbedarf einer PDF-Datei pro inkrementellem Update. [9]

1.2.9 Kompression

PDF-Dateien sind komprimiert und haben üblicherweise einen Bruchteil der Größe des Ursprungsformats. Dies wird durch Vermeidung von Redundanzen, Erhöhung der Entropie (Zeichendichte) und Weglassen von Informationen bewerkstelligt. Im Allgemeinen gibt es verlustlose und verlustbehaftete Kompression. Die Kompressionsalgorithmen Run Length Encoding (RLE), die genauso effiziente LZW, Flate-Komprimierung, ZIP und CCITT gehören zur verlustfreien Kompression. Zur verlustbehafteten Kompression zählen JPEG, JBIG2 und JPEG2000. [9] Kompressionsalgorithmen sind nicht auf bestimmte Dateiformate beschränkt. In PDF können die folgenden Kompressionsalgorithmen für Bilder verwendet werden: IP, RLE, JPEG, JPEG2000, CCITT und JBIG2. Eine hohe Bildqualität im PDF bedeutet eine größere Datei. Faktoren, die die Bildqualität beeinflussen, sind Breite x Höhe des Bildes, Farbtiefe, Farbraum und die Kompressionsmethode. [11]

Außerdem ist es möglich eine Datenreduktion durch Neuberechnung zu erzielen. Hierbei wird das verlustbehaftete Downsampling verwendet und führt häufig zu nicht befriedigenden Ergebnissen. Es gibt als Neuberechnungsmethoden die eher im Ergebnis mangelhafte Kurzberechnung, sowie die besseren durchschnittliche und bikubische Neuberechnungen. Neuberechnungen in Photoshop führen generell zu besseren Ergebnissen als in Adobe Acrobat Distiller. [9]

PDF-Dateien können zur Weboptimierung serialisiert (linearisiert) werden, sodass Teile des PDFs während des Ladevorgangs dargestellt werden. Liegen unkomprimierte Elemente im Dokument vor, werden diese beim Speichern durch die Flate-Komprimierung, die auch den ZIP-Algorithmus verwendet, komprimiert.

1.2.10 Ebenen

Ebenen werden auch als Optional Content Layers bezeichnet und stellen quasi mehrere Inhaltsschichten auf einer einzelnen PDF-Seite dar, wobei jede Seite im Dokument beliebig viele Ebenen enthalten kann. Jede Ebene kann PDF-Inhalt sozusagen logisch gruppieren und die Bearbeitung von Inhalten auf einer Ebene wirkt sich nur auf diese Ebene aus. Man kann Inhalte auch mehreren Ebenen zuordnen oder keiner Ebene. Ebenen können ein- und ausgeblendet, ihre Reihenfolge verändert, gesperrt, zusammengeführt, aus anderen PDF-Dateien importiert und für unterstützte Dateiformate von Adobeprogrammen, z.B. Photoshop, Illustrator oder InDesign, exportiert werden. Zusätzlich kann man eine Ebenennavigation mit Hilfe von Links und Lesezeichen konstruieren, um Ebenensichtbarkeit für den Betrachter zu steuern. [13]

1.2.11 Portfolio

Ein Portfolio bezeichnet eine Datei bestehend aus anderen Dateien, die kein Hauptdokument enthält, sondern lediglich eine Pseudo-Seite. Diese Pseudo-Seite wird von Portfolio inkompatiblen PDF-Programmen angezeigt. Zusätzlich können andere PDF-Dateien und andere Dateiformate im PDF-Hauptdokument eingebettet werden. [11]

1.2.12 JavaScript

In PDF kann man Ereignisse Aktionen zuordnen, d.h. bei Eintreffen eines Ereignisses wird automatisch eine Aktion ausgeführt. Ein Ereignis ist eine bestimmte Statusänderung von Objekten oder ein interaktives Anwenderereignis. Dabei kann man als Aktion JavaScript-Code aufrufen, dessen Aktion mit Lesezeichen, Verweisen, Seiten und Dokumentereignissen verknüpft ist. Auf Formularfeldern kann ebenfalls JavaScript angewandt werden. [11] Diese JavaScript-Erweiterung für Acrobat ist eine proprietäre Technologie von Adobe. Viele andere nicht-Adobe PDF-Programme bieten keine Unterstützung für JavaScript. [3]

1.3 PDF Dateiformate

PDF hat zahlreiche Dateiformate, von denen die meisten standardisiert wurden, hervorgebracht. Jedes Dateiformat ist einem individuellen Anwendungsbereich zugeordnet und adressiert spezifische Industriebranchen: PAdES für elektronische Signaturen, PDF/X für den professionellen Druck, PDF/A für die Archivierung, PDF/E für den Ingenieurbereich, PDF/H für das Gesundheitswesen, PDF/VT für den Druck mit

variablen Daten, PDF/UA für Barrierefreiheit, PDF/R für gescannte Dokumente und Durchsuchbare PDFs für Stichwortsuche. Im Folgenden stelle ich jedes Format vor und beschreibe seine speziellen Merkmale.

1.3.1 PAdES

PDF Advanced Electronic Signatures (PAdES) ergänzt den Funktionsumfang um Werkzeuge mit denen man elektronische Signaturen erzeugen, anpassen und prüfen kann. Es wurde vom European Telecommunications Standards Institute (ETSI) veröffentlicht, 1999 in PDF 1.3 eingeführt und basiert auf der ISO 32000-1 Spezifikation. Nachfolgend wurde dessen Konzept weiterentwickelt. PAdES erweitert PDF um kryptographische Techniken und ermöglicht sichtbare und unsichtbare digitale Signaturen. Resultierend soll dieses Dateiformat die Integrität, Authentizität, Verbindlichkeit und Rechtssicherheit von digital signierten PDF-Dokumenten herstellen. PAdES implementiert verschiedene Signaturformate wie CMS Advanced Electronic Signatures (CAAdES) und XML Advanced Electronic Signatures (XAdES), unterstützt Zeitstempel und die Validierung des Zertifikatwiderrufsstatus. Zertifikatbasierte Signaturen sollen die Identität des Unterzeichners und die Unabänderlichkeit des Dokuments sichern. Eine zertifizierte PDF-Datei ermöglicht die Umsetzung bestimmter Nutzungsrechte, wie eingeschränkte Bearbeitung, Ausfüllen von Formularen oder gesperrtes Drucken. Eine elektronische Unterschrift kann mit dem Programm Adobe Acrobat Sign erstellt werden. [14]

1.3.2 PDF/X

Speziell für den simpleren Datenaustausch in der Druckvorstufe und der professionellen Druckindustrie wurde PDF/X (Exchange) als ISO 15930:2001 entwickelt. Dieser erst 2001 publizierte Dateiformatstandard beschreibt die speziellen Eigenschaften von Druckvorlagen und vereinfacht die Datenübermittlung von der Design-Agentur und Druckvorstufe bis zum finalen Druck. Besonderen Wert wurde darauf gelegt, dass in offenen Dateiformaten aus Layoutprogrammen keine Informationen über Farbe und Schrift verloren gehen und einer Verfälschung im Druckergebnis vorgebeugt werden kann. [15] Die Entwicklung von PDF/X zielt auf eine Verminderung von Druckfehlern und Mehraufwand in der Druckerei. In der Umsetzung bedeutet das, dass Elemente, die sich nicht sinnvoll drucken lassen, z.B. Video und Audio, nicht berücksichtigt werden. PDF/X-kompatibel bezeichnet die Eigenschaft von Dokumenten, dass sie ohne vorherige Prüfung von der Druckerei direkt verwendet werden können. [16] Beschnitt, Farbangaben und verwendete Schriften sind u.a. für den Druck notwendig

und sollten verwendet werden. Qualitätsanforderungen, die sich auf bestimmte Druckverfahren beziehen, sind nicht implementiert, sondern werden abstrakter definiert. Besondere Qualitätsanforderungen liegen vor allem im Zeitungsdruck, Akzidenzdruck oder Bilderdruck vor. Vielmehr geht es bei PDF/X darum, Grundvoraussetzungen für den Druck sicherzustellen, z.B. ob der richtige Farbraum gesetzt wurde oder korrekte Einstellungen für Überdrucken und Überfüllung vorliegen. Neben Aussparen und Unterfüllung werden Überdrucken und Überfüllung zum Oberbegriff Trapping zusammengefasst. Bei der Überfüllung werden bei verschiedenen farbigen Objekten das hellere Objekt auf dunklem Hintergrund minimal vergrößert, sodass es das dunklere Objekt leicht überlappt. Solche Überlappungen nennt man Traps. Dies beugt weißen Blitzern (Papierweiß scheint durch) beim Druckergebnis vor. Die umgekehrte Vorgehensweise wird bei der Unterfüllung angewendet. Liegt ein dunkles Objekt auf hellem Hintergrund, so wird das helle Objekt an den Rändern zur dunkleren Farbe hin verengt. Vordergrundobjekte stehen in Layout- und Grafikprogrammen standardmäßig auf Aussparen. Dessen Fläche wird im Hintergrund ausgeschnitten, um unerwünschte Farbmischungen zu vermeiden. Im Falle von schwarzen oder sehr dunklem Text auf farbigem Hintergrund sollte man Layoutprogramm diese Vordergrundelemente überdrucken lassen. [17] Generell werden schwarze Schrift oder Linien im Drucker durch 3 oder 4 Farben zusammengesetzt und fehlende Schriften werden häufig durch den Font Courier kompensiert. Im Druck sollten keine verlustlosen Kompressionsalgorithmen für Bilder verwendet werden wie JPEG, da Artefakte auftreten können. Ebenso gibt es keine automatischen Einstellungen für passende Auflösungen von Vollton-, Halbton- oder Strichbildern. [16] Eine Farbe mit 100 % Deckkraft wird als Volltonfarbe bezeichnet. Halbtöne sind Farben mit geringerer Deckkraft. [18] Als Volltonfarben werden auch speziell vorgemischte Druckfarben bezeichnet die anstelle von oder zusätzlich zu den üblichen Prozessdruckfarben in CMYK verwendet werden. Für Volltonfarben ist eine eigene Druckplatte in der Druckmaschine vonnöten. [19] Der CMYK-Farbraum wird im Druck verwendet durch subtraktive Farbmischung mit den Farben Cyan, Magenta, Yellow und Key (Schwarz). Einige Farben können nicht von CMYK reproduziert werden, dann spricht man von Sonderfarben. Strichbilder sind Bilder mit ausschließlich weißen und schwarzen Partien. [20]

Bei allen PDF/X-Dateivarianten außer den Varianten, die ein p enthalten, muss ein Output-Intent im Katalog eingetragen sein. Jede Seite einer PDF/X-Datei muss mindestens die TrimBox oder ArtBox, aber nicht beide gemeinsam, beinhalten. JavaScript bzw. Aktionen, Open Prepress Interface (OPI) Kommentare und Verschlüsselung sind verboten. [9]

Es gibt verschiedene Varianten von PDF/X, die jeweils einen verbesserten Farbspielraum ermöglichen.

PDF/X-1a

PDF/X-1a ist eine Subvariante von PDF/X-1 (Norm ISO 15930-1). In der a-Version sind lediglich CMYK, Graustufen, Schwarz-Weiß (Bitmap) und Sonderfarben möglich und es muss eine Composite-Datei vorliegen. Vorseparierte Dateien sind nicht zulässig. Farben können nicht auf Grundlage von International Color Consortium (ICC) Profilen bei PDF/X-1a definiert werden. [9], [16] Erst seit PDF 1.3 werden ICC-Profile unterstützt, die die Farbeigenschaften, Helligkeit, Weißpunkt, Gammakurve und Farbumfang eines bestimmten Monitors eines spezifischen Geräts beschreiben, sprich ein ICC-Profil definiert wie Farben vom Zielgerät dargestellt werden können. Außerdem wird die Transformation zwischen dem Gerät und dem Profilverbindungsraum Profile Connection Space (PCS) definiert. Dabei gibt es die Variante Eingabepprofile für Kameras oder Scanner und Ausgabepprofile für Monitore oder Drucker. Zweck des ICC-Profils ist möglichst Farbübereinstimmungen zwischen verschiedenen Geräten zu erzielen.

[21] Beim PCS handelt es sich um ein neutrales Farbmodell im ICC-Colormangement, welches den Quellfarbraum mit dem Zielfarbraum verbindet und somit geräteunabhängig ist. Der PCS kann entweder der LAB oder XYZ Farbraum sein. [22]

Es können TIFF-, TIFF/IT-, EPS- und Desktop Color Separation (DCS)-Dateien integriert werden. Transparenzen, Ebenen, LZW- und JBIG2-Kompression, Formularfunktionen und interaktive Elemente dürfen nicht verwendet werden bzw. sind nicht implementiert. Dieser Standard wurde von ISO 15930-1:2001 auf ISO 15930-4:2003 überarbeitet. Lediglich in der überarbeiteten Version, die die Version von 2001 ersetzt, werden auch Sonderfarben unterstützt. [9], [23]

PDF/X-2

Die 2. Variante ist als ISO 15930-6:2003 erschienen und bietet die Voraussetzungen zum farbigen Qualitätsdruck wie Farbmanagement, CMYK- und Sonderfarbdaten in beliebiger Kombination. PDF/X-2 hat in der Praxis wegen der Unvollständigkeit der PDF-Datei für den Datenaustausch in der Druckvorstufe keinerlei Relevanz. Dieser Standard wird durch PDF/X-5 vollkommen ersetzt. [9], [23]

PDF/X-3

Zusätzlich erweitert Version 3 als ISO 15930-3:2002 [23] um die Farbräume RGB und LAB, sowie alle ICC-Profile. Möglicherweise wird in der Druckvorstufe der im Dokument eingestellte Farbraum in CMYK umgewandelt. Es findet eine automatische Transparenz- und Ebenenreduzierung statt. [16] Bei der Transparenzreduzierung

werden einzelne Bildsegmente in vektorbasierte und gerasterte Bereiche unterteilt, überlappende Bereiche der Transparenzen zerschnitten und auf einer Ebene reduziert. [24], [25]

PDF/X-4

Transparenzen, Ebenen, JPEG2000 und OpenType-Schriften können in dieser PDF/X-Variante als ISO 15930-7:2008 [9], [23] verwendet werden, wodurch sie für das Bedrucken von Textilien besonders gut geeignet ist. [16] Es gibt außerdem die PDF/X-4p (Profil) Variante. [9]

PDF/X-5

PDF/X-5 wurde als ISO 15930-8:2010 als vorletzter Standard des PDF/X-Formats verabschiedet und inkludiert externe Elemente und Multichannel-ICC-Profile. [23] Multichannel-Profile unterstützen mehr als 4 Farbkkanäle und können somit für Drucker mit mehr als 4 Druckpatronen eingesetzt werden. [26] Außerdem gibt es die folgenden Varianten: PDF/X-g (external graphic content), PDF/X-pg (external ICC color profiles and external graphical content) und PDF/X-gn (n-colorant ICCprofile) für den mehrfarbigen Verpackungsdruck. [9]

PDF/X-6

Der letzte PDF/X-Standard als Version 6 wurde in ISO 15930-9:2020 offenbart und basiert auf dem PDF 2.0 Standard. In dieser Version sind neben maßgeblichen Neuerungen für die heutigen Print-Anforderungen Lockerungen im Vergleich zu vorherigen PDF/X-Standards eingeführt worden. Die wichtigsten Neuerungen sind Parameter für Tiefenkompensierung, separate Ausgabebedingungen, DPart Metadaten, Informationen zu Sonderfarben im CxF/X-4 Standard und Mixing Hints. [23] Tiefenkompensierung ist eine rechnerische Korrektur und wird bei der Konvertierung eines Farbraums mit großem Tonwertumfang in einen mit kleinem Tonwertumfang angewendet. Dabei soll die ursprüngliche Differenzierung der Tonwerte dunkler Bildteile beibehalten werden können. [27] DPart-Metadaten wurden ursprünglich für den PDF/VT-Standard spezifiziert und ermöglichen mehrteilige PDF-Dateien in Datensätze zu unterteilen. Diese PDF-Dateien können dann automatisch verarbeitet werden. [28] Mixing Hints enthalten Informationen, z.B. wichtig bei Prüfdruck, über erwartete Ergebnisse, wenn mehrere Volltonfarben im Druck miteinander interagieren. Diese Informationen sind beispielsweise für einen Prüfdruck wissenswert. [29]

Zu den Lockerungen zählen die Möglichkeit von Notizen und grafischen Anmerkungen,

strukturelle Aktionen, Formularfelder und digitale Signaturen. Außerdem besteht dieser Standard aus 2 Konformitätsstufen: PDF/X-6p zur Referenzierung von ICC-Profilen und PDF/X-6n für Multicolor-Profilen. [23]

1.3.3 PDF/A

Das PDF/A Dateiformat (Archivable) wurde zur gesetzkonformen Langzeitarchivierung von digitalen Dokumenten entwickelt und solche Dokumente sind zunächst schreibgeschützt. Der ISO-Standard definiert die Konformität der Form von Elementen wie Schriften oder Layout für eine Langzeitarchivierung. Dadurch ist die Lesbarkeit der Dokumente über lange Zeiträume gesichert und die Bedingungen einer revisionssicheren Archivierung gewährleistet. [30] Revisionssichere Archivierung bedeutet, dass gespeicherte Daten vor nachträglichen Modifikationen, Fälschung oder Manipulation geschützt sind. [31] Der Fokus in diesem Dateiformat liegt auf langfristige und einfache Speicherung der PDF-Dateien. Folglich ist die Einbettung von Audio und Video nicht implementiert, aktive Komponenten wie Links, sowie externe Ressourcen wie Grafiken und Schriftarten werden nicht unterstützt, sondern müssen direkt eingebettet werden. Ebenso können Dokumente nicht verschlüsselt werden. Die Einbettung von Metadaten als Extensible Metadata Platform (XMP) wird unterstützt, was die Identifizierung und Suche von Dokumenten erleichtert. Es gibt einige Nachteile von PDF/A. Nicht alle Dokumente können problemlos in dieses Dateiformat umgewandelt werden, wie beispielsweise Dokumente mit Audio, Video oder JavaScript. Nach solch einer Konvertierung zu PDF/A kann es zu Fehlern in der visuellen Darstellung kommen und die Dateigröße kann enorm werden, da alle Elemente direkt eingebettet werden müssen. [30]

PDF/A-1

Seit der ersten Version von PDF/A ist das Dateiformat in die ISO-Norm als PDF/A-1 in ISO 19005-1:2005 übernommen worden. [23] Die Originalversion stellt sicher, dass alle externen Quellen wie Schriften oder Bilder eingebettet sind, unterstützt digitale Signaturen und Hyperlinks. PDF/A-1 ist abwärtskompatibel. Es gibt 2 Qualitätsebenen von PDF/A-1: PDF/A-1b (Basic) und PDF/A-1a (Accessible). Die Basic Variante legt Wert darauf, dass Dokumente eindeutig visuell reproduzierbar sind und Accessible ist zusätzlich für Barrierefreiheit optimiert. Bei Accessible können Text und inhaltliche Struktur von einem Screenreader durch Tagged PDF vorgelesen werden. [30] Des Weiteren werden, Sprach-Angabe und Unicode-Mappings unterstützt. [23]

PDF/A-2

Im Jahr 2011 wurde die PDF/A-2 Version als ISO 19005-2:2011 auf den Markt gebracht. Sie ermöglicht die Kompression von Grafikformaten mit JPEG-2000, Transparenzen, PDF-Ebenen, Portfolios, Object Level XMP Metadaten, Kommentartypen, Annotationen und digitale Signaturen. [23] PDF/A-1-Dateien können in PDF/A-2-Dateien eingebunden werden. Es gibt 3 Varianten von PDF/A-2: PDF/A-2b (Basic), PDF/A-2u (Unicode-Textsemantik) und PDF/A-2a (Accessible). Basic gewährleistet das unveränderte Erscheinungsbild eines Dokuments und definiert die Mindestanforderungen. Die Unicode-Version ergänzt um Unicode-Unterstützung und Indexierung. Accessible setzt alle Anforderungen der ISO-Norm 19005-2 um. [30]

PDF/A-3

Ein Jahr später wurde PDF/A-3 im Standard ISO-19005-3:2012 veröffentlicht. Er basiert auf PDF 1.7 und ermöglicht die Einbettung dynamischer, zur Laufzeit interpretierbaren Komponenten und Dateiformate. Gleichfalls definiert PDF/A-3 die Konformitätsebenen 3b, 3u und 3a. Die u-Variante bietet eine Vereinfachung in der Durchsuchbarkeit von Texten und das Kopieren von Unicode-Text. [23]

PDF/A-4

Viel später im Jahr 2020 wurde PDF/A-4 als ISO 19005-4:2020 herausgebracht. Dieser Standard basiert auf der PDF 2.0 Dateiversion. Sie spezifiziert 2 neue Konformitätsebenen: PDF/A-4f für nicht-PDF/A konforme Dateianhänge und PDF/A-4e für Einbindung von 3D-Inhalten in den Formaten U3D oder PRC für den Engineering-Bereich. [23]

1.3.4 PDF/E

PDF/E (Engineering) gilt als international standardisiertes Austauschformat als Norm ISO 24517 für technische Dokumente und wird im Maschinenbau, in der Fertigung und im Baugewerbe für Fertigungspläne, Konstruktionszeichnungen oder technische Dokumentationen verwendet. Das PDF/E Dateiformat von 2008 ist speziell für das Ingenieurwesen entworfen und kann interaktive 3D-Elemente und Animationen darstellen. Im einzelnen können CAD-Dateien im 3D- und 2D-Format eingebettet werden. Die 3D-Elemente können im Dokument ausgeklappt oder gedreht werden. Metadaten und interaktive Funktionen wie Lesezeichen, Formulare oder Hyperlinks werden unterstützt. [15]

1.3.5 PDF/H

Das PDF/H (Healthcare) Dateiformat soll im Gesundheitswesen Patientendaten erfassen, austauschen und archivieren. Hierbei wird besonders Wert auf die Anforderungen des Datenschutzes in gesundheitsspezifischen Ämtern, Institutionen und Arztpraxen gelegt. PDF/H wurde zwar im Jahr 2008 kreiert, jedoch wurde es nicht in den Normierungsprozess der ISO eingebunden. [23] Es handelt sich eher um eine Best-Practice für die Umstellung von Papiergesundheitsakten auf PDF als e-Akte. Die Digitalisierung soll gesundheitsbezogene Daten strukturieren, verwalten und so präsentieren, dass Forscher*innen und Beschäftigte im Gesundheitswesen effizienter auf sie zugreifen können.

1.3.6 PDF/VT

Basierend auf PDF/X wurde PDF/VT als spezielles Austauschformat im variablen Datendruck (Variable Data) und Transaktionsdruck (Transactional Printing) im Jahr 2010 auf den Markt gebracht. [32] Wiederkehrende Elemente wie Texte, Grafiken oder Bilder sollen effizienter verarbeitet und an den Drucker übertragen werden können. [15] Variabler Datendruck bezeichnet ein digitales Druckverfahren bei dem einzelne Parameter von Printprodukten individuell variiert werden können, wobei das Grundlayout beständig bleibt. Folglich können große Mengen von Printprodukten mit Personalisierung hergestellt werden, z.B. Werbebriefe mit konstanten grafischen Elementen wie Firmenlogos und individuellen Namen der Kund*innen. Dadurch können Firmen ihr Corporate Identity-Layout behalten und ihre Kund*innen persönlicher ansprechen. Der Begriff Transaktionsdruck definiert das Drucken von Transaktionsdokumentationen wie Rechnungen, Mahnungen, Lieferscheine oder Quittungen im Waren- und Dienstleistungssektor. Herausstechend ist, dass PDF/VT große Mengen an variablen Daten in einer einzigen PDF-Datei speichern kann, wobei es immer einen Satz von statischen und variablen Daten gibt. Diese Vorgehensweise spart Zeit, Kosten und reduziert Fehler. Vorteilhafterweise werden ICC-Profile unterstützt. [32] Die erste Version als ISO 16612-1:2005 konnte sich auf dem Markt nicht durchsetzen. [23]

PDF/VT-2

Die zweite Version als ISO 16612-2:2010 implementiert die Verwendung externer grafischer Inhalte und das Streamen von mehrteiligen Multipurpose Internet Mail Extension (MIME) Paketen in der Version PDF/VT-2s. MIME-Typen (media types) zeigen Art und Format von Dokumenten, Dateien oder einem Sortiment von Bytes an und sind standardisiert. Ein MIME-Typ besteht üblicherweise immer aus einem durch

ein / getrennten Typ und Subtyp. Der Typ repräsentiert die generelle Kategorie des Datentyps und der Subtyp die exakte Datenart des Typs. Jeder Typ hat seine eigene Menge an Subtypen. [33] Zum Lesen von PDF/VT-2 Dokumenten wird ein PDF/X-4- bzw. PDF/X-5- oder PDF/VT-konformer PDF-Reader benötigt. [23]

PDF/VT-3

Spezialisiert auf die Integration von variablen Daten (DPart-Metadaten) und den Transaktionsdruck ist die dritte PDF/VT Variante als ISO 16612-3:2020. [23]

1.3.7 PDF/UA

Das PDF/UA (Universal Accessibility) Dateiformat dient der Erstellung barrierefreier Dokumente. Die PDF/UA-Kennzeichnung stellt eine Klassifizierung für barrierefreie Dokumente dar und orientiert sich an den Anforderungen der Web Content Accessibility Guidelines (WCAG) 2.0 des World Wide Web Consortiums. Als Rechtliche Grundlage dient die Barrierefreie-Informationstechnik-Verordnung (BITV) 2.0. Um die Anforderungen der PDF/UA-Kennzeichnung zu erfüllen, müssen Dokumente bestimmte technische und inhaltliche Vorgaben erfüllen. Auf Basis des Matterhorn-Protokolls, welches aus 31 Prüfpunkten und 136 Konformitätskriterien besteht, müssen Aufbau von Texten, Bildern, Listen, Tabellen und Formularefeldern festgelegte Vorgaben erfüllen. Diese Konformitätskriterien können auf der einen Seite nur von einer Software geprüft werden und auf der anderen Seite nur von Menschen.

Menschen mit Einschränkungen sollen das Dokument optimal nutzen können. Zur Erleichterung des Verständnisses sollten Überschriften, alternative Texte für Bilder, Beschreibungen für Tabellen, Tags und eine klare Lesereihenfolge verwendet werden. [34] Es gibt die PDF/UA-1 Version aus ISO 14289-1:2012 und die überarbeitete Version PDF/UA-1 aus ISO 14289-1:2014, die erst 2020 als gültig erklärt wurde. [23]

1.3.8 PDF/R

Speziell für die Speicherung, den Transport und Austausch von gescannten Dokumenten gibt es das ISO 23504-1:2020 standardisierte Format PDF/R-1. Es bietet die grundsätzlichen Funktionalitäten von TIFF, bitonalen, Graustufen- und Echtfarbbildern. [23] Bitonale Bilder bestehen lediglich aus einer Vordergrund- und Hintergrundfarbe.

1.3.9 Searchable PDF

Searchable PDFs können mit Suchfunktionalitäten eines PDF-Readers durchsucht werden. Es kann gezielt nach Zahlen oder Stichwörtern durchsucht und Inhalte können zur Bearbeitung in anderen Programmen kopiert werden. Man erkennt durchsuchbare PDFs daran, dass man den Text markieren kann. Diese PDF-Art wird üblicherweise durch die Optical Character Recognition (OCR) Technologie erstellt. Bei OCR handelt es sich um optische Zeichenerkennung, die Textzeichen und Dokumentstruktur analysiert. Auf diese Weise können gescannte Dokumente oder Pixelbilder als PDF abgespeichert und in ein Durchsuchbares PDF in Acrobat umgewandelt werden. Während der Umwandlung wird dem Dokument eine zusätzliche unsichtbare Textebene, die unter der Bildebene liegt und durchsuchbar ist, auf der Seite hinzugefügt. In Acrobat ist es außerdem möglich mit der einfachen Suche innerhalb einer Datei nach Suchbegriffen zu suchen, mit der erweiterten Suche oder der Suchen-Werkzeugleiste mehrere PDF-Dokumente zu durchsuchen und speziell in der erweiterten Suche u.a. Objektdaten und Bildern zu lokalisieren. Textbasierte PDF-Dateien können grundsätzlich durchsucht werden und auch in andere Dateiformate wie Microsoft Word, Excel oder PowerPoint umgewandelt werden. Durchsuchbare PDFs ermöglichen Barrierefreiheit. Sie können von Bildschirmleseprogrammen für Sehbehinderte vorgelesen oder vergrößert werden. [35]

1.4 PDF Dateiversionen

Gestartet mit Version 1.0 war PDF lediglich ein proprietäres Dateiformat von Adobe. Die Freigabe von PDF als offenes und kostenlose Dateiformat führte letztendlich erst zu seiner weltweiten Verbreitung und Anerkennung. Erst im Jahr 2005 entwickelte sich Version 1.4 zu einem internationalen ISO Standard. Die letzte Dateiversion 2.0 von 2017 ist schon eine Weile her und es hat sich zeitlich nur das PDF/R-Dateiformat später entwickelt als PDF 2.0.

1.4.1 PDF 1.0

PDF 1.0 wurde 1992/1993 entwickelt und ist wurde nicht normiert. 1992 wurde die Spezifikation als Buch verkauft und 1993 das der Spezifikation entsprechende digitale Format entwickelt, welches ausschließlich den RGB Farbraum darstellen konnte. Medien, die einen anderen Farbraum besitzen wurden in RGB konvertiert. In der Druckindustrie ist jedoch der CMYK-Farbraum von Bedeutung. Folglich ist PDF 1.0 nicht für den Printbereich geeignet. Damals war Adoba Acrobat 1.0 das einzige Programm mit dem man diese Dateiversion bearbeiten konnte. [23]

1.4.2 PDF 1.1

Genauso ist das 1994 kreierte PDF 1.1 keine Norm und implementiert weiterhin nur den RGB Farbraum, jedoch geräteunabhängig. Zusätzlich benötigte man ein Update von Adobe Acrobat auf Version 2.0. Erstmals sind in diesem Format das Einbetten von Hyperlinks optional gebunden an Aktionen, mehrseitige Artikel und Threads, Passwort-verschlüsselung und Notizen bzw. Anmerkungen erschienen. [23] Hier kann man bereits Benutzungseinschränkungen geltend machen, wie Schutz vor unerlaubtem Öffnen des PDF-Dokuments, das Sperren von Teilfunktionen, z.B. Entnahme von Texten und Bildern, sowie verbotenes Drucken. Verschlüsselt wird mit einer 40-Bit-Schlüssellänge durch den RC4-Algorithmus. TrueType-Fonts können nativ eingebettet werden und einige geräteunabhängige, d.h. Commission Internationale de l'Éclairage (CIE) basierte Farbräume, können eingestellt werden. [9] Die Internationale Beleuchtungskommission mit der Abkürzung CIE ist eine unabhängige Non-Profit-Organisation für Licht, Beleuchtung, Farbe und Farbräume. Sie entwickelt und publiziert hierzu Standards und Messverfahren. [36], [37] Binäre Abspeicherung der PDF-Datei ist nun möglich, womit eine Reduktion der Dateigröße um 25 % erreicht werden kann. [9]

1.4.3 PDF 1.2

Fast alle für die Druckvorstufe nötigen Parameter aus PostScript wurden in Version 1.2 umgesetzt. Das 1996 erschienene PDF 1.2 wurde ebenfalls nicht standardisiert, jedoch ermöglichte es erstmals den druckbaren CMYK-Farbraum und Sonderfarben zu verwenden. Des weiteren wurden interaktive Formularfunktionen, Unicode, Unterstützung der OPI 1.3 Spezifikationen und eine Druckrasterfunktion implementiert. [23] OPI ist ein Workflow Protokoll, welches in der elektronischen Druckvorstufe verwendet werden kann, um Desktop Publishing Systeme und high-end Cisco Enterprise Print System (CEPS) zu verknüpfen und optimiert die Übertragung von hochauflösenden Dateien in Netzwerken. [38] In PDF 1.2 wurden erstmalig AcroForms vorgestellt. Zusätzlich ist das Abspielen von Video und Audio ausschließlich als Link zu einer externen Datei möglich. Composite-Fonts, CID-Fonts und alle CIE-basierte Farbräume werden unterstützt. [9]

1.4.4 PDF 1.3

1999 wurde PDF 1.3 mit fehlender Normierung auf den Markt gebracht und trug seinen Teil 2001 und 2002 bei zur Standardisierung des ISO PDF/X Standards. Es ist kompatibel mit PostScript 3 und bietet die Neuerungen der 2-Byte CID Schrifttypen, OPI 2.0 Unterstützung, Farbraumerweiterung um Sonderfarben durch ICC-Profile

und den DeviceN-Farbraum, weiche Schatten und Farbübergänge bzw. Verläufe in einem auflösungsunabhängigen Modus (Smooth Shading), digitale Signaturen, RC4-Verschlüsselung (40 Bit in Acrobat 4 und 56 Bit in Acrobat 4.05) und JavaScript. [9], [23] Der DeviceN-Farbraum wird auch in PostScript 3 unterstützt und erlaubt die willkürliche Kombinationen von Farbkanälen beim Composite-Druck. Dokumente mit Schmuckfarben müssen auf einem Gerät mit physikalisch getrennten Kanälen für jede verwendete Schmuckfarbe ausgegeben werden. Schmuckfarben sind festgelegte Farbtöne, die nicht aus Prozessfarben gemischt werden. Sie können Kosten sparen und vermeiden Farbschwankungen. Besonders verbreitet sind HKS und Patone. [17] Folglich kann kein CMYK- oder RGB-Gerät Dokumente mit Schmuckfarben farblich korrekt darstellen. Davon sind fast alle Farbdruckersysteme betroffen, sowie die von Adobe Acrobat erzeugte Bildschirmdarstellung von PDF Dokumenten mit Schmuckfarben. Ohne den DeviceN Farbraum können Bilder mit Kombinationen von z.B. CMYK und 2 Schmuckfarben oder Schwarz und eine Schmuckfarbe nicht im Composite-PostScript und Composite-PDF wiedergegeben werden, sondern höchstens mit CMYK als Näherung. [39] Dateianlagen jeglichen Typs können in Form von Streams im Body direkt eingebettet werden. Folglich kann eine PDF-Datei containerisiert werden. 3 weitere Boxen werden dem PDF-Format hinzugefügt: TrimBox, BleedBox und ArtBox. Für Überfüllungen in der Druckvorstufe können Traps als form XObject gespeichert werden. Bilder können auf Basis von Image XObjects für komplexere Pfadresultate maskiert werden. Eine Maske kann Sektionen eines Bildes ausblenden ohne diese zu löschen. [9]

1.4.5 PDF 1.5

Im Jahr 2003 kam PDF 1.5 auf den Markt und hat sich nicht zur Norm entwickelt. In dieser Version wurden erstmals Ebenen und 16-Bit-Farbtiefe in eingebetteten Bildern implementiert. Des Weiteren wurden gesteigerte Kompressionstechniken einschließlich Objekt-Streams und JPEG2000-Kompression, sowie eine verbesserte Cross-Reference Tabelle und XRef-Streams implementiert. 12 weitere Seitenübergänge für Präsentationen, verbesserte Unterstützung für Tagged PDF und die Adobe proprietäre Technologie XFA wurden außerdem hinzugefügt. [9], [23]

1.4.6 PDF 1.4

Der erste PDF ISO-Standard ISO 16612-1:2005 wurde zeitlich nach Version 1.5 verabschiedet. In diesem Format sind Transparenzen, JavaScript 1.5, bessere Integration von Datenbanken, Titel, Textblockdefinition, JBIG2-Komprimierung und 128-Bit-RC4-Verschlüsselung erstmalig integriert worden. [23] Außerdem wurde die Kennzeichnung

der Ausgabeabsicht über den Output-Intent mit einer Kompatibilität zu Version 1.3 implementiert. [9]

1.4.7 PDF 1.6

In diesem ISO 15930-8:2008 Standard sind erstmals folgende Technologien in diesem Format eingeführt worden: NChannel-Farbraum, welches eine Erweiterung von NDevice mit Sonderfarben bzw. Schmuckfarben ist, JPEG 2000-Kompression, Advanced Encryption Standard (AES) Verschlüsselung, direkte Einbettung von OpenType-Schriften, 3D-Daten (U3D) und XML Formulare. [23]

1.4.8 PDF 1.7

Veröffentlichung am 1. Juli 2008 ist PDF in Version 1.7 als ISO 32000-1:2008 als Offener Standard definiert worden. Es wurden komplexer 3D-Objekte, Kontrolle über 3D-Animationen und Einbettung von Standard-Druckeinstellungen wie Papierauswahl, Anzahl der Kopien und Skalierung hinzugefügt. [23]

1.4.9 PDF 2.0

XFA ist in PDF 2.0 als ISO 32000-2:2017 vom ISO-Gremium als veraltet markiert worden. Mehr Einstellungsmöglichkeiten und Funktionen sind diesem Format beigelegt worden: Erweiterte Definitionen der Halbtöne der Rasterung, z.B. für Flex- oder Tiefdruck, konsistente Transparenz, erweiterte Tagged-PDF Funktion für Barrierefreiheit, Definition von Sonderfarben über Spektralfarben, alternierende Reihenfolge der zu druckenden Farben, Steuerung der Schwarzpunktkompensation, AES-256-Bit-Verschlüsselung, DPart-Metadaten und Einbettung von 3D-Messungen oder Querschnittsdaten. [23] Spektralfarben bezeichnen die Regenbogenfarben, die entstehen, wenn weißes Licht durch ein Prisma gebrochen wird. Schwarzpunktkompensation stammt begrifflich aus der Bildverarbeitung. Bei diesem Prozess wird der Schwarzwert eines Bildes so angepasst, dass die Darstellung von dunkleren Bereichen verbessert wird. Ist der Schwarzwert falsch eingestellt, so können dunkle Bildbereiche grau oder „ausgewaschen“ erscheinen, was zu einer Reduktion an Detail und Kontrast führt. [40]

1.5 PDF Implementierung

PDF ist eine vektorbasierte Page Description Language (PDL) (Seitenbeschreibungssprache) und basiert auf dem PostScript-Format. Der MIME-Type von PDF heißt `application/pdf`. Eine PDL beschreibt den Seitenaufbau, wie die Seite in einem Ausgabeprogramm bzw. Ausgabegerät, z.B. einem Drucker, aussehen soll. PDLs können Seiten mit Vektoren beschreiben. An den Drucker wird durch die PDL ein Datenstrom der zu druckenden Ausgabe erzeugt und an den Drucker gesendet. Der Raster Image Processor (RIP) eines Druckers wandelt die Bildschirmausgabe in die gerasterte Druckerausgabe um. Viele APIs der Hardwareabstraktionsschicht im Computer wie Graphics Device Interface (GDI) oder OpenGL können in PDL ausgegeben. Speichert ein Satzprogramm den Seitenbeschreibungscode eines Dokuments in einer Datei, müssen Drucker die PDL nicht selbst verarbeiten. Eine PostScript Printer Description (PPD) Druckerbeschreibungsdatei definiert Fonts, Papiergröße, Auflösung und andere Standardeigenschaften für einen bestimmten PostScript-Drucker. [41] Im Common Unix Printing System, der Standard-Druckersteuerung von Linux hat der PostScript und der PDF-Interpreter `ghostscript` die Aufgabe eines RIP, d.h. er ist für die Umwandlung in die gerasterte Druckerausgabe auf dem Drucker zuständig. Zudem stellen PDLs eine Schnittstelle zum Quellcode eines Dokuments bzw. zu Programmen, die Quellcode verwalten oder das Dokument formatieren können, dar. Die PDL PDF erweitert die Funktionalität von PostScript um anklickbare Links (Hypertextfunktionalität), die die Navigation im Dokument erleichtern und URLs, die sich automatisch im Browser öffnen. [42]

1.5.1 PostScript

Sowohl die PostScript als auch PDF haben zum Ziel die Seiten eines Dokuments vollständig für die Ausgabe in der Druckvorstufe zu beschreiben. Die abwärtskompatible, stackorientierte, Turning-vollständige Hochsprache PostScript als PDL wurde in den 1980er Jahren von Adobe erfunden. [43], [44] Hinzu wurden weitere PostScript-Technologien entwickelt, die aus der Programmiersprache PostScript, Grafik-, Textformatierungsanwendungen, Treibern und Abbildungssystemen bestehen. PostScript hat sich als Industriestandard etabliert. Die letzte Version ist PostScript 3 von 1997. Seine primäre Anwendung gemäß des Adobe Imaging Models findet sich in der Beschreibung von Textdarstellung, graphische Formen und Bildern auf gedruckten oder auf dem Bildschirm angezeigten Seiten. Dabei ist die Beschreibung des Dokuments geräteunabhängig und eine PostScript-Datei ist sequentiell organisiert. PostScript unterstützt unter anderem beliebige geometrische Formen, Zeichenoperationen in Graustufen, RGB, CMYK und CIE (Yxy-Farbraum), vorinstallierte oder benutzerdefinierte Fonts,

Digitalbilder jeglicher Auflösung je nach Farbmodell und ein allgemeines Koordinatensystem.

In PostScript wird eine Seite, die ein Koordinatensystem umspannt, als Grafik betrachtet, die verschiedene Grafikelemente enthalten kann. Dabei werden die Textzeichen eines Fonts, gemäß des Adobe Imaging Models, als graphische Formen betrachtet auf denen Grafikoperationen möglich sind. Das Koordinatensystem unterstützt alle linearen Transformationen, die auf alle Seitenelemente angewandt werden können. Die Seitenbeschreibung in PostScript kann auf jedem Gerät, was einen PostScript-Interpreter implementiert, gerendert werden. In diesem Prozess wird die high-level PostScript-Beschreibung in low-level Rasterdatenformate für das jeweilige Gerät übersetzt. [43] Jede PostScript-Datei muss durch einen RIP interpretiert und die Dateien können in American Standard Code for Information Interchange (ASCII) vorliegen. [43] Der PostScript-Interpreter als RIP rechnet die Benutzerkoordinaten in Gerätepixel um, wobei auch die technischen Eckdaten des jeweiligen Geräts mitberücksichtigt werden. Theoretisch kann derselbe PostScript-Code auf verschiedenen Endgeräten mit unterschiedlicher Auflösung eine mehr oder weniger identische Ausgaben erreichen. Den Interpreter gab es früher als Hardware-RIP, der allerdings nicht mehr zum Einsatz kommt. Heute gibt es lediglich Software-RIPs, die von einem Betriebssystem kontrolliert werden und hardwareunabhängig arbeiten. Fast alle RIP-Hersteller orientieren sich am Standard und somit sind PostScript-Fehler in der Druckvorstufe minimiert worden. [9]

1.5.2 Adobe Imaging Model

PDF und die PostScript Programmiersprache haben das Adobe Imaging Model als Gemeinsamkeit. Es kann nahtlos zwischen PDF und PostScript konvertiert werden und beide erzielen das gleiche Ausgabeergebnis beim Druck. Dennoch fehlt PDF das general-purpose Framework der PostScript Programmiersprache. Stattdessen stellt ein PDF Dokument eine statische Datenstruktur optimiert für den random-access auf beliebigen Seiten dar und enthält zusätzlich Seitennavigationsinformationen für interaktives Lesen. Im Kontrast dazu sind PostScript-Dateien seriell organisiert.

Das high-level Imaging Model beschreibt die Elemente, die auf der Seite dargestellt werden, also Text, Geometrie oder Vektorgrafiken, als abstrakte graphische Elemente aus Vektorobjekten und Bézierkurven, anstatt als Pixeldefinitionen. [43] Pfad-Objekte werden durch verbundenen Punkten, Linien und Kurven mathematisch berechnet. Text-Objekte bilden eine eigene Datenstruktur (Fonts), die als Glyphen aus Pfad-Objekten bestehen. Bild-Objekte sind aus einzelnen Pixelwerten in einer rechteckigen Fläche aufgebaut und enthalten eine eindeutige Position im Rechteck und einen Farbwert. Die abstrakte Beschreibung graphischer Elemente macht das Imaging Model zu einem geräteunabhängigen Modell und es kann hochwertige Ausgaben auf vielen

verschiedenen Druckern und Bildschirmen liefern.

Eine Anwendung generiert zuerst die geräteunabhängige Beschreibung des gewünschten Ausgabegeräts in der PDL. Daraufhin interpretiert eine Firmware oder Software eines spezifischen Ausgabegeräts für Rasterausgaben die Beschreibung und rendert sie im Ausgabegerät. Hierbei hat die PDL die Rolle eines Austauschstandards für die Übertragung und Speicherung von druckbaren oder auf Displays darstellbaren Dokumenten. [43] Die Flexibilität des Adobe Imaging Models zeichnet sich durch seine flexible Ausgabefähigkeit auf jeglichen Rastergeräten und hochauflösenden Displays. Die Größe des Pixels wird durch die Ausgabeauflösung des Rastergeräts bestimmt, die bei Monitoren zwischen 75 und 110 Pixels per inch (ppi) und bei Tintentstrahl- bzw. Laserdruckern zwischen 300 und 1400 ppi liegt.

Später wurde das Imaging Model für die Unterstützung von Transparenzen erweitert. Diese Funktionalität wurde speziell für PDF implementiert und wird nicht von PostScript unterstützt. Bei PostScript überschreibt das zuletzt gezeichnete Objekt alle darunterliegenden Objekte im Hintergrund. [9]

1.5.3 Dateiformataufbau

PDF ist ein reines objektbasiertes Dateiformat und PDF-Dateien enthalten Dokumentdaten in binärer Form. PDF-Dateien bestehen aus Sequenzen von 8-Bit-Binärdaten bzw. 7-Bit-ASCII. [9] Ein Dokument entspricht immer einer Datei. Das Einbetten von binären Dateien in beliebigen Formaten oder anderer PDF-Dateien ist möglich.

Die Struktur besteht im Wesentlichen aus 4 Komponenten. Zunächst spezifiziert der Header die Version der PDF-Spezifikation (Signature) und den Charset Identifier. [45] Der Body enthält die Daten der Objekte, aus denen das Dokument besteht. Objekte im Body sind in einer komplizierten hierarchischen Struktur, dem Dokument, verknüpft. Zur Dateigrößenoptimierung werden komplexe Verbindungen zwischen den Daten hergestellt und die Daten eines mehrfach vorkommenden Objektes müssen nur einmal gespeichert werden. [11] Jedes Objekt wird im Body mit obj und endobject eingekapselt und jeder Stream mit stream und endstream. [9] Die Cross-Reference Table (Xref) deckt die Informationen über die Position der indirekten Objekte in der Datei ab. Liegt ein Verweis auf ein Objekt in der Xref, so kann es für andere Seiten wiederverwendet werden. In Xref sind alle Informationen für den random-access eingetragen. Neben Objekteinträgen können auch Cross-Reference-Streams hinterlegt werden. Xref ist der einzige Teil in PDF mit einem konstanten Format und kann aus mehreren Cross-Reference-Sections und Subsections jeweils mit Objekteinträgen für das inkrementelle Update bestehen. Ein Objekteintrag ist wie folgt aufgebaut: Die ersten 10 Bytes für die Byteposition (Offset), mit Leerzeichen als 1 Byte getrennt, die folgenden 5 Bytes für die eindeutige Generation Number und zuletzt eine ebenfalls durch ein Leerzeichen getrennte Markierung mit f oder n. f steht für free entry, d.h.

gelöschtes Objekt, und *n* für in use entry. Das erste Objekt in Xref hat eine Generation Number von 0 und wird nicht verwendet. [46] Zuletzt definiert der Trailer die Startposition der Cross-Reference Table als Pointer *startxref* und von speziellen Objekten im Body. [46] Außerdem enthält der Trailer die ID der PDF-Datei, einen Size Entry, Metadaten und eine Referenz zum /Root Objekt (Katalog) im Body. Abschließend markiert %%EOF das Dateende. [45], [46]

Beim inkrementellen Update wird am Ende der Original-Trailers ein Body Update, eine neue Xref-Section und ein Updated Trailer der Datei hinzugefügt. In der neuen Version der Xref-Section werden alle Objekte aufgeführt, die gelöscht, geändert oder ersetzt wurden. Der Updated Trailer umfasst alle Änderungen bezüglich des originalen Trailers. [9]

PDF-Viewer prozessieren PDF-Dateien im Prinzip vom Ende bis zum Anfang, d.h. vom Trailer zum Body. [46] Beim Parsen wird zunächst die Signature überprüft, dann wird die Position von %%EOF und *startxref* gesucht, was die Position der Xref angibt. Die Xref stellt die Offsets jedes Objektes zur Verfügung und der Trailer zeigt auf den /Root Entry des Root-Objekts. Nachfolgend werden alle Objekte geparkt und überprüft, ob /Root den /Pages Entry, /Pages ein Seiten-Array, jede /Page eine Größe der /MediaBox hat, /Contents als Stream-Objekt vorliegt und /Resources das /Font dictionary definiert. Zuletzt wird die Seite gerendert durch BeginText, Auswahl des Fonts, Bewegung des Cursors, Anzeigen des Strings und EndText. [45] Referenzen werden nicht in der parse time ausgewertet, sondern nur nach Verwendung. [47]

Seitenobjekte und die meisten PDF-Strukturen sind gerichtete azyklische Graphen. [47] PDF-Objekte können in den folgenden Typen vorliegen: Booleans, Integers oder reelle Zahlen, Strings, Namen, die mit einem / Zeichen beginnen, Arrays, Dictionaries, Streams, Null Objekt oder Kommentare mit einem vorangestellten %. Strings können als <Length> <string> oder <string> <terminating symbol> definiert werden. Dictionary Objekte sind als ein Paar von Objekten, genannt Entries, implementiert. Aktionen werden beispielsweise als Entries gespeichert. [48]

Text in AcroForms wird als Stream gespeichert. In Streams kann alles gespeichert werden und sie werden nicht interpretiert. Die Objekte in Streams können Referenzen auf andere Objekte vor allem Seiten enthalten. [46] Objekte können so gruppiert werden, wodurch eine bessere Komprimierung erreicht wird, vor allem bei der Gruppierung von Linien. [9]

Es gibt graphics state-Operatoren, die eine Datenstruktur, genannt graphics state, manipulieren. Graphics state ist ein globales Framework mit dem andere Grafikoperatoren ausgeführt werden. Es enthält die aktuelle Transformationsmatrix (CTM), welche die Benutzerortskordinaten in Ausgabegerätekoordinaten mappt, die aktuelle Farbe, den aktuellen Clipping Pfad und andere Parameter, die implizite Operanden

von Zeichenoperatoren sind. Außerdem gibt es noch Pfaderstellungsoperatoren, Pfadzeichenoperatoren und Textoperatoren. Zusätzlich werden marked-content Operatoren für den Dokumentenaustausch verwendet. [49]

Grundsätzlich besteht eine PDF-Datei aus 5 Seitenrahmen als Boxen für jede Seite. Diese Boxen werden weder gedruckt, noch standardmäßig angezeigt. Die äußerste und größte Box ist die MediaBox. Sie entspricht der physischen Größe des Mediums und dem Papierformat. Sie muss immer in einer PDF-Datei vorhanden sein und enthält auch alle Objekte, die über den Rand der Seitengröße hinausragen, wobei diese über die MediaBox gehen können. Innerhalb der MediaBox liegt als nächste Box die CropBox. Sie entsteht durch das Beschneiden der Seite und definiert den Ausschnitt zur Anzeige in Acrobat. Zusätzlich wird sie meist zum Platzieren von PDF-Dokumenten in anderen Programmen und zum Ausdrucken aus Acrobat verwendet. Beim Erstellen der PDF-Datei hat die CropBox die Größe der MediaBox und ist immer vorhanden. Darunter liegt die BleedBox. Sie definiert die Beschnittzugabe, die in der Praxis meist auf 3 mm gesetzt wird. Beschnittzugabe wird in der Druckvorstufe verwendet, damit keine weißen Blitzer am Rand des beschnittenen Druckbogens zu sehen sind. Die optionale BleedBox sollte kleiner als die MediaBox sein. Druckmarken wie Passkreuze, Schnittmarken oder Farbbalken sollten immer außerhalb der BleedBox liegen. Die TrimBox steht für die finale Größe des gedruckten und zugeschnittenen Dokuments. Ein zu druckendes Dokument benötigt zwingend die im PDF-Dateiformat optionale TrimBox, deren Größe kleiner oder gleich der BleedBox und MediaBox sein sollte. Der Standardwert für die TrimBox ist die Größe der CropBox. Ganz innen im Boxmodell von PDF liegt die ArtBox. Sie stellt einen Rahmen um alle druckbaren Objekte dar und legt somit den Inhalt fest. Meist sind ArtBox und TrimBox von der Größe her identisch. Im Bezug auf PDF/X-Dateien darf nur entweder die ArtBox oder die TrimBox vorhanden sein. Da die ArtBox optional ist, dient sie vor allem in Ausschussprogrammen als Default-Box, falls keine TrimBox angelegt wurde.

Erstellt man eine PDF-Datei muss man zwischen composite oder separiert wählen. Bei einer separierten Ausgabe gibt es für jeden Farbauszug bei CMYK inklusive aller Sonderfarben einen eigenen Farbauszug. Inhalte einer Composite-PDF-Datei können einfach verändert werden. Farbsimulationen und die Nutzung der Überdruckvorschau sind in einem separierten PDF-Dokument nicht mehr möglich. Separierte PDF-Dateien sind nicht medienneutral, da eine Farbverrechnung bei der Separation erfolgt. Überfüllung bleibt im Composite-PDF nicht erhalten, jedoch Überdrucken und Aussparen. In modernen Workflows der Druckindustrie hat man sich vom separierten Workflow abgewendet. [9]

Eine PDF-Datei besitzt 3 verschiedene Layers, womit nicht die Optional Content Layers gemeint sind. Zunächst enthält die Content Layer alle druckbaren Objekte, sprich Grafiken, Bilder und Texte. Elemente dieses Layers können ausschließlich mit

Acrobat Pro bearbeitet werden. Oberhalb der Content-Layer liegt die Enhancement Layer. In ihr sind Lesezeichen, Hyperlinks, Thumbnails, digitale Signaturen, Annotationen, Formularfelder und alle Multimedia-Elemente wie Video und Audio abgelegt. Die unsichtbare Information Layer umfasst alle Basisinformationen zu Schriftdaten, Formularfeldinhalten, Verschlüsselungsinformationen, Querverweistabellen und PDF-spezifische Informationen. [9]

PDF-Layouts können in linearer oder nicht linearer Form aufgebaut sein. Nicht lineare PDFs sind kleiner, aber langsamer und die Seiten sind in der Datei an verschiedenen Stellen. Lineare PDFs sind für den Online-Bereich vorgesehen und werden auf die Festplatte in einer linearen Art und Weise gespeichert. Online-PDF-Viewer können somit die Datei schon anzeigen bevor sie komplett geladen wurde. [49]

1.5.4 Implementierung von Fonts

Schriften werden als Konturen (Outlines) digital gespeichert und mit Instruktionen (Hints) versehen, sodass sie generisch skaliert werden können. Fonts werden in PDF als eigenständige Dateien behandelt und die Darstellung wird durch einen speziellen Font-Interpreter bewerkstelligt. Innerhalb der Datei werden Fonts als Dictionary registriert, worin u.a. Fonttyp als Subtype, PostScript-Name, Verschlüsselung und Schriftklasse (für eine mögliche Ersatzschrift) abgelegt sind. Für jeden verwendeten Font wird ein Font-Descriptor in der Datei hinterlegt. PDF verarbeitet 2 Klassen von Fonttypen: Simple-Fonts und Composite-Fonts.

Jede Glyphe im Dokument wird über einen Character-Code prozessiert. Daraufhin erfolgt eine Zuordnung des Character Codes zum hinterlegten Encoding (Mapping). Zuletzt wird die Glyphe im aktuellen Font über die Glyphen-ID zum Zeichen der Glyphe aufgerufen. Folglich erzielt das Mapping des Codes und der Aufruf der Glyphe die benötigte Konturbeschreibung. Ein optionales Unicode-Mapping ToUnicode ist von Nöten, damit die Glyphen auch über Unicode verarbeitet werden kann. Ist dieses Mapping nicht vorhanden, so kann keine Textsuche und das Kopieren von Text stattfinden. Fehler im Mapping oder Modifikation von Schriften können zu falsche Ausgabebuchstaben, mangelnde Wiederverwendung und fehlerhafte Textkonvertierung führen.

Eine Font-Einbettung kann als zweite Option als Object-Stream gespeichert werden bzw. können Fonts sich auf eine externe Referenz beziehen. Die Beschreibung von Glypen ist bei eingebettete Schriften als Steam im Eintrag FontFile registriert. Falls die Schrift nicht eingebettet wurde fehlt dieser Eintrag. Schriftsubstitution findet immer dann statt, wenn der Character-Code nicht mit der Encoding-Tabelle übereinstimmt. Häufig fehlen bestimmte Glypen im Font. Falls eine Outline-Beschreibung des Fonts

zum Erstellungszeitpunkt nicht verfügbar ist, wird die Einbettung des Fonts verhindert. Dies kommt vor allem dann vor, wenn ein Font ein Schutzflag besitzt. Weitere Probleme bei der Schrifteinbettung sind u.a. Laufweitenfehler in Schriften, Fehler in der Buchstabenbeschreibung oder beim Cachen von Fonts. Zwecks der Schriftsubstitution müssen folgende allgemeine Informationen zu einem Font in der PDF-Datei gespeichert sein: Name der Schrift, Fontfamilie, Typ, Subtyp, Schriftstärke (Font Weight), Zeichenbreite, Laufweite, maximale Ausprägung der FontBox, Dickeninformationen, Positionsangaben über Versal- und x-Höhe und Winkel für Italic (kursiv). Diese Informationen sind selbst bei nicht eingebetteten Schriften vorhanden. [9]

1.6 PDF Sicherheitsaspekte

Etwa 40 % der Unternehmen setzen PDFs für geschützte Inhalte ein. In den letzten 2 Jahren ist die Nutzung der elektronischen Signaturfunktion in PDFs um mehr als 150 % gestiegen. [50] Diese Statistik zeigt keine gute Entwicklung, da PDF-Dokumente nicht für vertrauliche Inhalte verwendet werden sollten. Obwohl PDF Verschlüsselung verwendet erlaubt das Dateiformat eine Vielzahl an Angriffen, um die Sicherheit von PDF Dokumenten zu untergraben. Ich werde im Folgenden die implementierten Sicherheitsmechanismen von PDF und die möglichen Angriffe beleuchten.

In den Sicherheitseinstellungen eines PDF-Dokuments können Dokumentensicherheit und Zugriffsregeln justiert werden. PDF unterstützt Verschlüsselung und die Vergabe von Passwörtern. Eventuell kann beim Öffnen einer Datei ein Passwort gefordert werden oder das Kopieren von Teilinhalten, jeglichem Inhalt, Ausfüllen von Formularfeldern, Dokumentveränderungen (z.B. Struktur, Inhalt, Kommentare), das Einbetten und Editieren von Schriften oder das Ausdrucken kann vom Ersteller des Dokuments gesperrt worden sein. Das Schwärzen von Dokumenten, d.h. ein schwarzer Balken liegt auf dem Text, führt nicht dazu, dass der geschwärzte Text aus der Datei verschwindet. Er kann weiterhin ausgelesen werden, ebenso Metadaten. [14]

1.6.1 Digitale Signatur

Digitale Unterschriften sollen die Identität des Unterzeichners des Dokuments authentifizieren und dass der Inhalt nach der digitalen Unterschrift nicht geändert wurde. Der Verfasser benötigt für die digitale Signatur ein Signatur-Zertifikat. Das Zertifikat bescheinigt die Echtheit der Unterschrift und der Herkunft und wird von einem Zertifizierungsanbieter ausgestellt. Zusätzlich können Zertifikate ablaufen oder entzogen werden und müssen gültig sein. Dabei sollte ein vertrauenswürdiger Zertifizierungsanbieter gewählt werden. Jede Unterschrift kann mit einem Zeitstempel versehen werden.

Ein vertrauenswürdiger Zeitstempel-Anbieter (ZSA) belegt den Zeitpunkt, wann diese Unterschrift geleistet wurde. [11]

Eine digitale Signatur ist eine spezielle Art von elektronischer Signatur, die kryptographische Techniken implementiert. Im Gegensatz dazu kann eine elektronische Signatur verschiedene Formen annehmen, beispielsweise eine gescannte handschriftliche Unterschrift, ein getippter Name, eine biometrische Signatur oder eine digitale Signatur. Elektronische Signaturen sind der Oberbegriff und digitale Signaturen sind eine Teilmenge davon. Elektronische Signaturen bieten variierende Sicherheitsgrade. [14]

Digitale Signaturen verwenden asymmetrische Kryptographie. Anfangs wird ein Algorithmus zur Schlüsselgenerierung gestartet. Als Ausgabe werden ein Private Key und Public Key erzeugt. Ein Signierungsalgorithmus erstellt den einzigartigen Hash-Wert des PDF-Dokuments und verschlüsselt ihn mit dem geheimen Private Key, was die digitale Signatur produziert. Zuletzt überprüft ein Signaturvalidierungsalgorithmus die Authentizität des PDF-Dokuments, indem er erneut einen Hash des Dokuments berechnet. Die Signatur wird mit dem Public Key entschlüsselt und gibt einen Hash aus. Falls der berechnete Hash im Signaturvalidierungsalgorithmus mit dem entschlüsselten Hash übereinstimmt, ist die Authentizität des PDF-Dokuments gesichert. [51]

Eine PDF-Datei ermöglicht mehrere digitale Unterschriften, jedoch muss jede neue Unterschrift in einem inkrementellen Update geleistet werden. Jede Unterschrift muss mit einem Unterschriftsfeld im Dokument verbunden sein. Optional kann das Unterschriftsfeld mit einem Widget gekoppelt sein. Dann wird die Unterschrift graphisch dargestellt. Unterschriften ohne Widgets sind versteckte Unterschriften. [11] Es gibt Desktop-Anwendungen und online Validierungsservices zur Überprüfung der digitalen Signatur.

1.6.2 PDF Signature Spoofing

Die PDF-Spezifikation ist sehr ungenau formuliert im Bezug auf Signaturen und auf welche Art und Weise sie validiert werden müssen. PDF-Viewer haben eine hohe Toleranz beim Öffnen, Validieren und Anzeigen von beschädigten PDF-Dateien.

Im Jahr 2019 wurden 3 Attacken zum Vortäuschen von validen PDF Signaturen gefunden: Incremental Saving Attack (ISA), Signature Wrapping Attack (SWA) und Universal Signature Forgery (USF). Das Attack Scenario sieht wie folgt aus: Der Angreifer besitzt das signierte PDF mit einer gültigen Signatur und manipuliert es. Das manipulierte signierte PDF wird an das Opfer geschickt und die Signatur bleibt gültig, obwohl der Inhalt geändert wurde. [46]

Die ISA nutzt das Incremental Update-Feature von PDF aus, um böartigen Inhalt ins

PDF zu schleusen. Im Prozess des Signierens wird ein Incremental Update verwendet, um die Signatur zu speichern. Am Ende des Original-Trailers wird ein neuer Katalog und ein neues Signatur-Objekt als Body Updates angehängt, was den Signaturwert und Informationen über den Ersteller der Signatur enthält. Danach kommt eine updated Xref-Section und ein Updated Trailer. Beim Incremental Update können Objekte mit anderem Inhalt neu definiert werden. Der Updated Body wird hinter dem Originaltrailer angehängt, darunter zeigt die Updated Xref-Section auf das neue Objekt und der Updated Trailer wird ganz am Ende angefügt. Zuerst hat man geprüft, ob die PDF-Reader gegen eine Attacke anfällig waren, bei der hinter dem Incremental Update, was die Signatur enthält, eine weitere Sektion mit Body Updates, Xref Table und Trailer angefügt wurde. Ausschließlich LibreOffice wurde durch diese Vorgehensweise getäuscht. Alle weiteren Strategien produzieren kaputte PDF-Dateien, die keine Standardkonformität aufweisen, jedoch PDF-Viewer sind fehlertolerant. Als Nächstes haben die Forscher hinter dem Updated Trailer des Incremental Updates der Signatur Body Updates hinzugefügt, was eigentlich eine beschädigte PDF-Datei darstellt. Einige getestete PDF-Viewer haben lediglich überprüft, ob eine neue Xref-Sektion und Trailer vorhanden sind. Da sie nicht vorhanden waren, blieb die Signatur gültig und die zusätzlichen Body Updates wurden ausgeführt und die Modifikation blieb ohne Warnung unbemerkt. Andere PDF-Viewer benötigten neben zusätzlichen Body-Updates noch einen Trailer ohne Xref dazwischen, damit keine Warnung geworfen wurde. Die komplexeste Vorgehensweise, bei der neue Body Updates mit einer Kopie des Signatur-Objekts am Dateiende angebracht wurde, hat einige PDF-Viewer wie Foxit gezwungen die Signatur 2 Mal zu validieren und die Body Updates wurden eingefügt. [46]

Bei der SWA werden die Werte der signierten ByteRange modifiziert und Platz wird für das Einschleusen von böartigen Inhalt geschaffen. Das Signatur-Objekt besteht aus einem /Contents-Eintrag mit dem Signaturwert und einem /ByteRange-Eintrag mit 4 Werten, was den signierten Teil im Dokument anzeigt. Die ersten 2 Einträge der ByteRange beziehen sich auf den Beginn des Dokuments bis zum Anfang des Signaturwerts. Hingegen definieren die letzten beiden ByteRange-Einträge den Bereich nach dem Signaturwert bis zu %%EOF. Diese beiden Bereiche wurden nicht angerührt. Die erfolgreiche Idee war eine zweite ByteRange hinter dem Signaturwert mit einem angepassten dritten Wert, der Platz für böartige Objekte, etwas Padding und eine böartige Xref, die auf die böartigen Objekte zeigt, zu setzen. Lediglich die böartige Xref-Position ist im Trailer vorgegeben, der nicht verändert werden kann. [46]

Mittels USF wird die Signaturvalidierung außer Kraft gesetzt. Dennoch wird die Meldung „PDF is validly signed“ dem Benutzer angezeigt. Vor allem die Adobe-Produkte waren anfällig für diese Attacke. Die Vorgehensweise gestaltete sich wie folgt: Die Forscher versuchten /Contents oder /ByteRange der Signatur entweder wegzulassen oder unübliche Werte wie kein Wert oder null zuzuweisen. Zwei PDF-Viewer versagten,

wenn man `/Contents` auf 0 Bytes setzte. Das Weglassen der `/ByteRange` oder das Gleichsetzen mit null brach die Sicherheitsmechanismen von Adobe. [46]

Mittels dieser Attacken ist es den Forschern gelungen zu zeigen, dass 21 von 22 PDF-Viewer inklusive den Viewern von Adobe und 6 von 8 Online-Anbietern anfällig waren. Der einzige PDF-Viewer, der gegen alle Attacken immun war, war die veraltete Version von Adobe Reader 9, die jedoch Remote Code Execution enthält. [46]

1.6.3 PDFex PDF Encryption Attacks

PDFex bezeichnet Attacken auf die PDF-Verschlüsselung mit Passwortschutz, die im Jahr 2019 entdeckt wurden. Es gibt 2 Attack-Klassifizierungen: Direct Exfiltration und Cipher Block Chaining (CBC) Malleability Gadgets. Das Attacker Model gestaltet sich wie folgt: 2 Personen Alice und Bob wollen ein vertrauliches PDF mit Passwort austauschen. Wir nehmen an, dass ein Angreifer durch eine Man-in-the-middle (MITM) Attack das verschlüsselte PDF unbemerkt abgreifen konnte als Alice das Dokument zu Bob geschickt hat. Daraufhin modifiziert der Angreifer das Dokument, sodass die Veränderungen unerkennbar sind für Bob, und schickt seine Version des Dokuments an Bob. Bob entsperrt das Dokument mit seinem Passwort und das entschlüsselte PDF wird automatisch zurück zum Server des Angreifers übertragen. [46]

Ein verschlüsseltes PDF enthält einen Objekt-Stream als verschlüsselten Cipher Text im Body und einen `/Encrypt`-Eintrag, der Informationen darüber enthält, wie die Daten entschlüsselt werden sollen. Der Großteil der PDF-Dateistruktur liegt unverschlüsselt vor. Ausschließlich alle Strings und Streams für Inhalte ohne die anderen Objekttypen wie Integer oder Booleans, die dokumentstrukturbeschreibend sein sollen, werden verschlüsselt. Der Grund dafür ist, dass die PDF-Spezifikation weiterhin die random-access Optimierung im Dateiformat beibehalten möchte. Folglich ist die gesamte Dokumentenstruktur unverschlüsselt und eine ganze Reihe an wichtigen Informationen wie Anzahl und Größe der Seiten, verwendete Objekte oder Hyperlinks können vom Angreifer inspiziert werden.

PDF verwendet einen speziellen Streamfilter-Typ, genannt Crypt Filter für Verschlüsselung. Jeder Standard Filter eines Streams kann vom Crypt Filter überschrieben werden. Ein Standard Identity Filter wird bei besonderen Streams für z.B. Dokumentmetadaten gesetzt, damit diese unverschlüsselt bleiben in einem verschlüsselten Dokument. Diese Unterstützung von partieller Verschlüsselung kann einem Angreifer ermöglichen seinen Inhalt mit verschlüsseltem zu vermischen ohne das Passwort zu wissen. Forscher fanden 18 verschiedene Techniken für eine ganze Reihe von PDF-Readern. [46]

Bei der Direct Exfiltration Attack wird die Kryptografie nicht angerührt. Bei allen Strings im verschlüsselten PDF von Alice ändert der Angreifer die Crypt Filter

zum Identity Filter um. Jetzt kann der Angreifer bei Bedarf Strings verändern und kann weitere Objekte mit unverschlüsselten Strings hinzufügen. Außerdem kann er verschlüsselte Teile des Dokuments in Inhalte einfügen, die er kontrolliert, d.h. er kann auf verschlüsselte Streams oder Strings in seinem Inhalt referenzieren und zugreifen. Nachfolgend fügt er eine submit-form action hinzu, die Namen und Werte von AcroForms zu einer Ziel-URL überträgt. Der Text des Formularfeldes wird als Stream gespeichert. Kombiniert der Angreifer eine OpenAction, die ausgeführt wird, sobald das Dokument geöffnet wird, mit einer submit-form action zu attacker.com, so kann der vertrauliche entschlüsselte Inhalt an den Angreifer zurück als POST-Request gesendet werden. Die OpenAction wird ausgelöst, sobald Bob sein Passwort eingegeben hat. Statt einer submit-form action kann man auch einen Hyperlink verwenden. Jedes Objekt kann als Hyperlink definiert werden, was einen Get-Request to attacker.com triggert. JavaScript kann ebenfalls verwendet werden. [46], [52]

PDF verschlüsselt durch AES-256 mit einer Schlüssel-Länge von 256 Bit und operiert im CBC Mode ohne Message Authentication Code (MAC) Integritätsschutz. AES gehört zu den Blockchiffren und ist ein symmetrisches Verschlüsselungsverfahren. Bei symmetrischer Verschlüsselung gibt es nur einen Schlüssel fürs Verschlüsseln und Entschlüsseln. Ein Block ist 128 Bit lang. Der Subkey (Rundenschlüssel) hat immer eine Länge von 128 Bit. Die Schlüssellänge beeinflusst den key schedule, d.h. die Art und Weise wie Rundenschlüssel vom Master Key abgeleitet werden, sowie die Anzahl an Runden. Während der Algorithmus ausgeführt wird, wird ein 4 x 4 Array aus je 1 Byte (insgesamt 128 Bit), genannt State, in 14 Runden verschlüsselt. Im ersten einzigen Schritt, der KeyExpansion, werden die Rundenschlüssel für jede Runde plus 1 weiterer Rundenschlüssel aus dem Master Key berechnet. Anfangs wird der State gleichgesetzt mit dem der zu unverschlüsselten Nachricht (Plaintext). Auf dem State Array wird bitweises XOR mit dem Rundenschlüssel angewendet im AddRoundKey-Schritt. Jedes Byte vom State wird dabei mit einem Byte vom Rundenschlüssel kombiniert. Im SubBytes (Substitution) Schritt wird jedes Byte des aktualisierten State Arrays mit einem Byte durch eine Substitutionstabelle (S-Box) ersetzt. Dadurch werden die Bytes im State vermischt. Danach kommt die ShiftRows Sequenz. Die Bytes in jeder Zeile von State werden unterschiedlich nach links verschoben: Die 1. Zeile bleibt unberührt, die 2. Zeile wird um 1 verschoben, die 3. um 2 und die letzte um 3 Positionen. Die überlaufenden Zellen werden rechts an die jeweilige Zeile wieder angehängt. Als Vorletztes jeder Runde außer der letzten Runde kommt MixColumn dran. Hier werden Spalten vermischt, indem jede Spalte mit einer konstanten Matrix zu einer neuen Spalte multipliziert wird. Abschließend zu jeder Runde wird nochmals AddRoundKey mit dem aktuellen Rundenschlüssel ausgeführt, also State bitweise XOR verknüpft mit dem Rundenschlüssel. Im letzten Schritt produziert AddRoundKey den Ciphertext. Die invertierte Operation des Algorithmus wird beim entschlüsseln angewendet und alle Funktionen werden umgekehrt aufgerufen. [53]–[55]

Während des CBC Mode wird ein vorheriger Ciphertextblock mit dem nächsten Plaintextblock durch XOR verknüpft. Das Ergebnis und der Schlüssel dienen als Input für den AES-Algorithmus und produzieren einen verschlüsselten Output als Ciphertextblock. Im ersten Schritt wird der erste Plaintextblock mit einem Initialisierungsvektor IV (nonce) als Zufallszahl oder Zeitstempel mit XOR verknüpft. IV sollte nur einmal verwendet werden und muss Sender und Empfänger bekannt sein. [56]

Ein MAC ist eine kryptographische Prüfsumme, die aus dem Datensatz und dem symmetrischen Schlüssel von Sender und Empfänger gebildet wird. Im Gegensatz zu einem Hash kann der MAC nur von Sender und Empfänger berechnet und von beiden verifiziert werden. [56]

Nicht alle PDF-Viewer unterstützen teilweise verschlüsselte Dokumente. Sie sind immun gegen Direct Exfiltration Attacks. Trotzdem können Angreifer CBC Malleability Gadgets verwenden, um die Exfiltrations des Texts zu erhalten, da keine MAC für den Ciphertext beim PDF-Standard verwendet wird. Für die Ausführung der Attacke müssen 2 Vorbedingungen erfüllt sein. Zum einen muss ein Plaintext-Segment dem Angreifer vorliegen. Beim aktuellsten AESV3-Algorithmus wird der Plaintext als 12 Bytes im Perms Entry (extended permissions) einer PDF-Datei mit dem gleichen AES-Schlüssel für Streams und Strings verschlüsselt. Obwohl der Perms-Wert mit Electronic Code Book (ECB) Mode verschlüsselt wird, ist der Output-Ciphertext gleich seinem Plaintext, wenn man ihn mit CBC verschlüsseln und dabei einen Initialization Vector von 0 verwendet würde. Bei älteren Versionen des AES-Algorithmus in PDF muss der bekannte Plaintext aus dem Objekt, auf das die Exfiltration angewendet werden soll, kommen.

Alice verschlüsselt eine Nachricht aus 2 Blöcken p_0 und p_1 zu c_0 und c_1 und Bob kann diese Nachricht wieder zu p_0 und p_1 entschlüsseln. CBC Gadgets kann man konstruieren mit einem bekannten Plaintext-Teil IV, den man besitzt und kann dadurch neue Plaintextblöcke g_0 und g_1 in eine entschlüsselte Plaintext-Nachricht einfügen. Der Angreifer erhält die Nachricht aus c_0 und c_1 von Alice und konstruiert 2 neue verschlüsselte Ciphertext Blöcke x_0 und x_1 . x_0 wird durch $IV \oplus p_0 \oplus g_0$ und x_1 durch $IV \oplus p_0 \oplus g_1$ gebildet. Eine neue verschlüsselte Nachricht wird durch die Concatenation von x_0 , c_0 , x_1 , c_0 und c_1 gebildet. Der ursprüngliche c_0 Block wird durch einen vom Angreifer erstellten neuen c_0 Block ersetzt. x_0 ist aus IV erstellt worden und x_1 ist lediglich dazu da, die Verkettung beizubehalten. x_1 wird zu unkontrollierbaren Bytes ohne Sinn entschlüsselt. c_1 ist der verschlüsselte Block von Alice, der die Zieldaten, enthält. Bei der Entschlüsselung erhält Bob den vom Angreifer erstellten Plaintext-Block g_0 , die unkontrollierten Bytes, den zweiten Plaintext-Block vom Angreifer g_1 und die entschlüsselten Zieldaten von Alice. Folglich konnte der Angreifer Alices p_0 durch g_0 und g_1 ersetzen.

Als Exfiltration Channel muss man AcroForms oder Hyperlinks verwenden.

2 PDF Programme auf dem Markt

Die Popularität von Portable Document Format (PDF) Dateien ist seit 2008 rasant angestiegen in der globalen Informationsübertragung. Täglich werden weltweit 2,5 Milliarden PDF Dokumente erzeugt. Seine Beliebtheit verdankt PDF vor allem an der plattformübergreifenden Kompatibilität (Desktop-Computer, Tablets und Smartphones), denn PDF Dokumente ist auf mehr als 1,5 Milliarden Geräten ohne zusätzliche Software lesbar. Über 80% der geschäftlichen Dokumente werden als PDF Datei weitergegeben. [50] 90 % der Büroangestellten wollen auf das PDF Dateiformat nicht mehr verzichten. Drei Viertel aller archivierten Dokumente sind PDF Dokumente. [57] Bis 2025 werden über 3 Milliarden Dollar jährlich für PDF Editoren ausgegeben werden. [57] Im Jahr 2015 gab es 1,6 Milliarde PDF-Dokumente im Web und im Jahr 2019 wurden PDF-Dateien bei ca. 99 % Firmen und Regierungsinstitutionen weltweit verwendet. [46]

2.1 Die Firma Adobe Systems Incorporated

1982 wurde die Firma Adobe Systems Incorporated von John Warnock und Chick Geschke gegründet. Adobe Illustrator war das erste auf PostScript basierende Grafikprogramm, welches 1988 auf den Markt gebracht wurde. [9]

2.2 Aktueller Stand von Forschung und Technik

2.3 Freie PDF Programme und Onlinedienste

PDF Dateien lassen sich in vielen Programmen einfach über den Druckdialog erstellen. Apple hat das Lesen von PDF Dokumenten in seiner Apples Vorschau integriert. Viele Webbrowser stellen PDF Viewer bereit, so Google Chrome seit 2010. [2]

2.3.1 PDFCreator

PDF Dokumente und Dateien erzeugen

2.3.2 LibreOffice

PDF Dokumente und Dateien erzeugen

2.3.3 OpenOffice

PDF Dokumente und Dateien erzeugen

2.3.4 ghostscript

2.4 Kostenpflichtige PDF Programme und Onlinedienste

2.4.1 Adobe Acrobat

Die nicht-Pro Version von Acrobat kann prüfen, ob es sich bei dem geöffneten PDF-Dokument um ein PDF/A-Dokument handelt und auf dessen Konformität prüfen. Zusätzlich kann man sich die Kompatibilität mit anderen PDF-Dateiformaten PDF/X, PDF/E, PDF/VT und PDF/UA anzeigen lassen. [30] Acrobat kann über JavaScript ferngesteuert werden. Dazu muss man die Berechtigung zur Ausführung von JavaScript erteilen. [9]

2.4.2 Adobe Acrobat Pro

PDF-Inhalte können bearbeitet und Dokumente mit digitalen Signaturen unterzeichnet werden. [35] Eine PDF-Datei kann in eine PDF/A-Datei inklusive seiner Varianten, PDF/X, PDF/UA, PDF/VT oder PDF/E konvertiert werden. Außerdem kann die Kompatibilität mit diesen Formaten überprüft werden in Preflight-Profilen. [30] Die Barrierefreiheit kann automatisch validiert werden oder ein neues Dokument kann direkt barrierefrei erstellt werden. Adobe Acrobat Pro kann andere Dokumentenformate wie HTML, DOC, DOCX, TXT und RTF in PDF konvertieren, PDF in andere Dateiformate wie Microsoft Word exportieren oder Dokumente unterschreiben. [58] Mit dem Werkzeug Scan & OCR kann man Pixelbilder als PDF und gescannte PDF-Dokumente in ein durchsuchbares PDF umwandeln. [35] Installiert man Acrobat Pro in Windows, steht dem Anwender ein Adobe PDF-Drucker mit entsprechender PPD-Datei zur Verfügung. [9]

2.4.3 Onlinetools von Acrobat

Produktseite:

<https://www.adobe.com/de/acrobat/online.html>

<https://www.adobe.com/de/acrobat/online/convert-pdf.html> Mit den Adobe Acrobat Onlinetools kann man über den Browser verschiedene Dateitypen in PDF umwandeln, unter anderem PDF in JPEG oder andere Bildformate, PDF Dateien bearbeiten und Kompression anwenden. Die Onlinetools können außerdem PDF in Word umwandeln. [35] Der Adobe Acrobat PDF-Converter der Onlinetools kann DOCX, DOC, XLSX, XLS, PPTX, PPT, TXT, RTF, JPEG, PNG, TIFF, BMP, sowie Adobe eigene AI-, INDD- und PSD-Dateien in PDF konvertieren. [58] Die kostenlose Version des PDF-Converters kann nur begrenzt oft genutzt werden.

2.4.4 Acrobat Distiller

In Acrobat Distiller als Software-Interpreter können PostScript-Dateien in PDF konvertiert werden und umgekehrt. Bei der Erstellung einer PDF-Datei schneidet Distiller an der MediaBox-Grenze herausragende Elemente ab. [9]

2.4.5 Microsoft Word

Aus einem Word-Dokument lässt sich in Microsofts Word eine PDF-Datei, inklusive im PDF/A-Dateiformat, erstellen. [30]

2.5 PDF zu Word Konvertierung

In PDF ist keine automatische Anpassung des Seiteninhalt-Layouts, wie z.B. in Microsoft Word, möglich. Daher kann ein PDF-Dokument nicht sinnvoll in das Word-Format umgewandelt werden ohne möglicherweise das ursprüngliche PDF-Layout zu beeinflussen und zu ändern, sowie die maximalen Bearbeitungsmöglichkeiten von Word ausschöpfen zu können.

2.6 PDF zu Latex Konvertierung

2.7 Relevanz von PDF in verschiedenen Marktbranchen

Durchsuchbare PDFs werden in Verträgen, Rechnungen und Geschäftsunterlagen verwendet, damit Mitarbeiter*innen Informationen gezielter suchen und Daten abteilungsübergreifend effizienter verwaltet werden können. In Forschungsarbeiten und wissenschaftlichen Artikeln werden durchsuchbare PDFs bei der Überprüfung von Quellen oder dem Extrahieren von Zitaten hauptsächlich verwendet. Behörden, Bibliotheken und Unternehmen digitalisieren Dokumente zur Archivierung und wandeln sie in ein durchsuchbares PDF um, was den langzeitigen Bestand der Dokumente sichert. [35]

Das PDF/A-Dateiformat wird in Bibliotheken und Archiven zur digitalen Archivierung von Büchern, Zeitschriften und historischen Dokumenten verwendet. Auch im Behördenzweig und Verwaltungssektor hat PDF/A für die Aufbewahrung von Verwaltungsakten und rechtlichen Dokumenten seine Existenzberechtigung. Im Gesundheitswesen wird es außerdem zur Speicherung von Patientenakten und medizinischen Unterlagen verwendet. Hingegen im Finanzwesen werden mit ihm Geschäftsunterlagen und Finanzdokumente verwahrt. Unternehmen und Organisationen können mit PDF/A gesetzliche und Compliance-Vorschriften einhalten. [30]

PDF/VT-Dateien werden im Direktmarketing verwendet. Personalisierte Werbematerialien erhöhen die Wahrscheinlichkeit einer positiven Reaktion bei den Kund*innen auf die Werbebotschaft und verbessert die Bindung von Unternehmen und Kund*innen. Der Transaktionsdruck findet bei Finanzdienstleistungen, Versicherungen und E-Commerce besonderen Anklang. Beliebte Transaktionsdokumente sind Rechnungen, Kontoauszüge, Versicherungspolice oder Bestellbestätigungen. [32]

PDF-Dokumente mit der PDF/UA-Kennzeichnung stärken den Ruf und die Reputation eines Unternehmens oder einer Organisation durch Engagement für Inklusion. [34]

Digitale Signaturen werden bei digitalen Freigabe-, Abnahme-, Genehmigungs- und Vertragsprozesse verwendet. PAdES wird in Rechtssystemen, Finanzwesen und Regierungssektor eingesetzt. [14]

2.8 Rolle von PDF in der Druckvorstufe und Designbranche

Vor allem in der grafischen Industrie wird PDF gerne verwendet, weil es eine plattformübergreifende Visualisierung bietet auf allen Betriebssystemen. Schriften können bei

Einbettung exakt wiedergegeben werden, unabhängig ob es sich um eine Windows oder MacOS Schrift handelt. Im Vergleich zu PostScript-Dateien erzielen die kompaktere Codierung von Seiteninhalten, dem einmaligen Speichern von identischen Bildern und die Verwendung von Kompressionsalgorithmen eine maßgeblich kleinere Dateigröße bei PDF. Korrekturänderungen in PDF-Dateien sind kurz vor dem Druck noch möglich und PDF entwickelte sich zunehmend zum Containerformat für alle grafischen Elemente. Die Produktion von Druckerzeugnissen wird somit wesentlich flexibler und sicherer. Downsampling und Kompression beschleunigt den Transport von der Agentur zum Dienstleistungsbüro enorm. In der Ausgabe ist die effektive Auflösung maßgeblich. Effektive Auflösung ist die Bildauflösung, die aus der Anzahl der Bildpunkte und der Fläche resultieren, auf der das Bild platziert wurde. Downsampling beeinflusst diese effektive Auflösung. Starke Artefakte fallen im Offsetdruck weniger auf als im Digitaldruck.

[9] Für die Betrachtung von Druckvorstufen-PDF-Dateien sollte immer Acrobat Pro bzw. Adobe Reader verwendet werden, da viele Drittanbieter-PDF-Viewer druckvorstufenrelevante Informationen nicht fehlerlos darstellen können. [9]

In der Werbebranche werden PDF-Dateien vor allem für Korrekturabzüge verwendet. Ein Korrekturabzug ist eine Skizze bzw. Designvorlage des Werbeprodukts in vom Kunden gewünschten Position und Größe des Druckmotivs auf dem Werbeartikel. Als digitales Layout wird der Korrekturabzug mit dem Kunden abgestimmt und seine Änderungswünsche vor dem Druck entgegengenommen. [59]

Dank der Profile für unterschiedliche Geräte und Bedruckstoffe, kann eine Simulation des Ergebnisses am Monitor oder durch einen Prüfdruck bewerkstelligt werden. Dadurch steigt die Reproduktionssicherheit bei gleichbleibender Qualität und die Produktionszeiten verkürzen sich enorm. In den meisten Druckprojekten steht zu Beginn noch nicht fest, wann, wo und auf welchem Bedruckstoff gedruckt werden soll. Die zeitintensive Optimierung der Druckdaten kann durch PDF auf einen späteren Zeitpunkt verlegt werden.

Jeglicher Schutz oder Sperren sollte an einer druckvorstufentauglichen PDF-Datei vermieden werden, selbst wenn lediglich das Editieren gesperrt ist. Aktionen sind innerhalb druckfähiger Dateien untersagt, unabhängig von JavaScript oder Aktionen von Acrobat. [9]

Da allgemeine Schriftinformationen immer eingebettet sind und die Zeilenlängen im Prinzip immer stimmen, können Druckvorstufenbetriebe zumindest immer erkennen, welche Schrift bzw. Schriftschnitt der Ersteller der PDF-Datei ursprünglich vorgesehen hatte, falls die Schrift nicht eingebettet wurde. [9]

In der Praxis werden PDF-Dateien mit Hilfe von Prüfprofilen überprüft, Agenturen entwickeln nach eigenen Kriterien vorgefertigte Prüfroutrinen und einen automatisch

generierten Prüfbericht (Report). Der Prüfbericht sollte auf schnelle Fehlersuche im überprüften Dokument optimiert sein. Notwendige Korrekturen können im Originaldokument, bei PDF-Erstellung oder im vorliegenden PDF-Dokument ausgeübt werden je nach Schweregrad des Fehlers. Korrekturen im Originaldokument sind vorzuziehen, da sie Folgefehler minimieren können, jedoch liegt der Agentur oftmals nicht das Originaldokument oder ausschließlich eine unvollständige PDF-Datei des Originaldokuments vor. Eine Erstellung von Korrekturprofilen für Änderungen an der gesamten PDF-Datei kann dabei hilfreich sein. Man kann zwischen einer Vielzahl an voreingestellten Prüfprofilen und einer wesentlich kleineren Menge an Korrekturprofilen im Preflight in Adobe Acrobat Pro wählen. Außerdem kann der Prüfbericht als Kommunikationsmittel zwischen Auftraggeber und Agentur dienen, falls der Agentur das Originaldokument nicht ausgehändigt wurde. Das Preflight-Werkzeug in Acrobat Pro ist ein gängiges Werkzeug in der Druckvorstufe. Die Kontrolle von PDF-Dateien mit Preflight kann viel Geld sparen. Im tiefgreifenden Preflight Check, der ein System vor dessen Einsatz überprüft, kann man die besten Ergebnisse erzielen, wenn das zum Job passende Prüfprofil verwendet wird. Beim Preflighting-Prozess werden fehlerhafte und Objekte mit speziellen Anforderungen gefunden, ihr Zustand abgefragt und dann dementsprechende ein Fehler, eine Warnung oder eine Information ausgegeben. Im Warnungsfall muss die Agentur entscheiden, ob das Objekt, was die Warnung verursacht hat, sich negativ auf das Endprodukt auswirkt. Folglich können durch Preflight frühzeitig Mängel im Produktionszyklus beseitigt werden. Ein Report sollte für die automatisierte Auswertung in weiterführenden Workflow-Systemen im XML-Standard vorliegen. Erfolgreiche selbst erstellte Prüfprofile basieren auf qualitativ hochwertig gewählte Kriterien, wobei nicht zu viele verwendet werden sollten. Prüfprofile können als wichtigste Prüfkriterien das Dokument, Seiten, Bilder, Farbe, Zeichensätze, Rendering und Standard-Konformität enthalten. Nach der Einbringung von Korrekturen im PDF sollte eine technische und visuelle Überprüfung der Druckdatei stattfinden. In einem korrigierten Kunden-PDF sind die für die Druckerei wichtigen Druck-, Schneide- und Passermarken sowie der Bereich des Anschnitts meistens unerwünscht. Um diesen Bereich und alle Druckmarken unsichtbar zu machen wird die CropBox auf die Größe der TrimBox skaliert. PDF-Dateien, die nicht aus professionellen Anwendungen der Druckvorstufe erstellt worden sind, fehlen in den meisten Fällen die TrimBox bzw. BleedBox. Hat der Datenersteller Schnittmarken sehr genau manuell platziert, so können fast alle PDF-Bearbeitungswerkzeuge davon die TrimBox bzw. BleedBox ableiten. Umschläge und Rücken werden häufig als Druckbogen als einseitiges PDF ausgegeben. Falls der Umschlag versehentlich als PDF-Datei aus Einzelseiten erstellt wurde, müssen diese Seiten zu einem Druckbogen zusammengeführt werden. Für die Weiterverarbeitung sollten leere Seiten und nicht druckbare Objekte, die als solche gekennzeichnet sind oder sich außerhalb des druckbaren Bereichs befinden, entfernt werden. Große Dateien sind bei der Verarbeitung sehr zeitaufwendig und weniger ressourcenschonend. PDF-Dateien können sich durch Output-Intents, eingebettete Dateien, unzureichende

Komprimierung von Bildern und Objekten, zu hohe Auflösung und die Präsenz nicht druckbarer Objekte in ihrer Dateigröße aufblähen. Häufig wird in der Agentur ein Abzug-PDF zur Druckfreigabe an den Auftraggeber versandt. Die Seiteninhalte eines Abzug-PDFs sollten gerastert werden, da fehlerhafte Grundeinstellungen im Adobe Reader zu einer abweichenden Darstellung des PDFs im Vergleich zum Aussehen nach dem Druck führen kann. Abzug-PDFs sollten eine Qualität besitzen, die ausreichend ist für eine Ansicht, jedoch für die Produktion bei einem anderen Druckdienstleister nicht genügt und der Output-Intent sollte zwecks Dateigrößenoptimierung entfernt werden. Falls viele Vektoren in einem Druckdokument enthalten sind, würde trotz PDF-Optimierung weiterhin eine hohe Auflösung in Vektorgrafiken bestehen bleiben und folglich nur eine geringe Dateigrößenreduktion erzielt werden. Das Rastern des Inhalts bietet einen praxisnahen Lösungsweg. Hierbei werden überdruckende Objekte in das Bild eingerechnet und Vektoren gerendert, wodurch eine maßgebliche Dateigrößenoptimierung erzielt werden kann. Speziell bei PDF/X-Dateien müssen bestimmte Inhalte als Metadaten vorliegen, wie der Dokumententitel, das Änderungsdatum der Datei, das PDF-Erstellerprogramm und das Setzen des Trapping Keys. [9]

Textmodifikationen sind am meisten gefordert in der Druckvorstufe. Farbänderungen bzw. Farbkonvertierungen sind ebenso erforderliche Eingriffe. Änderungen am Layout oder Neugestaltungen von Seiten müssen im Originalprogramm erledigt werden und das modifizierte PDF muss in das Druck-PDF integriert werden. Ständige visuelle Kontrollen der PDF-Datei des Kunden mit der korrigierten Version werden durch eine Fachkraft im Betrieb durchgeführt. Am Ende jeder Korrektur steht die Prüfung auf PDF/X-Konformität, um als technisches Gütesiegel weitere Fehler für den Druck zu reduzieren. [9]

Fehlende Schriften in PDF-Dateien sind in der Druckvorstufe katastrophal. Beim nachträglichen Einbetten von Schriften in letzter Minute muss die richtige Schrift gesucht werden und der richtige Schriftname beschreibt nicht notwendigerweise dieselbe Schrift mit derselben Codierung bzw. Laufweite. Fehlende Zeichen, überlappende Buchstaben, unregelmäßige Abstände zwischen den Buchstaben, usw. sind gängige Probleme. Schriften können auch durch die PDF-Bearbeitung extrahiert (ausgebettet) werden. In der Druckvorstufe müssen Schriftenbezeichnungen für die Ausgabe eindeutig gemacht werden. Bilder sollten nach der PDF-Bearbeitung anschließend geschärft werden. Das wird vom Datenersteller oftmals vergessen. Falls im Druck-PDF ein falscher Zielfarbraum eingestellt wurde, wirkt sich das auf den Gesamtfarbauftrag aus. Eine Farbraumkonvertierung in den für das Druckergebnis gewünschten Farbraum muss vorgenommen und der maximale Gesamtfarbauftrag muss angepasst werden. [9]

Vor allem Office-Dokumente müssen für den Druck aufbereitet werden. Marketingabteilungen von Industrieunternehmen sind gezwungen auf die zur Verfügung stehenden

Werkzeuge, den Microsoft-Office-Programmen bzw. OpenOffice-Programmen zurückzugreifen bei der Druck-PDF-Erzeugung. Meistens liegen dann alle Objekte in RGB vor, es fehlt die TrimBox und der Anschnitt, sowie keine Einzelseiten-PDFs liegen zum Ausschießen vor. [9] Ausschießen bezeichnet den Prozess, dass die einzelnen Seiten des Druckerzeugnisses in der Seitenmontage seitenverkehrt so angeordnet werden, dass sie nach dem Druck und der Weiterverarbeitung (Falzen) die korrekte Reihenfolge vorweisen. [17] Alle RGB-Farbräume müssen nach CMYK umgewandelt werden. Im Besonderen müssen beim Offsetdruck schwarze Texte auf den Farbaufzug K in CMYK gebracht werden. Schmuckfarben werden in CMYK oder eine andere Schmuckfarbe konvertiert bzw. gemappt. Die hinterlegten Alternativ-Farbwerte für Schmuckfarben weichen in der Vielfalt der Programme von einander ab. Ursächlich ist, dass unterschiedliche Pantone Libraries implementiert wurden. Häufig sind in PDF-Dateien unterschiedliche Farbwerte für dieselbe Farbe anzutreffen. Das entfernen von Druckmarken ist für den Datenersteller und die Druckvorstufe, die mehrere Seiten auf einem Druckbogen ausschießen muss, ein gängigere Arbeitsschritt. Die letzte Arbeitsphase im PDF-Workflow ist das Überfüllen bzw. Unterfüllen, um weiße Blitzer zu vermeiden. Spezialisten in der Druckvorstufe sollten das Hinzufügen von Traps übernehmen bzw. über dessen Notwendigkeit entscheiden. Der Druckvorstufenbetrieb gibt dem Auftraggeber den ISO-Standard der PDF-Datei für das Druckerzeugnis vor. Nur wenn sich die Ausgangsdatei mit der zum Druck verwendeten Enddatei in allen Einzelheiten deckt, kann man sich Reklamationen, Geld, Zeit und Diskussionen sparen. Sind die Druckdaten erstellt, müssen die enthaltenen Druckseiten noch in der Druckvorstufe für die Ausgabe auf die Druckplatte bzw. für die Bebilderung von Digitaldrucksystemen in eine korrekte Anordnung gebracht werden. Dieser Prozess, genannt Ausschießen, wird üblicherweise von der Druckvorstufe digital ausgeführt. In Produktionsumgebungen, wo auf Digitaldrucksystemen direkt ausgegeben wird, muss das Ausschießen auch vom Datenersteller selbst vor Ort vorgenommen werden. Ziel des Ausschusses ist eine schnellere und kostengünstigere Produktion durch die bestmögliche Ausnutzung des Papiers bzw. Materials und nachfolgenden Schritte (Zusammentragen, Binden und Schneiden) der Endverarbeitung zu ermöglichen und vereinfachen. In der Praxis wird am häufigsten der Ausschuss durch eine Softwarelösung nach dem Designprozess praktiziert. Vor allem in der Magazin- und Zeitungsproduktion, wo Personen zu gleicher Zeit auf unterschiedlichen Seiten arbeiten und diese zu schwankenden Zeitpunkten fertigstellen, wird nach dem Designprozess ausgeschossen. Es gibt jedoch auch die Möglichkeiten im Erstellungsprogramm, beim Drucken auf dem Drucker oder im RIP auszuschießen. [9]

Zum Erstellen von PDF-Dateien mit geringer Dateigröße für den Online-Bereich muss der Output-Intent mit dem angehängten ICC-Profil entfernt werden, da ICC-Profile eine eher größere Dateigröße aufweisen. Für eine korrekte farbliche Simulation am Monitor in der Druckvorstufe ist es in einigen Fällen wünschenswert, dass ein

Output-Intent gesetzt wird. Bei der Erzeugung einer ISO-konformen PDF-Datei, z.B. bei PDF/X, PDF/A oder PDF/E wird immer ein Output-Intent angelegt. Je nach Standard wird auch das Zielfarprofil eingebettet. Die direkte Ausgabe von PDF-Dateien über den Druckdialog in Acrobat Pro ist in der Praxis nicht mehr gängig, da alle gängigen Workflow-Systeme auf einem PostScript-3-RIP basieren. Intern konvertiert der PostScript-RIP die PDF-Datei in eine PostScript-Datei automatisch. Die Ausgabe von PostScript aus Acrobat Pro heraus spielt noch für Laserdrucker, Farbkopierer und Broschüren auf Farbdruckern eine Rolle. [9]

Bilder, die nicht im Zielfarbraum vorliegen müssen erst in den Ausgabefarbraum überführt, separiert ausgegeben und Transparenzen reduziert werden. Jegliche Transparenzen in Objekten, vor allem Texte, Grafiken oder Bilder, werden beim speichern in ein Dateiformat, welches keine Live-Transparenzen unterstützt, reduziert. Zu diesen Dateiformaten gehören u.a. Encapsulated PostScript (EPS), JPEG, GIF, BMP, PDF 1.3 und niedriger. Nach der Transparenzreduzierung sollten für die Ausgabe Quellfarbprofile von den reduzierten Objekten entfernt werden, da sie oftmals zu unerwünschten Farbtransformationen im Ausgabegerät führen können. Das Anbringen von Transparenzen auf Objekte mit Volltonfarben ist mit Ausnahme der Deckkraftänderung verboten. Bilder können unscharf werden, wenn in den meisten Fällen eine zu niedrige Reduzierungsauflösung global eingestellt ist. Der Prozess der Transparenzreduzierung sollte auf den letztmöglichen Zeitpunkt in der Produktion von digitalen Daten verschoben werden. [9]

Da der wirtschaftliche Druck auf die produzierenden Unternehmen immer mehr zunimmt, müssen einzelne Produktionsschritte immer mehr zeitlich gestaucht werden und im Idealfall automatisch ablaufen. Für einen automatisierten PDF-Workflow muss dem Trapping-Key ein eindeutiger Wert zugewiesen werden. Elemente, die nicht für den Druck vorgesehen werden, müssen aus dem druckbaren Bereich entfernt werden.

Von einer medienneutralen Druckproduktion spricht man, wenn die Farbraumkonvertierung der neutral abgespeicherten Daten ausschließlich in RGB oder in RGB und CMYK zu einem möglichst späten Zeitpunkt stattfindet. Bei Logos werden medienneutrale PDF-Dokumente nicht bevorzugt. Durch das medienneutrale Konzept gewinnt man an Flexibilität und reduziert Mehrarbeit im Produktionsprozess, z.B. wenn ein späterer Wechsel des Druckverfahrens und der Papierklasse erfolgt. Der Gegensatz zur medienneutralen Arbeitsweise ist die verfahrensangepasste Arbeitsweise. In der Praxis ist primär der PDF-Empfänger für die Rastereinstellungen des RIPs verantwortlich. Die Anzahl der Sonderfarben ist in keinem PDF/X-Standard beschränkt. In der Verpackungsindustrie werden Mehrkanalproduktionen verwendet. [9]

Der Begriff Binding bezeichnet im Prozess der Druckdatenerstellung die Farbkonvertierung in die gewünschten Druckbedingungen. Beim Early Binding liegen alle verfahrensangepasste Daten schon im gewünschten Zielfarbraum vor. Hingegen bei

medienneutralen Daten kann bei der PDF-Erzeugung eine Konvertierung in den Zielfarbraum erfolgen. Dies wird als Intermediate Binding bezeichnet. Im Prozess des Late Bindings wird die Konvertierung in den Zielfarbraum bei medienneutralen Daten erst in der Ausgabe vorgenommen. [9]

Statische PDF-Dateien sind nicht responsive, d.h. eine optimale Anpassung an verschiedene Endgeräte ist nicht garantiert und sie haben eine lange Ladezeit. Daher erstellt man einen PDF-Online-Blätterkatalog oder ePaper. Es handelt sich um eine Konvertierung von PDF in HTML5 mit entsprechenden Tools. Den PDF-Blätterkatalog kann man in seine Homepage einbinden oder einfach über Social-Media-Kanäle oder per Newsletter teilen. [60]

3 Open Source PDF Web App

3.1 Problemstellung und Anforderungen

3.2 Konzept und Methodik

3.3 Funktionalität der PDF Web App

3.4 Bedienung der PDF Web App

3.5 Implementierung der PDF Web App

3.6 Testdurchführung der PDF Web App

3.6.1 Funktionale User Tests

3.6.2 Stress Tests

4 Diskussion und Kritik

Fazit und Ausblick

Literatur

- [1] Wikipedia. „PostScript.“ (2023), Adresse: <https://de.wikipedia.org/wiki/PostScript> (besucht am 19.12.2023).
- [2] Wikipedia. „Portable Document Format.“ (2023), Adresse: https://de.wikipedia.org/wiki/Portable_Document_Format (besucht am 19.12.2023).
- [3] Wikipedia. „PDF.“ (2023), Adresse: <https://en.wikipedia.org/wiki/PDF> (besucht am 23.12.2023).
- [4] Wikipedia. „Offener Standard.“ (2023), Adresse: https://de.wikipedia.org/wiki/Offener_Standard (besucht am 20.12.2023).
- [5] Wikipedia. „Royalty-free.“ (2023), Adresse: <https://en.wikipedia.org/wiki/Royalty-free> (besucht am 23.12.2023).
- [6] Tobias Lang. „Was ist ein Farbraum?“ (2016), Adresse: <https://themen.rainbowprint.de/farbraum/> (besucht am 30.12.2023).
- [7] Adobe Inc. „Pfade und Formen, Grundlagen.“ (2023), Adresse: <https://helpx.adobe.com/de/indesign/using/paths-shapes.html> (besucht am 30.12.2023).
- [8] Typografie.info. „PostScript Type 0, Bedeutung/Definition.“ (o. D.), Adresse: <https://www.typografie.info/3/wiki.html/p/postscript-type-0-r43/> (besucht am 20.12.2023).
- [9] H. P. Schneeberger, *PDF in der Druckvorstufe das umfassende Handbuch, PDF-Dateien erstellen, prüfen, korrigieren und ausgeben; PDF/X-1a bis PDF/X-5 sicher im Griff; Preflighting, Automatisierung, Standards u.v.m.* (Galileo Design), de. Bonn: Galileo Press, 2014, 910 S., Für Beruf und Ausbildung, ISBN: 978-3-642-38552-0.
- [10] D. S. Peter Bühler Patrick Schlaich, *PDF, Grundlagen - Print-PDF - Interaktives PDF*, de. Berlin: Springer-Verlag GmbH Deutschland, 2018, 97 S., ISBN: 978-3-662-54615-4. DOI: 0.1007/978-3-662-54615-4.
- [11] Soft Xpansion GmbH & Co. KG. „PDF: Grundlagen eines Dateiformats.“ (2013), Adresse: <https://soft-xpansion.com/files/cc/PDF-Grundlagen.pdf> (besucht am 21.12.2023).

- [12] Wikipedia. „XFA.“ (2023), Adresse: <https://en.wikipedia.org/wiki/XFA> (besucht am 21.12.2023).
- [13] Adobe Inc. „PDF-Ebenen.“ (2023), Adresse: <https://helpx.adobe.com/de/acrobat/using/pdf-layers.html> (besucht am 23.12.2023).
- [14] Adobe Inc. „PAdES: Elektronische Signaturen in PDF-Dokumenten. Für was steht die Abkürzung PAdES, welche Vorteile hat das Format und wie kannst du selbst ein Dokument digital signieren. Wir zeigen es dir.“ (o. D.), Adresse: <https://www.adobe.com/de/acrobat/resources/document-files/pdf-types/pades.html> (besucht am 26.12.2023).
- [15] Adobe Inc. „PDF/E: das Dateiformat für Engineering und technische Kommunikation. Erfahre, was PDF/E-Dateien auszeichnet, in welchen Bereichen sie Anwendung finden und wie du selbst eine PDF/E-Datei erstellst.“ (o. D.), Adresse: <https://www.adobe.com/de/acrobat/resources/document-files/pdf-types/pdf-e.html> (besucht am 26.12.2023).
- [16] Adobe Inc. „PDF/X-Dateien: effizienter drucken. Wir erklären dir, was man unter PDF/X-Dateien versteht, wie sie genau funktionieren und was der Unterschied zu originären PDFs ist.“ (o. D.), Adresse: <https://www.adobe.com/de/acrobat/resources/document-files/pdf-types/pdf-x.html> (besucht am 26.12.2023).
- [17] bm - gesellschaft für bildung in medienberufen mbh Köln, *Stoffsammlung Mediengestalter*, de. Köln, o. D., 190 S.
- [18] aktuelle-druckinfos.de. „Halbton- und Vollton.“ (o. D.), Adresse: <https://www.aktuelle-druckinfos.de/wiki-halbton-und-vollton> (besucht am 30.12.2023).
- [19] Adobe Inc. „Vollton- und Prozessfarben, Grundlagen.“ (2023), Adresse: <https://helpx.adobe.com/de/indesign/using/spot-process-colors.html> (besucht am 30.12.2023).
- [20] ENZYKLO.DE DEUTSCHE ENZYKLOPÄDIE. „Strichbild Bedeutung.“ (o. D.), Adresse: <https://www.enzyklo.de/Begriff/Strichbild> (besucht am 30.12.2023).
- [21] BenQ. „ICC-Profil Grundlagen.“ (2021), Adresse: <https://www.benq.eu/de-de/knowledge-center/knowledge/icc-profile-basics.html> (besucht am 20.12.2023).
- [22] PREPRESS Secrets. „Die Rolle des Profile Connection Space.“ (2015), Adresse: https://www.prepress-secrets.at/index_files/profile-connection-space.html (besucht am 20.12.2023).
- [23] PROJECT CONSULT. „PDF Standards.“ (o. D.), Adresse: <https://www.project-consult.de/themen/pdf-standards/> (besucht am 23.12.2023).

- [24] Adobe Inc. „Tranzparenz-Reduzierung (Acrobat-Pro), Transparenzen sind ein gern genutztes Stilmittel in der Gestaltung. Bei der Vorbereitung für den Druck müssen sie allerdings in der Regel reduziert werden. Was heißt das?“ (2023), Adresse: <https://helpx.adobe.com/de/acrobat/using/transparency-flattening-acrobat-pro.html> (besucht am 30.12.2023).
- [25] Primus-Print.de Die Besten drucken online. „Transparenzen.“ (o. D.), Adresse: <https://www.primus-print.de/daten/transparenzen/> (besucht am 30.12.2023).
- [26] Adobe Inc. „Work with color profiles.“ (2023), Adresse: <https://helpx.adobe.com/photoshop/using/working-with-color-profiles.html> (besucht am 30.12.2023).
- [27] fine art printer. „Tiefenkompensierung.“ (o. D.), Adresse: <https://www.fineartprinter.de/ger/FAQ/Tiefenkompensierung> (besucht am 30.12.2023).
- [28] Akash Choudhary. „callas software presents pdfDPartner, the first free DPart metadata viewer.“ (2021), Adresse: <https://pdfa.org/callas-software-presents-pdfdpartner-the-first-free-dpart-metadata-viewer/> (besucht am 30.12.2023).
- [29] callas. „Check for print and prepress related PDF 2.0 features.“ (o. D.), Adresse: <https://help.callassoftware.com/m/pdftoolbox/1/1608299-check-for-print-and-prepress-related-pdf-2-0-features> (besucht am 30.12.2023).
- [30] Adobe Inc. „PDF/A: Wie unterscheidet es sich von PDF? Erfahre, was PDF/A-Dateien auszeichnet, was der Unterschied zu einem PDF ist und wie du selbst eine PDF/A-Datei erstellen kannst.“ (o. D.), Adresse: <https://www.adobe.com/de/acrobat/resources/document-files/pdf-types/pdf-a.html> (besucht am 25.12.2023).
- [31] Adobe Inc. „Revisionssichere Archivierung mit einem Dokumentenmanagementsystem (DMS). Lerne, wie du Dateien revisionssicher mit einem Dokumentenmanagementsystem archivierst.“ (o. D.), Adresse: <https://www.adobe.com/de/acrobat/resources/audit-proof-archiving.html> (besucht am 25.12.2023).
- [32] Adobe Inc. „PDF/X-Dateien: effizienter drucken. Wir erklären dir, was der ISO-Standard PDF/VT bedeutet, wofür du den Dateityp brauchst und wie du selbst ein PDF/VT erstellen kannst.“ (o. D.), Adresse: <https://www.adobe.com/de/acrobat/resources/document-files/pdf-types/pdf-vt.html> (besucht am 26.12.2023).
- [33] Mozilla. „MIME types (IANA media types).“ (o. D.), Adresse: https://developer.mozilla.org/en-US/docs/Web/HTTP/Basics_of_HTTP/MIME_types (besucht am 01.01.2024).

- [34] Adobe Inc. „PDF/UA: So erstellst du barrierefreie PDFs.PDF/UA: So erstellst du barrierefreie PDFs. Wir erklären dir, was eine PDF/UA-Kennzeichnung ist, wofür du sie brauchst und wie du selbst barrierefreie PDF-Dokumente erstellen kannst.“ (o. D.), Adresse: <https://www.adobe.com/de/acrobat/resources/document-files/pdf-types/pdf-ua.html> (besucht am 26. 12. 2023).
- [35] Adobe Inc. „So erstellst du ein durchsuchbares PDF. Lerne, was ein Searchable PDF ist, welche PDF-Arten es gibt und wie du selbst eine durchsuchbare PDF-Datei erstellst.“ (o. D.), Adresse: <https://www.adobe.com/de/acrobat/resources/document-files.html> (besucht am 25. 12. 2023).
- [36] Wikipedia. „Internationale Beleuchtungskommission.“ (2023), Adresse: https://de.wikipedia.org/wiki/Internationale_Beleuchtungskommission (besucht am 30. 12. 2023).
- [37] Wikipedia. „International Commission on Illumination.“ (2023), Adresse: https://en.wikipedia.org/wiki/International_Commission_on_Illumination (besucht am 30. 12. 2023).
- [38] PrintWiki, The Free Encyclopedia of Print. „Open Prepress Interface.“ (o. D.), Adresse: http://printwiki.org/Open_Prepress_Interface (besucht am 20. 12. 2023).
- [39] HELIOS. „Welche Vorteile hat DeviceN für die Druckvorstufe?“ (o. D.), Adresse: https://www.helios.de/web/DE/news/deviceN_prepress.html (besucht am 20. 12. 2023).
- [40] Proof.de. „Schwarzpunktkompensation.“ (o. D.), Adresse: <https://www.proof.de/lexikon/schwarzpunktkompensation/> (besucht am 30. 12. 2023).
- [41] TechTarget. „PPD file (Postscript Printer Description file).“ (o. D.), Adresse: <https://www.techtarget.com/whatis/definition/PPD-file-Postscript-Printer-Description-file> (besucht am 29. 12. 2023).
- [42] Wikipedia. „Seitenbeschreibungssprache.“ (2021), Adresse: <https://de.wikipedia.org/wiki/Seitenbeschreibungssprache> (besucht am 20. 12. 2023).
- [43] Adobe Inc. „PostScript, LANGUAGE REFERENCE third edition.“ (1999), Adresse: <https://web.archive.org/web/20090419181826/http://www.adobe.com/devnet/postscript/pdfs/PLRM.pdf> (besucht am 20. 12. 2023).
- [44] Wikipedia. „Adobe Inc.“ (2023), Adresse: https://de.wikipedia.org/wiki/Adobe_Inc. (besucht am 01. 01. 2024).
- [45] Ange Albertini. „PDF 101 & PDF Secrets, Learning the PDF basics, applying it to hide/reveal informations in documents.“ (2014), Adresse: https://media.ccc.de/v/MRMCD2014_-_6007_-_en_-_grossbaustelle_ber_-_201409051830_-_pdf_101_pdf_secrets_-_ange_albertini (besucht am 29. 12. 2023).

-
- [46] Fabian Ising and Vladislav Mladenov. „How to Break PDFs, Breaking PDF Encryption and PDF Signatures.“ (2019), Adresse: https://media.ccc.de/v/36c3-10832-how_to_break_pdfs (besucht am 29.12.2023).
 - [47] Julia Wolf. „OMG WTF PDF, What you didn't know about Acrobat.“ (2011), Adresse: https://media.ccc.de/v/27c3-4221-en-omg_wtf_pdf (besucht am 29.12.2023).
 - [48] Ido Solomon. „BADPDF, Stealing Windows Credentials via PDF Files.“ (2019), Adresse: <https://media.ccc.de/v/gpn19-45-badpdf-stealing-windows-credentials-via-pdf-files> (besucht am 29.12.2023).
 - [49] FILEFORMAT. „PDF File Format, What is a PDF file?“ (o.D.), Adresse: <https://docs.fileformat.com/pdf/> (besucht am 01.01.2024).
 - [50] Mehmet Bayram, formilo. „Popularität und Statistiken der PDF.“ (o.D.), Adresse: <https://www.formilo.com/pdf-formulare/einfuehrung/popularitaet-statistiken/> (besucht am 19.12.2023).
 - [51] DocuSign. „Understanding digital signatures, What is a digital signature, and how can you create one?“ (o.D.), Adresse: <https://www.docusign.com/how-it-works/electronic-signature/digital-signature/digital-signature-faq> (besucht am 01.01.2024).
 - [52] Jens Müller, Fabian Ising, Vladislav Mladenov, Christian Mainka, Sebastian Schinzel, Jörg Schwenk. „PDFex: Major Security Flaws in PDF Encryption.“ (2019), Adresse: <https://web-in-security.blogspot.com/2019/09/pdfex-major-security-flaws-in-pdf.html> (besucht am 02.01.2024).
 - [53] Y. L. Jonathan Katz, *Introduction to MODERN CRYPTOGRAPHY, Third Edition* (A CHAPMAN & HALL BOOK), en. Boca Raton, Florida: CRC Press, 2021, 626 S., ISBN: 978-135-11330-36.
 - [54] studyflix. „AES Verschlüsselung.“ (o.D.), Adresse: <https://studyflix.de/informatik/aes-verschlüsselung-1611> (besucht am 02.01.2024).
 - [55] Baivab Kumar Jena. „What Is AES Encryption and How Does It Work?“ (2023), Adresse: <https://www.simplilearn.com/tutorials/cryptography-tutorial/aes-encryption> (besucht am 02.01.2024).
 - [56] J. Schwenk, *Sicherheit und Kryptographie im Internet, Theorie und Praxis 5. Auflage*, de. Wiesbaden: Springer Vieweg, 2020, 519 S., ISBN: 978-3-658-29260-7. DOI: 10.1007/978-3-658-29260-7.
 - [57] Oliver Helfrich, KOFAX. „30 Jahre PDF, Ein Geschenk, das uns immer wieder neu überrascht.“ (2023), Adresse: <https://www.kofax.de/learn/blog/30-years-of-pdf> (besucht am 19.12.2023).

- [58] Adobe Inc. „Dokumentenformate: Alles, was du wissen musst.“ (o. D.), Adresse: <https://www.adobe.com/de/acrobat/resources/document-files.html> (besucht am 20.12.2023).
- [59] Promotional Blog. „Korrekturabzug.“ (o. D.), Adresse: <http://www.promotional-blog.de/glossary/korrekturabzug/> (besucht am 30.12.2023).
- [60] Kerstin Merber. „PDF Blätterkatalog erstellen und das hochwertige Ergebnis in wenigen Minuten sehen.“ (o. D.), Adresse: <https://mypdf.me/blaetterbare-pdf/pdf-blaetterkatalog/> (besucht am 01.01.2024).

Anhang

Erklärung

Ich versichere, die von mir vorgelegte Arbeit selbstständig verfasst zu haben. Alle Stellen, die wörtlich oder sinngemäß aus veröffentlichten oder nicht veröffentlichten Arbeiten anderer oder der Verfasserin/des Verfassers selbst entnommen sind, habe ich als entnommen kenntlich gemacht. Sämtliche Quellen und Hilfsmittel, die ich für die Arbeit benutzt habe, sind angegeben. Die Arbeit hat mit gleichem Inhalt bzw. in wesentlichen Teilen noch keiner anderen Prüfungsbehörde vorgelegen.

Anmerkung: In einigen Studiengängen findet sich die Erklärung unmittelbar hinter dem Deckblatt der Arbeit.

Köln, 04.03.2024

Unterschrift