

---

# Entwicklung einer webbasierter Applikation zur Bearbeitung von PDF Dateien

Bachelorarbeit zur Erlangung des Bachelor-Grades  
(*Bachelor of Science*) im Studiengang Technische Informatik  
an der Fakultät für Informations-, Medien- und Elektrotechnik  
der Technischen Hochschule Köln

vorgelegt von: Janina Schroeder  
Matrikel-Nr.: 11132206  
Adresse: Laurentiusweg 10  
50321 Brühl  
janina\_jessika\_jelena.schroeder@smail.th-koeln.de

eingereicht bei: Prof. Dr. Chunrong Yuan  
Zweitgutachter/in: Prof. Dr. René Wörzberger

Köln, 04.03.2024

# Bachelorarbeit

**Titel:** Entwicklung einer webbasierter Applikation zur Bearbeitung von PDF

Dateien

**Gutachter:**

- Prof. Dr. Chunrong Yuan
- Prof. Dr. René Wörzberger

**Zusammenfassung:** Für die Bachelorarbeit habe ich eine Open Source offline Webseite zur Bearbeitung von PDF Dateien im Firefox Browser programmiert. Seit Adobe den PDF Standard entwickelt hat, tauchten zahlreiche meist kostenpflichtige PDF Anwendungen, um PDF Dateien zu bearbeiten auf dem Markt auf. Ich habe den Markt an PDF Programmen analysiert und diese mit meiner Webapplikation verglichen. Daraufhin beleuchte ich den aktuellen Stand der Technik des PDF Standards. Im späteren Verlauf erkläre ich die Implementierung meiner Webapp und meine Erfahrungen mit anderen Browsern, sowie auf MacOS, Linux, Android und iOS. Die Javascript Libraries PDF.js und PDF-LIB sind das tragende Fundament meiner PDF Webapp. Die PDF Webapp vereint alle Funktionalitäten, die man für gängige PDF Bearbeitung benötigt. Man kann PDFs lesen, splitten, mergen, erstellen, sowie mit Texten, Bildern, Geometrie und Zeichnungen versehen. Am Ende diskutiere ich, was man hätte besser machen können, welche Funktionalitäten fehlen und welche Features in Zukunft noch geplant sind.

**Stichwörter:** PDF Bearbeitung, Adobe, Javascript, Vue JS 3, auf PDF zeichnen, Splitten, Mergen, PDF.js, PDF-LIB

**Datum:** 04. März 2024

# Inhaltsverzeichnis

Abkürzungsverzeichnis	V
1 Grundlagen	2
1.1 Wichtigste Features . . . . .	3
1.1.1 WYSIWYG . . . . .	3
1.1.2 Fonts . . . . .	3
1.1.3 Bilder . . . . .	4
1.1.4 3D-Daten . . . . .	5
1.1.5 Kommentare . . . . .	5
1.1.6 Verweise . . . . .	5
1.1.7 Formulare . . . . .	5
1.1.8 Incremental Update . . . . .	6
1.1.9 Kompression . . . . .	7
1.1.10 Ebenen . . . . .	7
1.1.11 Portfolio . . . . .	7
1.1.12 JavaScript . . . . .	8
1.2 PDF Dateiformate . . . . .	8
1.2.1 PAdES . . . . .	8
1.2.2 PDF/X . . . . .	9
1.2.3 PDF/A . . . . .	12
1.2.4 PDF/E . . . . .	13
1.2.5 PDF/H . . . . .	14
1.2.6 PDF/VT . . . . .	14
1.2.7 PDF/UA . . . . .	15
1.2.8 PDF/R . . . . .	15
1.2.9 Searchable PDF . . . . .	15
1.3 PDF Dateiversionen . . . . .	16
1.3.1 PDF 1.0 . . . . .	16
1.3.2 PDF 1.1 . . . . .	16
1.3.3 PDF 1.2 . . . . .	17
1.3.4 PDF 1.3 . . . . .	17
1.3.5 PDF 1.5 . . . . .	18
1.3.6 PDF 1.4 . . . . .	18
1.3.7 PDF 1.6 . . . . .	18
1.3.8 PDF 1.7 . . . . .	18
1.3.9 PDF 2.0 . . . . .	19
	II

1.4	PDF Implementierung . . . . .	19
1.4.1	PostScript . . . . .	20
1.4.2	Adobe Imaging Model . . . . .	20
1.4.3	Dateiformataufbau . . . . .	21
1.4.4	Implementierung von Fonts . . . . .	26
1.5	PDF Sicherheitsaspekte . . . . .	28
1.5.1	Digitale Signatur . . . . .	29
1.5.2	PDF Signature Spoofing . . . . .	30
1.5.3	PDFex PDF Encryption Attacks . . . . .	32
2	Open Source PDF Web App . . . . .	39
2.1	Anforderungen und Konzept . . . . .	39
2.1.1	Vorgaben für den Funktionsumfang der PDF Web App . . . . .	40
2.1.2	Qualitätsanforderungen . . . . .	43
2.2	Realisierte Funktionalität und Bedienung der PDF Web App . . . . .	44
2.2.1	Bedienung des Readers . . . . .	46
2.2.2	Bedienung des Creators . . . . .	48
2.2.3	Bedienung des Splitters . . . . .	48
2.2.4	Bedienung des Mergers . . . . .	50
2.2.5	Bedienung des Editors . . . . .	52
2.3	Implementierung der PDF Web App . . . . .	71
2.3.1	Werkzeuge . . . . .	71
2.4	Testdurchführung der PDF Web App . . . . .	71
2.4.1	Funktionale User Tests . . . . .	71
2.4.2	Stress Tests . . . . .	71
2.4.3	Browserunterschiede . . . . .	71
3	Marktübersicht und PDF Wettbewerberprogramme . . . . .	72
3.1	Die Firma Adobe Systems Incorporated . . . . .	72
3.2	Aktueller Stand von Forschung und Technik . . . . .	72
3.3	Freie PDF Programme und Onlinedienste . . . . .	74
3.3.1	foxit . . . . .	74
3.3.2	PDF24 . . . . .	74
3.3.3	PDFsam . . . . .	74
3.3.4	DrawboardPDF . . . . .	74
3.3.5	PDFCreator . . . . .	74
3.3.6	LibreOffice . . . . .	74
3.3.7	OpenOffice . . . . .	75
3.3.8	ghostscript . . . . .	75
3.4	Kostenpflichtige PDF Programme und Onlinedienste . . . . .	75
3.4.1	Adobe Acrobat . . . . .	75
3.4.2	Adobe Acrobat Pro . . . . .	75
3.4.3	Onlinetools von Acrobat . . . . .	75
3.4.4	Acrobat Distiller . . . . .	76

3.4.5	Microsoft Word . . . . .	76
3.4.6	pdf-it . . . . .	76
3.4.7	PDFelement . . . . .	76
3.4.8	Soda PDF . . . . .	76
3.4.9	Nitro PDF Pro . . . . .	76
3.4.10	Ashampoo PDF Pro 3 . . . . .	76
3.4.11	Infix 7 . . . . .	76
3.4.12	PDF Director 2 Pro . . . . .	77
3.4.13	Perfect PDF . . . . .	77
3.5	PDF zu Word Programme und Onlinedienste . . . . .	77
3.5.1	UPDF . . . . .	78
3.5.2	WPS . . . . .	78
3.5.3	LightPDF . . . . .	78
3.6	PDF zu Latex Programme und Onlinedienste . . . . .	78
3.7	Zielgruppenanalyse . . . . .	78
3.7.1	Soziodemographische Kriterien . . . . .	78
3.7.2	Psychographische Kriterien . . . . .	78
3.8	Umfeldanalyse . . . . .	78
3.8.1	Politische Aspekte . . . . .	78
3.8.2	Soziographische Aspekte . . . . .	78
3.9	Relevanz von PDF in verschiedenen Marktbranchen . . . . .	78
3.10	Rolle von PDF in der Druckvorstufe und Designbranche . . . . .	79
3.11	Wettbewerbsanalyse . . . . .	85
3.12	Unternehmensanalyse . . . . .	85
3.12.1	Unternehmensziele . . . . .	85
3.12.2	SWOT-Analyse . . . . .	85
3.13	Marketingstrategie . . . . .	85
3.13.1	Produkt . . . . .	85
3.13.2	Preis . . . . .	85
3.13.3	Promotion . . . . .	85
3.13.4	Platzierung . . . . .	85
3.13.5	Personal . . . . .	85
4	Diskussion und Kritik . . . . .	86
4.1	Erfahrungen bei der Programmierung der Tablet-Version . . . . .	88
4.1.1	Bewertung der Tests und Performance der PDF Web App . . . . .	89
4.2	Ideen für zukünftige Releases der PDF Web App . . . . .	89
	Literatur . . . . .	92
	Tabellenverzeichnis . . . . .	98
	Abbildungsverzeichnis . . . . .	99
	Anhang . . . . .	101
		IV

# Abkürzungsverzeichnis

- AES** Advanced Encryption Standard. 18, 19, 33–38, 99
- ASCII** American Standard Code for Information Interchange. 20, 21
- BITV** Barrierefreie-Informationstechnik-Verordnung. 15
- CAD** Computer-Aided Design. 5, 13
- CAdES** CMS Advanced Electronic Signatures. 8
- CBC** Cipher Block Chaining. 33, 34, 36–38, 99
- CEPS** Cisco Enterprise Print System. 17
- CID** Character Identifier Font. 4, 17
- CIE** Commission Internationale de l’Éclairage. 16, 17
- DCS** Desktop Color Separation. 10
- DOS** Denial-of-Service. 28
- ECB** Electronic Code Book. 37
- EEA** Evil Annotation Attack. 28
- EPS** Encapsulated PostScript. 81
- ETSI** European Telecommunications Standards Institute. 8
- GDI** Graphics Device Interface. 19
- GPT-4** Generative Pre-trained Transformer 4. 73
- ICC** International Color Consortium. 10–12, 14, 17, 80
- IE** Information Extraction. 72
- ISA** Incremental Saving Attack. 30, 31, 99
- ISO** International Organization for Standardization. 2, 3, 6, 8–19, 80, 83

**JSON** JavaScript Object Notation. 90

**MAC** Message Authentication Code. 34, 36–38

**MIME** Multipurpose Internet Mail Extension. 14, 19, 38

**MITM** Man-in-the-middle. 33, 37

**MLP** multilayer perception. 73

**NLP** Natural Language Processing. 72, 73

**OCR** Optical Character Recognition. 15, 72, 73, 75, 89, 90

**OPI** Open Prepress Interface. 10, 17

**PAdES** PDF Advanced Electronic Signatures. 8, 79

**PCS** Profile Connection Space. 10

**PDL** Page Description Language. 19–21

**PPD** PostScript Printer Description. 19, 75

**ppi** Pixels per inch. 21

**RE** Relation Extraction. 72

**RIP** Raster Image Processor. 19, 20, 80, 81, 84

**RLE** Run Length Encoding. 7

**SSA** Sneaky Signature Attack. 28

**SWA** Signature Wrapping Attack. 30–32, 99

**USF** Universal Signature Forgery. 30–32, 99

**WCAG** Web Content Accessibility Guidelines. 15

**WYSIWYG** What You See Is What You Get. 2, 3

**XAdES** XML Advanced Electronic Signatures. 8

**XFA** XML Forms Architecture. 6, 18, 19

**XML** Extensible Markup Language. 6, 18, 38, 82

**XMP** Extensible Metadata Platform. 12, 13

**ZSA** Zeitstempel-Anbieter. 29



# Einleitung

## Motivation

Zu Hause benutze ich 4 PDF-Programme, um alle für mich zufriedenstellenden häufigen Anforderungen der PDF-Bearbeitung zu erledigen: Adobe Reader zum Anzeigen von PDF, Drawboard PDF zum Zeichnen, Foxit Reader zum Schreiben und PDF Sam Basic zum Splitten und Mergen. Ich habe dann später herausgefunden, dass man mit Foxit Reader auch Splitten, Mergen und Zeichnen kann, jedoch finde ich dieses Programm sehr unintuitiv und ich vergesse immer wo die Einstellmöglichkeiten für diese Funktionalitäten waren. Oft habe ich dann keine Lust die Einstellmöglichkeiten im Internet zu googlen und nehme dann lieber PDF Sam Basic zum Splitten von Seiten. PDF Sam Basic ist da einfacher, jedoch ist es sehr störend, dass man bei seiner Installation auch eine andere Werbeversion von PDF Sam zusätzlich installiert. Ich habe mir gedacht, dass es nicht sein kann, dass mir kein kostenloses PDF Programm so wirklich gefällt und deshalb beschloss meine eigene PDF Web App zu entwickeln. Weiter habe ich überlegt: Es wäre sinnvoll eine Webseite zu programmieren, die man auch offline nutzen kann. Alles was man benötigen soll ist ein Browser und keine Installationen mit zusätzlichen Werbeprogrammen, die man eigentlich nicht installieren wollte. Wie wäre es mit einer Open Source Web App, die ich meinen Freunden zeigen kann und mit denen ich mich auf dem Arbeitsmarkt bewerben kann? Gesagt, getan - ich habe diese PDF Web App für diese Bachelorarbeit programmiert und sie ist neben ein paar Ecken und Kanten besser geworden, als ich es je erwartet hätte. Ich habe während der Programmierung viel gelernt über JavaScript, asynchrone Programmierung, Event Handler, usw. und bin generell sicherer geworden im Programmieren. Vor allem habe ich Wert darauf gelegt, dass die Web App eher einfach und intuitiv zu bedienen ist. Einige Features waren nicht geplant, aber mir hat es Spaß gemacht sie zu implementieren, da ich die Motivation hatte ein für andere und mich gutes Tool zu entwickeln. Natürlich gibt es noch eine lange Liste an Features, die ich in Zukunft noch implementieren möchte. Die PDF Web App ist kein abgeschlossenes Projekt. Dieses Hobby-Projekt möchte ich gerne nach der Bachelorarbeit weiter auf meiner Github-Seite maintainen. Vielleicht gibt es andere Entwickler, die mein Repository forken oder bug fixes hinzusteuern wollen. Vielleicht kann ich andere Entwickler dafür begeistern an der PDF Web App mitzuarbeiten und sie noch besser zu machen.

## Aufbau der Arbeit

# 1 Grundlagen

Das PDF Dateiformat steht für Plattformunabhängigkeit, Hardwareunabhängigkeit, Konsistenz in Formatierung und Layout und soll ein möglichst originalgetreues Druckergebnis liefern. Der Leser soll ein PDF Dokument immer nach dem Prinzip What You See Is What You Get (WYSIWYG) (What You See Is What You Get) in der Form betrachten und ausdrucken können wie es vom Ersteller des Dokuments festgelegt wurde.



Abbildung 1.1 Adobe PDF Icon [1]

PDF wurde im Jahr 1993 von dem 1982 gegründeten amerikanischen Softwareunternehmen Adobe Inc. veröffentlicht und ging aus dem 1991 von Adobe-Mitbegründer John Warnock gestarteten „Project Camelot“ hervor[2]. Ziel des Projekts war es, ein Dateiformat für elektronische Dokumente zu kreieren, sodass dieses Anwendungsprogramm, Betriebssystem und Hardware unabhängig sowie originalgetreu wiedergegeben werden kann. In Abbildung 1.1 ist das Datei-Icon für PDF von Adobe zu sehen.

Anfangs war der Adobe Reader noch kostenpflichtig und PDF war für einen langen Zeitraum ein proprietäres Dateiformat, welches offengelegt im PDF Reference Manual von Adobe dokumentiert ist. Die Spezifikation von PDF ist seit 1993 kostenlos einsehbar [1]. Die International Organization for Standardization (ISO) übernahm PDF im Jahr 2007 in den Standardisierungsprozess und seit der Veröffentlichung von PDF Version 1.7 am 1. Juli 2008 gilt PDF als Offener Standard als ISO 32000-1:2008[1], [2]. Vorher war PDF ein proprietäres Dateiformat von Adobe. Der Begriff Offener Standard bezeichnet einen Standard, der für alle Teilnehmer am Markt besonders leicht zugänglich, weiterentwickelbar und einsetzbar ist. Das bedeutet, dass der Standard von einer gemeinnützigen Organisation eingeführt, veröffentlicht sowie weiter bearbeitet wird und gleichmäßige Einflussnahme aller interessierten Parteien ermöglicht [3].

Im gleichen Jahr publizierte Adobe eine Public Patent Licence zum ISO Standard 23000-1, also PDF Version 1.7, die royalty-free Rechte einräumt, um PDF-Implementierungen zu programmieren, verkaufen und verbreiten [1]. Royalty-free bedeutet hierbei, dass Compu-

terherstellerfirmen pro verkauftes Endgerät keine Gebühren (royalties), sowie keine fixe Jahrespauschale bezahlen müssen [4]. Die letzte Dateiversion von PDF heißt PDF 2.0 und sie wurde im Jahr 2020 von der ISO standardisiert. Heute wird PDF seit 2006 von der PDF Association weiterentwickelt [2].

## 1.1 Wichtigste Features

Die in den Unterkapiteln genannten Operationen auf dem PDF-Dateiformat beziehen sich hauptsächlich auf Adobe Acrobat-Werkzeuge. PDFs können Texte, Tabellen, Bilder, Pfade, Links, Buttons, Formulare, Audio-, Videoelemente und Funktionen enthalten. Rich Media-PDFs ermöglichen interaktive Inhalte, die eingebettet oder verlinkt werden können. Solche Elemente sind Bilder, Audio, Video oder Buttons, z.B. als digitaler Katalog [1]. Fonts und Bilder sollten grundsätzlich immer eingebettet werden.

In PDFs werden alle Informationen als nummerierte Objekte gespeichert. Objekte können zu Gruppen kombiniert werden. Der aktuelle Farbmodus im Dokument kann in andere Farbmodi konvertiert werden. Um die Navigation innerhalb eines PDF Dokuments zu erleichtern kann man anklickbare Inhaltsverzeichnisse und miniaturisierte Seitenvorschauen (Thumbnails) verwenden. Optional ist eine Gliederung als hierarchische Baumstruktur in Form von Lesezeichen möglich, mit der der Betrachter leichter durch das Dokument geführt werden kann.

PDF-Dateien enthalten grundsätzlich Metadaten. Bei Metadaten oder Metainformationen handelt es sich um strukturierte Daten, die sich auf Merkmale anderer Daten beziehen. Beispiele für Metadaten sind Name, Titel der Datei, Autor, Stichwörter zum Inhalt, das Datum der Speicherung. PDF-Dateien können Dateianhänge enthalten, die geöffnet und im lokalen Dateisystem abgespeichert werden können [1].

### 1.1.1 WYSIWYG

Ein PDF-Dokument hat ein festes Layout und eine feste Anzahl von Seiten. Unabhängig von der Software mit der das Dokument angezeigt wird oder mit welcher Hardware es ausgedruckt wird bleiben alle Elemente nach dem Prinzip WYSIWYG auf den Seiten immer exakt an derselben Position. Alle Layout- und Formatierungsangaben stammen aus der Erstellungsanwendung. Bei der Konvertierung von Dokumenten mit variablem Layout zu PDF, wie z.B. .txt-Dateien oder HTML muss der Inhalt auf die vorhandenen Seiten und den verfügbaren Platz verteilt werden.

### 1.1.2 Fonts

Jedes Textzeichen ist ein abstraktes Symbol und ein Schriftzeichen beruht auf eine graphische Darstellung. Eine Schriftart ist in PDF als Objekt enthalten. Die Schriftart kann mit

Werkzeugen in Acrobat bearbeitet werden. Der Text muss ausgewählt sein und es können darauf folgende Operationen angewandt werden: Farbveränderung in RGB, Transparenzen, Verschiebung, Löschen, Skalierung, Verzerrung bzw. Scherung, Spiegelung, Drehung, Beschneidung oder Ersetzung. Der RGB-Farbraum eignet sich lediglich für die Bildschirmdarstellung und beschreibt die für den Menschen 16,7 Millionen sichtbaren Farben mit Hilfe von additiver Farbmischung mittels Rot, Grün und Blau. Ein Farbraum umfasst die mathematischen Parameter als Daten für die Gesamtzahl der Farben, die auf einem Monitor, Druckmaterial, usw. darstellbar sind [5].

In Adobe Acrobat Pro kann der gesamte Text pro Seite in Pfade konvertiert werden. Pfade sind mathematisch berechnete Linien, die aus gekrümmten Segmenten bestehen. Der Anfang und das Ende jedes Segments werden als Ankerpunkte bezeichnet und Pfade können geschlossen oder geöffnet sein. Die Form des Pfads kann durch die Griffpunkte an den Ankerpunkten modifiziert werden und Pfadsegmente können somit verformt werden [6]. Auf diese Weise kann man komplexe Formen für z.B. Firmenlogos oder auch eigene Schriftarten designen. Solche manuellen Pfade kann man vor allem in Adobes Illustrator, InDesign oder Photoshop erstellen.

PDF unterstützt Type-1-Fontformate, Multiple-Master-Fonts, TrueType-Fontformate, OpenType-Fontformate, Dfonts, Character Identifier Font (CID) codierte Fonts und Composite-Fonts. Seit PDF 1.3 werden CID-Schrifttypen als Abkömmlinge von Composite-Fonts unterstützt. CID ist ein Synonym für das PostScript Type-0-Format, das eine Adressierung von mehr als 256 Zeichen ermöglicht und für Fonts mit einer großen Zeichenanzahl verwendet wurde [7]. Composite-Fonts sind Basisschriften mit hierarchischem System. Die oberste hierarchische Ebene stellt den root font dar. Alle folgenden Fonts sind descendant fonts. Sie ermöglichten die Einführung von Type-1-Schriften im asiatischen Markt [8]. Falls die Schriftart nicht im Dokument eingebettet wurde, wird sie aus der Ursprungsdatei möglicherweise durch eine Ersatzschrift des Benutzersystems im PDF-Programm substituiert [8].

### 1.1.3 Bilder

Generell sollte für das Bearbeiten von Bildern ein externes Bildbearbeitungsprogramm verwendet werden, z.B. Photoshop oder das kostenlose Gimp. Dafür kann für die Bearbeitung in Photoshop das Bild mittels Acrobat Pro aus dem PDF extrahiert werden und später wieder im in Acrobat Pro geöffneten PDF ersetzt werden. Vektorgrafiken als Pfadobjekte und Rasterbilder als Pixelobjekte (Bitmap) können nach Auswahl verschoben, gelöscht, skaliert, verzerrt, gespiegelt, gedreht, die Deckkraft verändert, beschnitten oder ersetzt werden [8]. Der Mehrwert an Vektorgrafiken liegt in dessen Eigenschaften, dass sie auflösungsunabhängig sind, da sie beliebig groß ohne Qualitätsverlust skaliert werden können und dass sie wesentlich weniger Speicherplatz benötigen als Rasterbilder.

Die Auflösung von Bildern kann in Acrobat neu berechnet werden. Niedrig aufgelöste Bilder behalten ihre Auflösung bei. Ein guter Neuberechnungsalgorithmus heißt bikubische Neuberechnung. Bei Schwarzweißbildern kann eine Neuberechnung zu unschönen Artefakten

führen [9]. Generell führt eine Neuberechnung der Auflösung in Bildbearbeitungsprogrammen zu besseren Ergebnissen als in Acrobat. Etwaige Pixelbearbeitungen wie Tonwertkorrekturen oder das Schärfen von Bildern können ausschließlich in Bildbearbeitungsprogrammen vorgenommen werden.

#### 1.1.4 3D-Daten

PDFs mit 3D-Inhalten bestehen aus dem U3D-Flächenmodell oder dem BREP/Flächenmodell PRC. Diese Flächenmodelle werden vorwiegend bei der Visualisierung von Computer-Aided Design (CAD) Daten verwendet. Beide Formate können im Adobe Reader angezeigt, animiert, geschnitten und gemessen werden. Viele Drittanbieter PDF-Reader und die PDF-Viewer im Browser können eingebettete 3D-Daten meist nicht darstellen. Einige CAD-Programme ermöglichen einen 3D-PDF-Export oder Import [2].

#### 1.1.5 Kommentare

Ein Kommentarobjekt, das mit Dokumentenseiten verlinkt ist, besteht aus 2 technisch separaten Bausteinen. Zum einen werden Kommentare durch ein grafisches Element auf den zugehörigen Seiten symbolisiert, zum anderen wird der Kommentarinhalt in einem rechteckigen Kommentarbereich dargestellt. Ein Anwender kann die Darstellung des Kommentarobjekts je nach Geschmack modifizieren. Unüblicherweise kann ein Kommentar sogar als Video-Kommentar abgespielt werden. Die wichtigsten Kommentartypen sind Notizzettel, Textmarkierung, Stempel, Wasserzeichen, Textboxen, Formen, Freihand-Markierung, Audio, Video und 3D-Illustrationen. Kommentare können optional mit ausgedruckt werden [10].

#### 1.1.6 Verweise

Technisch gesehen sind Verweise oder Hyperlinks spezialisierte Kommentare ohne Symboldarstellung. Auf der Seite wird ein Ausschnitt zur Platzierung des Verweises gewählt, der über einem Inhaltselement (Text oder Bild) liegt. Der Verweis zeigt auf eine Seite oder Seitenbereich im geöffneten Dokument, eine andere PDF-Datei, eine E-Mailadresse oder URL. Man kann sogar Zielobjekte mit einem im gesamten Dokument eindeutigen Namen einstellen [10].

#### 1.1.7 Formulare

In PDFs kann man Formularfelder vom Typ Textfeld, Kontrollkästchen, Auswahlknopf, Kombinationsfeld, Auswahlliste, Schaltfläche, Barcode- oder Unterschriftsfeld erstellen. Ein Formularfeld ist ein Objekt zum befüllen und speichern von Felddaten. Die unterschiedlichen Formularfeldtypen weisen verschiedene Eigenschaften in Bezug auf Interaktivität und Gestaltung auf. Jedes Feld hat einen eindeutigen Namen im gesamten Dokument.

Mit diesem unikalen Namen können Namensgruppen realisiert werden. Durch eine hierarchische Struktur mittels Teilnamen, die mit einem Punkt voneinander getrennt sind mit dem äußersten Gruppennamen zuerst geschrieben werden, können Felddaten noch besser und logischer beschrieben bzw. strukturiert werden. Jedes Feldobjekt geht Hand in Hand mit einem Widget, welches ein spezielles Kommentarobjekt zur Steuerung darstellt. Diese Widgets stehen für Werte oder Zustände der Felder und sind dafür verantwortlich, dass man Formulare im PDF-Dokument mit dem Computer, Tablet oder Smartphone ausfüllen kann. Außerdem ist es möglich unsichtbare Feldobjekte, die ohne das Widget platziert werden können, zu erstellen, um die PDF-Software anzusprechen. Häufiger werden mehrere Widgets mit einem Feldobjekt gekoppelt [10].

Um elektronisch ausfüllbare Formulare zu verwenden müssen zusätzlich in Acrobat Formularfelder auf die entsprechenden Stellen platziert werden. Falls ein Listenfeld verwendet wird, sollte man eine Schrift für die Listeneinträge im PDF einbetten. Formulare können einen druckbaren und nicht druckbaren Teil enthalten. In der Druckvorstufe müssen vor dem Druck alle Formularfelder eliminiert werden, damit alle Schriften eingebettet werden können [8]. Es gibt 2 verschiedene Möglichkeiten von PDF Formularen: AcroForms (Acrobat Forms) oder Adobes proprietäre XML Forms Architecture (XFA) forms, welche mit Version 2.0 von der ISO als veraltet markiert wurden. XFAs Haupterweiterungen zu Extensible Markup Language (XML) sind rechnergestützte, aktive Tags und sein Datenformat ist kompatibel mit anderen Systemen, Anwendungen und Technologiestandards [11]. XML ist eine Sprache zur Markierung von Inhalten mit Hilfe von Tags, um die Struktur zu beschreiben und Elemente zu identifizieren [8]. AcroForms unterstützen das Abschicken (submit), Zurücksetzen und Importieren von Daten. Die submit-Aktion transferiert die Namen und Werte eines ausgewählten interaktiven Formularfelds zu einer vordefinierten URL. In der Praxis werden Formulare in einem Grafik- oder Layoutprogramm gestaltet und als PDF exportiert.

#### 1.1.8 Incremental Update

Die ursprüngliche Version einer PDF-Datei bleibt erhalten, während das incremental update die Änderungen im Dokument enthält. Professionelle PDF-Programme können ähnlich einer Versionsverwaltung jede geänderte Version des Dokuments laden. Bei einfacheren PDF-Programmen wird lediglich die letzte Version geladen. Bei Verwendung von incremental updates kann man digital unterschriebene Dokumente ändern ohne dass die Unterschrift ungültig wird, da die Dokumentversion mit der digitalen Unterschrift eine andere Version ist als die nachträgliche Änderung. Dabei muss die digitale Unterschrift als incremental update gespeichert werden, sonst würde sie bei nachträglicher Dokumentenmodifikation unabhängig von der Änderungsart verfallen. Folglich sollten mehrfach signierte Dokumente ebenfalls mit der Option incremental update gespeichert werden [10]. Pro incremental update steigt der Speicherbedarf einer PDF-Datei.

### 1.1.9 Kompression

PDF-Dateien sind komprimiert und haben üblicherweise einen Bruchteil der Größe des Ursprungsformats. Dies wird durch Vermeidung von Redundanzen, Erhöhung der Entropie (Zeichendichte) und Weglassen von Informationen bewerkstelligt. Im Allgemeinen gibt es verlustlose und verlustbehaftete Kompression. Die Kompressionsalgorithmen Run Length Encoding (RLE), die genauso effiziente LZW, Flate-Komprimierung, ZIP und CCITT gehören zur verlustfreien Kompression. Zur verlustbehafteten Kompression zählen JPEG, JBIG2 und JPEG2000 [8]. Kompressionsalgorithmen sind nicht auf bestimmte Dateiformate beschränkt. In PDF können die folgenden Kompressionsalgorithmen für Bilder verwendet werden: IP, RLE, JPEG, JPEG2000, CCITT und JBIG2. Eine hohe Bildqualität im PDF bedeutet eine größere Datei. Faktoren, die die Bildqualität beeinflussen, sind Breite x Höhe des Bildes, Farbtiefe, Farbraum und die Kompressionsmethode [10].

Außerdem ist es möglich eine Datenreduktion durch Neuberechnung zu erzielen. Hierbei wird das verlustbehaftete Downsampling verwendet und führt häufig zu nicht befriedigenden Ergebnissen. Es gibt als Neuberechnungsmethoden die eher im Ergebnis mangelhafte Kurzberechnung, sowie die besseren durchschnittliche und bikubische Neuberechnungen. Neuberechnungen in Photoshop führen generell zu besseren Ergebnissen als in Adobe Acrobat Distiller [8].

PDF-Dateien können zur Weboptimierung serialisiert (linearisiert) werden, sodass Teile des PDFs während des Ladevorgangs dargestellt werden. Liegen unkomprimierte Elemente im Dokument vor, werden diese beim Speichern durch die Flate-Komprimierung, die auch den ZIP-Algorithmus verwendet, komprimiert.

### 1.1.10 Ebenen

Ebenen werden auch als Optional Content Layers bezeichnet und stellen quasi mehrere Inhaltsschichten auf einer einzelnen PDF-Seite dar, wobei jede Seite im Dokument beliebig viele Ebenen enthalten kann. Jede Ebene kann PDF-Inhalt sozusagen logisch gruppieren und die Bearbeitung von Inhalten auf einer Ebene wirkt sich nur auf diese Ebene aus. Man kann Inhalte auch mehreren Ebenen zuordnen oder keiner Ebene. Ebenen können ein- und ausgeblendet, ihre Reihenfolge verändert, gesperrt, zusammengeführt, aus anderen PDF-Dateien importiert und für unterstützende Dateiformate von Adobeprogrammen, z.B. Photoshop, Illustrator oder InDesign, exportiert werden. Zusätzlich kann man eine Ebenennavigation mit Hilfe von Links und Lesezeichen konstruieren, um Ebenensichtbarkeit für den Betrachter zu steuern [12].

### 1.1.11 Portfolio

Ein Portfolio bezeichnet eine Datei bestehend aus anderen Dateien, die kein Hauptdokument enthält, sondern lediglich eine Pseudo-Seite. Diese Pseudo-Seite wird von Portfolio

inkompatiblen PDF-Programmen angezeigt. Zusätzlich können andere PDF-Dateien und andere Dateiformate im PDF-Hauptdokument eingebettet werden [10].

### 1.1.12 JavaScript

In PDF kann man Ereignisse Aktionen zuordnen, d.h. bei Eintreffen eines Ereignisses wird automatisch eine Aktion ausgeführt. Ein Ereignis ist eine bestimmte Statusänderung von Objekten oder ein interaktives Anwenderereignis. Dabei kann man als Aktion JavaScript-Code aufrufen, dessen Aktion mit Lesezeichen, Verweisen, Seiten und Dokumentereignissen verknüpft ist. Auf Formularfeldern kann ebenfalls JavaScript angewandt werden [10]. Diese JavaScript-Erweiterung für Acrobat ist eine proprietäre Technologie von Adobe. Viele andere nicht-Adobe PDF-Programme bieten keine Unterstützung für JavaScript [1].

## 1.2 PDF Dateiformate

PDF hat zahlreiche Dateiformate, von denen die meisten standardisiert wurden, hervor- gebracht. Jedes Dateiformat ist einem individuellen Anwendungsbereich zugeordnet und adressiert spezifische Industriebranchen: PAdES für elektronische Signaturen, PDF/X für den professionellen Druck, PDF/A für die Archivierung, PDF/E für den Ingenieurbereich, PDF/H für das Gesundheitswesen, PDF/VT für den Druck mit variablen Daten, PDF/UA für Barrierefreiheit, PDF/R für gescannte Dokumente und Durchsuchbare PDFs für Stichwortsuche. Im Folgenden stelle ich jedes Format vor und beschreibe seine speziellen Merkmale.

### 1.2.1 PAdES

PDF Advanced Electronic Signatures (PAdES) ergänzt den Funktionsumfang um Werk- zeuge mit denen man elektronische Signaturen erzeugen, anpassen und prüfen kann. Es wurde vom European Telecommunications Standards Institute (ETSI) veröffentlicht, 1999 in PDF 1.3 eingeführt und basiert auf der ISO 32000-1 Spezifikation. Nachfolgend wurde dessen Konzept weiterentwickelt. PAdES erweitert PDF um kryptographische Techniken und ermöglicht sichtbare und unsichtbare digitale Signaturen. Resultierend soll dieses Dateiformat die Integrität, Authentizität, Verbindlichkeit und Rechtssicherheit von digital signierten PDF-Dokumenten herstellen. PAdES implementiert verschiedene Signaturformate wie CMS Advanced Electronic Signatures (CAAdES) und XML Advanced Electronic Signatures (XAdES), unterstützt Zeitstempel und die Validierung des Zertifikatwiderrufsstatus. Zertifikatbasierte Signaturen sollen die Identität des Unterzeichners und die Unabänder- lichkeit des Dokuments sichern. Eine zertifizierte PDF-Datei ermöglicht die Umsetzung bestimmter Nutzungsrechte, wie eingeschränkte Bearbeitung, Ausfüllen von Formularen oder gesperrtes Drucken. Eine elektronische Unterschrift kann mit dem Programm Adobe Acrobat Sign erstellt werden [13].



### 1.2.2 PDF/X

Speziell für den simpleren Datenaustausch in der Druckvorstufe und der professionellen Druckindustrie wurde PDF/X (Exchange) als ISO 15930:2001 entwickelt. Dieser erst 2001 publizierte Dateiformatstandard beschreibt die speziellen Eigenschaften von Druckvorlagen und vereinfacht die Datenübermittlung von der Design-Agentur und Druckvorstufe bis zum finalen Druck. Besonderen Wert wurde darauf gelegt, dass in offenen Dateiformaten aus Layoutprogrammen keine Informationen über Farbe und Schrift verloren gehen und einer Verfälschung im Druckergebnis vorgebeugt werden kann [14]. Die Entwicklung von PDF/X zielt auf eine Verminderung von Druckfehlern und Mehraufwand in der Druckerei. In der Umsetzung bedeutet das, dass Elemente, die sich nicht sinnvoll drucken lassen, z.B. Video und Audio, nicht berücksichtigt werden. PDF/X-kompatibel bezeichnet die Eigenschaft von Dokumenten, dass sie ohne vorherige Prüfung von der Druckerei direkt verwendet werden können [15].

Beschnitt, Farbangaben und verwendete Schriften sind u.a. für den Druck notwendig und sollten verwendet werden. Qualitätsanforderungen, die sich auf bestimmte Druckverfahren beziehen, sind nicht implementiert, sondern werden abstrakter definiert. Besondere Qualitätsanforderungen liegen vor allem im Zeitungsdruck, Akzidenzdruck oder Bilderdruck vor. Vielmehr geht es bei PDF/X darum, Grundvoraussetzungen für den Druck sicherzustellen, z.B. ob der richtige Farbraum gesetzt wurde oder korrekte Einstellungen für Überdrucken und Überfüllung vorliegen. Neben Aussparen und Unterfüllung werden Überdrucken und Überfüllung zum Oberbegriff Trapping zusammengefasst. Bei der Überfüllung werden bei verschieden farbigen Objekten das hellere Objekt auf dunklem Hintergrund minimal vergrößert, sodass es das dunklere Objekt leicht überlappt. Solche Überlappungen nennt man Traps. Dies beugt weißen Blitzern (Papierweiß scheint durch) beim Druckergebnis vor. Die umgekehrte Vorgehensweise wird bei der Unterfüllung angewendet. Liegt ein dunkles Objekt auf hellem Hintergrund, so wird das helle Objekt an den Rändern zur dunkleren Farbe hin verengt. Vordergrundobjekte stehen in Layout- und Grafikprogrammen standardmäßig auf Aussparen. Dessen Fläche wird im Hintergrund ausgeschnitten, um unerwünschte Farbmischungen zu vermeiden. Im Falle von schwarzen oder sehr dunklem Text auf farbigem Hintergrund sollte man Layoutprogramm diese Vordergrundelemente überdrucken lassen [16]. Generell werden schwarze Schrift oder Linien im Drucker durch 3 oder 4 Farben zusammengesetzt und fehlende Schriften werden häufig durch den Font Courier kompensiert. Im Druck sollten keine verlustlosen Kompressionsalgorithmen für Bilder verwendet werden wie JPEG, da Artefakte auftreten können. Ebenso gibt es keine automatischen Einstellungen für passende Auflösungen von Vollton-, Halbton- oder Strichbildern [15]. Eine Farbe mit 100 % Deckkraft wird als Volltonfarbe bezeichnet. Halbtöne sind Farben mit geringerer Deckkraft [17]. Als Volltonfarben werden auch speziell vorgemischte Druckfarben bezeichnet die anstelle von oder zusätzlich zu den üblichen Prozessdruckfarben in CMYK verwendet werden. Für Volltonfarben ist eine eigene Druckplatte in der Druckmaschine vonnöten [18]. Der CMYK-Farbraum wird im Druck verwendet durch subtraktive Farbmischung mit den Farben Cyan, Magenta, Yellow und Key (Schwarz). Einige Farben können nicht von

CMYK reproduziert werden, dann spricht man von Sonderfarben. Strichbilder sind Bilder mit ausschließlich weißen und schwarzen Partien [19].

Bei allen PDF/X-Dateivarianten außer den Varianten, die ein p enthalten, muss ein Output-Intent im Katalog eingetragen sein. Jede Seite einer PDF/X-Datei muss mindestens die TrimBox oder ArtBox, aber nicht beide gemeinsam, beinhalten. JavaScript bzw. Aktionen, Open Prepress Interface (OPI) Kommentare und Verschlüsselung sind verboten [8].

Es gibt verschiedene Varianten von PDF/X, die jeweils einen verbesserten Farbspielraum ermöglichen.

### PDF/X-1a

PDF/X-1a ist eine Subvariante von PDF/X-1 (Norm ISO 15930-1). In der a-Version sind lediglich CMYK, Graustufen, Schwarz-Weiß (Bitmap) und Sonderfarben möglich und es muss eine Composite-Datei vorliegen. Vorseparierte Dateien sind nicht zulässig. Farben können nicht auf Grundlage von International Color Consortium (ICC) Profilen bei PDF/X-1a definiert werden [8], [15]. Erst seit PDF 1.3 werden ICC-Profile unterstützt, die die Farbeigenschaften, Helligkeit, Weißpunkt, Gammakurve und Farbumfang eines bestimmten Monitors eines spezifischen Geräts beschreiben, sprich ein ICC-Profil definiert wie Farben vom Zielgerät dargestellt werden können. Außerdem wird die Transformation zwischen dem Gerät und dem Profilverbindungsraum Profile Connection Space (PCS) definiert. Dabei gibt es die Variante Eingabeprofile für Kameras oder Scanner und Ausgabeprofile für Monitore oder Drucker. Zweck des ICC-Profils ist möglichst Farbübereinstimmungen zwischen verschiedenen Geräten zu erzielen [20]. Beim PCS handelt es sich um ein neutrales Farbmodell im ICC-Colormanagement, welches den Quellfarbraum mit dem Zielfarbraum verbindet und somit geräteunabhängig ist. Der PCS kann entweder der LAB oder XYZ Farbraum sein [21].

Es können TIFF-, TIFF/IT-, EPS- und Desktop Color Separation (DCS)-Dateien integriert werden. Transparenzen, Ebenen, LZW- und JBIG2-Kompression, Formularfunktionen und interaktive Elemente dürfen nicht verwendet werden bzw. sind nicht implementiert. Dieser Standard wurde von ISO 15930-1:2001 auf ISO 15930-4:2003 überarbeitet. Lediglich in der überarbeiteten Version, die die Version von 2001 ersetzt, werden auch Sonderfarben unterstützt [8], [22].

### PDF/X-2

Die 2. Variante ist als ISO 15930-6:2003 erschienen und bietet die Voraussetzungen zum farbigen Qualitätsdruck wie Farbmanagement, CMYK- und Sonderfarbdaten in beliebiger Kombination. PDF/X-2 hat in der Praxis wegen der Unvollständigkeit der PDF-Datei für den Datenaustausch in der Druckvorstufe keinerlei Relevanz. Dieser Standard wird durch PDF/X-5 vollkommen ersetzt [8], [22].

### PDF/X-3

Zusätzlich erweitert Version 3 als ISO 15930-3:2002 [22] um die Farbräume RGB und LAB, sowie alle ICC-Profile. Möglicherweise wird in der Druckvorstufe der im Dokument eingestellte Farbraum in CMYK umgewandelt. Es findet eine automatische Transparenz- und Ebenenreduzierung statt [15]. Bei der Transparenzreduzierung werden einzelne Bildsegmente in vektorbasierte und gerasterte Bereiche unterteilt, überlappende Bereiche der Transparenzen zerschnitten und auf einer Ebene reduziert [23], [24].

### PDF/X-4

Transparenzen, Ebenen, JPEG2000 und OpenType-Schriften können in dieser PDF/X-Variante als ISO 15930-7:2008 [8], [22] verwendet werden, wodurch sie für das Bedrucken von Textilien besonders gut geeignet ist [15]. Es gibt außerdem die PDF/X-4p (Profil) Variante [8].

### PDF/X-5

PDF/X-5 wurde als ISO 15930-8:2010 als vorletzter Standard des PDF/X-Formats verabschiedet und inkludiert externe Elemente und Multichannel-ICC-Profile [22]. Multichannel-Profile unterstützen mehr als 4 Farbkanäle und können somit für Drucker mit mehr als 4 Druckpatronen eingesetzt werden [25]. Außerdem gibt es die folgenden Varianten: PDF/X-g (external graphic content), PDF/X-pg (external ICC color profiles and external graphical content) und PDF/X-gn (n-colorant ICCprofile) für den mehrfarbigen Verpackungsdruck [8].

### PDF/X-6

Der letzte PDF/X-Standard als Version 6 wurde in ISO 15930-9:2020 offenbart und basiert auf dem PDF 2.0 Standard. In dieser Version sind neben maßgeblichen Neuerungen für die heutigen Print-Anforderungen Lockerungen im Vergleich zu vorherigen PDF/X-Standards eingeführt worden. Die wichtigsten Neuerungen sind Parameter für Tiefenkompensierung, separate Ausgabebedingungen, DPart Metadaten, Informationen zu Sonderfarben im CxF/X-4 Standard und Mixing Hints [22]. Tiefenkompensierung ist eine rechnerische Korrektur und wird bei der Konvertierung eines Farbraums mit großem Tonwertumfang in einen mit kleinem Tonwertumfang angewendet. Dabei soll die ursprüngliche Differenzierung der Tonwerte dunkler Bildteile beibehalten werden können [26]. DPart-Metadaten wurden ursprünglich für den PDF/VT-Standard spezifiziert und ermöglichen mehrteilige PDF-Dateien in Datensätze zu unterteilen. Diese PDF-Dateien können dann automatisch verarbeitet werden [27]. Mixing Hints enthalten Informationen, z.B. wichtig bei Prüfdruck, über erwartete Ergebnisse, wenn mehrere Volltonfarben im Druck miteinander interagieren. Diese Informationen sind

beispielsweise für einen Prüfdruck wissenswert [28].

Zu den Lockerungen zählen die Möglichkeit von Notizen und grafischen Anmerkungen, strukturelle Aktionen, Formularfelder und digitale Signaturen. Außerdem besteht dieser Standard aus 2 Konformitätsstufen: PDF/X-6p zur Referenzierung von ICC-Profilen und PDF/X-6n für Multicolor-Profile [22].

### 1.2.3 PDF/A

Das PDF/A Dateiformat (Archivable) wurde zur gesetzeskonformen Langzeitarchivierung von digitalen Dokumenten entwickelt und solche Dokumente sind zunächst schreibgeschützt. Der ISO-Standard definiert die Konformität der Form von Elementen wie Schriften oder Layout für eine Langzeitarchivierung. Dadurch ist die Lesbarkeit der Dokumente über lange Zeiträume gesichert und die Bedingungen einer revisionssicheren Archivierung gewährleistet [29]. Revisionssichere Archivierung bedeutet, dass gespeicherte Daten vor nachträglichen Modifikationen, Fälschung oder Manipulation geschützt sind [30]. Der Fokus in diesem Dateiformat liegt auf langfristige und einfache Speicherung der PDF-Dateien. Folglich ist die Einbettung von Audio und Video nicht implementiert, aktive Komponenten wie Links, sowie externe Ressourcen wie Grafiken und Schriftarten werden nicht unterstützt, sondern müssen direkt eingebettet werden. Ebenso können Dokumente nicht verschlüsselt werden. Die Einbettung von Metadaten als Extensible Metadata Platform (XMP) wird unterstützt, was die Identifizierung und Suche von Dokumenten erleichtert. Es gibt einige Nachteile von PDF/A. Nicht alle Dokumente können problemlos in dieses Dateiformat umgewandelt werden, wie beispielsweise Dokumente mit Audio, Video oder JavaScript. Nach solch einer Konvertierung zu PDF/A kann es zu Fehlern in der visuellen Darstellung kommen und die Dateigröße kann enorm werden, da alle Elemente direkt eingebettet werden müssen [29].

#### PDF/A-1

Seit der ersten Version von PDF/A ist das Dateiformat in die ISO-Norm als PDF/A-1 in ISO 19005-1:2005 übernommen worden [22]. Die Originalversion stellt sicher, dass alle externen Quellen wie Schriften oder Bilder eingebettet sind, unterstützt digitale Signaturen und Hyperlinks. PDF/A-1 ist abwärtskompatibel. Es gibt 2 Qualitätsebenen von PDF/A-1: PDF/A-1b (Basic) und PDF/A-1a (Accessible). Die Basic Variante legt Wert darauf, dass Dokumente eindeutig visuell reproduzierbar sind und Accessible ist zusätzlich für Barrierefreiheit optimiert. Bei Accessible können Text und inhaltliche Struktur von einem Screenreader durch Tagged PDF vorgelesen werden [29]. Des Weiteren werden, Sprach-Angabe und Unicode-Mappings unterstützt [22].

## PDF/A-2

Im Jahr 2011 wurde die PDF/A-2 Version als ISO 19005-2:2011 auf den Markt gebracht. Sie ermöglicht die Kompression von Grafikformaten mit JPEG-2000, Transparenzen, PDF-Ebenen, Portfolios, Object Level XMP Metadaten, Kommentartypen, Annotationen und digitale Signaturen [22]. PDF/A-1-Dateien können in PDF/A-2-Dateien eingebunden werden. Es gibt 3 Varianten von PDF/A-2: PDF/A-2b (Basic), PDF/A-2u (Unicode-Textsemantik) und PDF/A-2a (Accessible). Basic gewährleistet das unveränderte Erscheinungsbild eines Dokuments und definiert die Mindestanforderungen. Die Unicode-Version ergänzt um Unicode-Unterstützung und Indexierung. Accessible setzt alle Anforderungen der ISO-Norm 19005-2 um [29].

## PDF/A-3

Ein Jahr später wurde PDF/A-3 im Standard ISO-19005-3:2012 veröffentlicht. Er basiert auf PDF 1.7 und ermöglicht die Einbettung dynamischer, zur Laufzeit interpretierbaren Komponenten und Dateiformate. Gleichfalls definiert PDF/A-3 die Konformitätsebenen 3b, 3u und 3a. Die u-Variante bietet eine Vereinfachung in der Durchsuchbarkeit von Texten und das Kopieren von Unicode-Text [22].

## PDF/A-4

Viel später im Jahr 2020 wurde PDF/A-4 als ISO 19005-4:2020 herausgebracht. Dieser Standard basiert auf der PDF 2.0 Dateiversion. Sie spezifiziert 2 neue Konformitätsebenen: PDF/A-4f für nicht-PDF/A konforme Dateianhänge und PDF/A-4e für Einbindung von 3D-Inhalten in den Formaten U3D oder PRC für den Engineering-Bereich [22].

### 1.2.4 PDF/E

PDF/E (Engineering) gilt als international standardisiertes Austauschformat als Norm ISO 24517 für technische Dokumente und wird im Maschinenbau, in der Fertigung und im Baugewerbe für Fertigungspläne, Konstruktionszeichnungen oder technische Dokumentationen verwendet. Das PDF/E Dateiformat von 2008 ist speziell für das Ingenieurwesen entworfen und kann interaktive 3D-Elemente und Animationen darstellen. Im einzelnen können CAD-Dateien im 3D- und 2D-Format eingebettet werden. Die 3D-Elemente können im Dokument ausgeklappt oder gedreht werden. Metadaten und interaktive Funktionen wie Lesezeichen, Formulare oder Hyperlinks werden unterstützt [14].

### 1.2.5 PDF/H

Das PDF/H (Healthcare) Dateiformat soll im Gesundheitswesen Patientendaten erfassen, austauschen und archivieren. Hierbei wird besonders Wert auf die Anforderungen des Datenschutzes in gesundheitsspezifischen Ämtern, Institutionen und Arztpraxen gelegt. PDF/H wurde zwar im Jahr 2008 kreiert, jedoch wurde es nicht in den Normierungsprozess der ISO eingebunden [22]. Es handelt sich eher um eine Best-Practice für die Umstellung von Papiergesundheitsakten auf PDF als e-Akte. Die Digitalisierung soll gesundheitsbezogene Daten strukturieren, verwalten und so präsentieren, dass Forscher\*innen und Beschäftigte im Gesundheitswesen effizienter auf sie zugreifen können.

### 1.2.6 PDF/VT

Basierend auf PDF/X wurde PDF/VT als spezielles Austauschformat im variablen Datendruck (Variable Data) und Transaktionsdruck (Transactional Printing) im Jahr 2010 auf den Markt gebracht [31]. Wiederkehrende Elemente wie Texte, Grafiken oder Bilder sollen effizienter verarbeitet und an den Drucker übertragen werden können [14]. Variabler Datendruck bezeichnet ein digitales Druckverfahren bei dem einzelne Parameter von Printprodukten individuell variiert werden können, wobei das Grundlayout beständig bleibt. Folglich können große Mengen von Printprodukten mit Personalisierung hergestellt werden, z.B. Werbebriefe mit konstanten grafischen Elementen wie Firmenlogos und individuellen Namen der Kund\*innen. Dadurch können Firmen ihr Corporate Identity-Layout behalten und ihre Kund\*innen persönlicher ansprechen. Der Begriff Transaktionsdruck definiert das Drucken von Transaktionsdokumentationen wie Rechnungen, Mahnungen, Lieferscheine oder Quittungen im Waren- und Dienstleistungssektor. Herausstechend ist, dass PDF/VT große Mengen an variablen Daten in einer einzigen PDF-Datei speichern kann, wobei es immer einen Satz von statischen und variablen Daten gibt. Diese Vorgehensweise spart Zeit, Kosten und reduziert Fehler. Vorteilhafterweise werden ICC-Profile unterstützt [31]. Die erste Version als ISO 16612-1:2005 konnte sich auf dem Markt nicht durchsetzen [22].

### PDF/VT-2

Die zweite Version als ISO 16612-2:2010 implementiert die Verwendung externer grafischer Inhalte und das Streamen von mehrteiligen Multipurpose Internet Mail Extension (MIME) Paketen in der Version PDF/VT-2s. MIME-Typen (media types) zeigen Art und Format von Dokumenten, Dateien oder einem Sortiment von Bytes an und sind standardisiert. Ein MIME-Typ besteht üblicherweise immer aus einem durch ein / getrennten Typ und Subtyp. Der Typ repräsentiert die generelle Kategorie des Datentyps und der Subtyp die exakte Datenart des Typs. Jeder Typ hat seine eigene Menge an Subtypen [32]. Zum Lesen von PDF/VT-2 Dokumenten wird ein PDF/X-4- bzw. PDF/X-5- oder PDF/VT-konformer PDF-Reader benötigt [22].

## PDF/VT-3

Spezialisiert auf die Integration von variablen Daten (DPart-Metadaten) und den Transaktionsdruck ist die dritte PDF/VT Variante als ISO 16612-3:2020 [22].

### 1.2.7 PDF/UA

Das PDF/UA (Universal Accessibility) Dateiformat dient der Erstellung barrierefreier Dokumente. Die PDF/UA-Kennzeichnung stellt eine Klassifizierung für barrierefreie Dokumente dar und orientiert sich an den Anforderungen der Web Content Accessibility Guidelines (WCAG) 2.0 des World Wide Web Consortiums. Als Rechtliche Grundlage dient die Barrierefreie-Informationstechnik-Verordnung (BITV) 2.0. Um die Anforderungen der PDF/UA-Kennzeichnung zu erfüllen, müssen Dokumente bestimmte technische und inhaltliche Vorgaben erfüllen. Auf Basis des Matterhorn-Protokolls, welches aus 31 Prüfpunkten und 136 Konformitätskriterien besteht, müssen Aufbau von Texten, Bildern, Listen, Tabellen und Formularefeldern festgelegte Vorgaben erfüllen. Diese Konformitätskriterien können auf der einen Seite nur von einer Software geprüft werden und auf der anderen Seite nur von Menschen.

Menschen mit Einschränkungen sollen das Dokument optimal nutzen können. Zur Erleichterung des Verständnisses sollten Überschriften, alternative Texte für Bilder, Beschreibungen für Tabellen, Tags und eine klare Lesereihenfolge verwendet werden [33]. Es gibt die PDF/UA-1 Version aus ISO 14289-1:2012 und die überarbeitete Version PDF/UA-1 aus ISO 14289-1:2014, die erst 2020 als gültig erklärt wurde [22].

### 1.2.8 PDF/R

Speziell für die Speicherung, den Transport und Austausch von gescannten Dokumenten gibt es das ISO 23504-1:2020 standardisierte Format PDF/R-1. Es bietet die grundsätzlichen Funktionalitäten von TIFF, bitonalen, Graustufen- und Echtfarbbildern [22]. Bitonale Bilder bestehen lediglich aus einer Vordergrund- und Hintergrundfarbe.

### 1.2.9 Searchable PDF

Searchable PDFs können mit Suchfunktionalitäten eines PDF-Readers durchsucht werden. Es kann gezielt nach Zahlen oder Stichwörtern durchsucht und Inhalte können zur Bearbeitung in anderen Programmen kopiert werden. Man erkennt durchsuchbare PDFs daran, dass man den Text markieren kann. Diese PDF-Art wird üblicherweise durch die Optical Character Recognition (OCR) Technologie erstellt. Bei OCR handelt es sich um optische Zeichenerkennung, die Textzeichen und Dokumentstruktur analysiert. Auf diese Weise können gescannte Dokumente oder Pixelbilder als PDF abgespeichert und in ein Durchsuchbares PDF in Acrobat umgewandelt werden. Während der Umwandlung wird

dem Dokument eine zusätzliche unsichtbare Textebene, die unter der Bildebene liegt und durchsuchbar ist, auf der Seite hinzugefügt. In Acrobat ist es außerdem möglich mit der einfachen Suche innerhalb einer Datei nach Suchbegriffen zu suchen, mit der erweiterten Suche oder der Suchen-Werkzeugleiste mehrere PDF-Dokumente zu durchsuchen und speziell in der erweiterten Suche u.a. Objektdaten und Bildern zu lokalisieren. Textbasierte PDF-Dateien können grundsätzlich durchsucht werden und auch in andere Dateiformate wie Microsoft Word, Excel oder PowerPoint umgewandelt werden. Durchsuchbare PDFs ermöglichen Barrierefreiheit. Sie können von Bildschirmleseprogrammen für Sehbehinderte vorgelesen oder vergrößert werden[34].

## 1.3 PDF Dateiversionen

Gestartet mit Version 1.0 war PDF lediglich ein proprietäres Dateiformat von Adobe. Die Freigabe von PDF als offenes und kostenlose Dateiformat führte letztendlich erst zu seiner weltweiten Verbreitung und Anerkennung. Erst im Jahr 2005 entwickelte sich Version 1.4 zu einem internationalen ISO Standard. Die letzte Dateiversion 2.0 von 2017 ist schon eine Weile her und es hat sich zeitlich nur das PDF/R-Dateiformat später entwickelt als PDF 2.0.

### 1.3.1 PDF 1.0

PDF 1.0 wurde 1992/1993 entwickelt und ist wurde nicht normiert. 1992 wurde die Spezifikation als Buch verkauft und 1993 das der Spezifikation entsprechende digitale Format entwickelt, welches ausschließlich den RGB Farbraum darstellen konnte. Medien, die einen anderen Farbraum besitzen wurden in RGB konvertiert. In der Druckindustrie ist jedoch der CMYK-Farbraum von Bedeutung. Folglich ist PDF 1.0 nicht für den Printbereich geeignet. Damals war Adoba Acrobat 1.0 das einzige Programm mit dem man diese Dateiversion bearbeiten konnte [22].

### 1.3.2 PDF 1.1

Genauso ist das 1994 kreierte PDF 1.1 keine Norm und implementiert weiterhin nur den RGB Farbraum, jedoch geräteunabhängig. Zusätzlich benötigte man ein Update von Adobe Acrobat auf Version 2.0. Erstmals sind in diesem Format das Einbetten von Hyperlinks optional gebunden an Aktionen, mehrseitige Artikel und Threads, Passwortverschlüsselung und Notizen bzw. Anmerkungen erschienen [22]. Hier kann man bereits Benutzungseinschränkungen geltend machen, wie Schutz vor unerlaubtem Öffnen des PDF-Dokuments, das Sperren von Teilfunktionen, z.B. Entnahme von Texten und Bildern, sowie verbotenes Drucken. Verschlüsselt wird mit einer 40-Bit-Schlüssellänge durch den RC4-Algorithmus. TrueType-Fonts können nativ eingebettet werden und einige geräteunabhängige, d.h. Commission Internationale de l'Éclairage (CIE) basierte Farbräume, können eingestellt werden



[8]. Die Internationale Beleuchtungskommission mit der Abkürzung CIE ist eine unabhängige Non-Profit-Organisation für Licht, Beleuchtung, Farbe und Farbräume. Sie entwickelt und publiziert hierzu Standards und Messverfahren [35], [36]. Binäre Abspeicherung der PDF-Datei ist nun möglich, womit eine Reduktion der Dateigröße um 25 % erreicht werden kann [8].

### 1.3.3 PDF 1.2

Fast alle für die Druckvorstufe nötigen Parameter aus PostScript wurden in Version 1.2 umgesetzt. Das 1996 erschienene PDF 1.2 wurde ebenfalls nicht standardisiert, jedoch ermöglichte es erstmals den druckbaren CMYK-Farbraum und Sonderfarben zu verwenden. Des weiteren wurden interaktive Formularfunktionen, Unicode, Unterstützung der OPI 1.3 Spezifikationen und eine Druckrasterfunktion implementiert[22]. OPI ist ein Workflow Protokoll, welches in der elektronischen Druckvorstufe verwendet werden kann, um Desktop Publishing Systeme und high-end Cisco Enterprise Print System (CEPS) zu verknüpfen und optimiert die Übertragung von hochauflösenden Dateien in Netzwerken [37]. In PDF 1.2 wurden erstmalig AcroForms vorgestellt. Zusätzlich ist das Abspielen von Video und Audio ausschließlich als Link zu einer externen Datei möglich. Composite-Fonts, CID-Fonts und alle CIE-basierte Farbräume werden unterstützt [8].

### 1.3.4 PDF 1.3

1999 wurde PDF 1.3 mit fehlender Normierung auf den Markt gebracht und trug seinen Teil 2001 und 2002 bei zur Standardisierung des ISO PDF/X Standards. Es ist kompatibel mit PostScript 3 und bietet die Neuerungen der 2-Byte CID Schrifttypen, OPI 2.0 Unterstützung, Farbraumerweiterung um Sonderfarben durch ICC-Profile und den DeviceN-Farbraum, weiche Schatten und Farbübergänge bzw. Verläufe in einem auflösungsunabhängigen Modus (Smooth Shading), digitale Signaturen, RC4-Verschlüsselung (40 Bit in Acrobat 4 und 56 Bit in Acrobat 4.05) und JavaScript [8], [22].

Der DeviceN-Farbraum wird auch in PostScript 3 unterstützt und erlaubt die willkürliche Kombinationen von Farbkanälen beim Composite-Druck. Dokumente mit Schmuckfarben müssen auf einem Gerät mit physikalisch getrennten Kanälen für jede verwendete Schmuckfarbe ausgegeben werden. Schmuckfarben sind festgelegte Farbtöne, die nicht aus Prozessfarben gemischt werden. Sie können Kosten sparen und vermeiden Farbschwankungen. Besonders verbreitet sind HKS und Pantone [16]. Folglich kann kein CMYK- oder RGB-Gerät Dokumente mit Schmuckfarben farblich korrekt darstellen. Davon sind fast alle Farbdruckersysteme betroffen, sowie die von Adobe Acrobat erzeugte Bildschirmdarstellung von PDF Dokumenten mit Schmuckfarben. Ohne den DeviceN Farbraum können Bilder mit Kombinationen von z.B. CMYK und 2 Schmuckfarben oder Schwarz und eine Schmuckfarbe nicht im Composite-PostScript und Composite-PDF wiedergegeben werden, sondern höchstens mit CMYK als Näherung [38]. Dateianlagen jeglichen Typs können in Form von Streams im Body direkt eingebettet werden. Folglich kann eine PDF-Datei

containerisiert werden. 3 weitere Boxen werden dem PDF-Format hinzugefügt: TrimBox, BleedBox und ArtBox. Für Überfüllungen in der Druckvorstufe können Traps als form XObject gespeichert werden. Bilder können auf Basis von Image XObjects für komplexere Pfadresultate maskiert werden. Eine Maske kann Sektionen eines Bildes ausblenden ohne diese zu löschen [8].

### 1.3.5 PDF 1.5

Im Jahr 2003 kam PDF 1.5 auf den Markt und hat sich nicht zur Norm entwickelt. In dieser Version wurden erstmals Ebenen und 16-Bit-Farbtiefe in eingebetteten Bildern implementiert. Des Weiteren wurden gesteigerte Kompressionstechniken einschließlich Objekt-Streams und JPEG2000-Kompression, sowie eine verbesserte Cross-Reference Tabelle und XRef-Streams implementiert. 12 weitere Seitenübergänge für Präsentationen, verbesserte Unterstützung für Tagged PDF und die Adobe proprietäre Technologie XFA wurden außerdem hinzugefügt [8], [22].

### 1.3.6 PDF 1.4

Der erste PDF ISO-Standard ISO 16612-1:2005 wurde zeitlich nach Version 1.5 verabschiedet. In diesem Format sind Transparenzen, JavaScript 1.5, bessere Integration von Datenbanken, Titel, Textblockdefinition, JBIG2-Komprimierung und 128-Bit-RC4-Verschlüsselung erstmalig integriert worden[22]. Außerdem wurde die Kennzeichnung der Ausgabeabsicht über den Output-Intent mit einer Kompatibilität zu Version 1.3 implementiert [8].

### 1.3.7 PDF 1.6

In diesem ISO 15930-8:2008 Standard sind erstmals folgende Technologien in diesem Format eingeführt worden: NChannel-Farbraum, welches eine Erweiterung von NDevice mit Sonderfarben bzw. Schmuckfarben ist, JPEG 2000-Kompression, Advanced Encryption Standard (AES) Verschlüsselung, direkte Einbettung von OpenType-Schriften, 3D-Daten (U3D) und XML Formulare [22].

### 1.3.8 PDF 1.7

Veröffentlichung am 1. Juli 2008 ist PDF in Version 1.7 als ISO 32000-1:2008 als Offener Standard definiert worden. Es wurden komplexer 3D-Objekte, Kontrolle über 3D-Animationen und Einbettung von Standard-Druckeinstellungen wie Papierauswahl, Anzahl der Kopien und Skalierung hinzugefügt[22].

### 1.3.9 PDF 2.0

XFA ist in PDF 2.0 als ISO 32000-2:2020 vom ISO-Gremium als veraltet markiert worden. Mehr Einstellungsmöglichkeiten und Funktionen sind diesem Format beigelegt worden: Erweiterte Definitionen der Halbtöne der Rasterung, z.B. für Flex- oder Tiefdruck, konsistente Transparenz, erweiterte Tagged-PDF Funktion für Barrierefreiheit, Definition von Sonderfarben über Spektralfarben, alternierende Reihenfolge der zu druckenden Farben, Steuerung der Schwarzpunktkompensation, AES-256-Bit-Verschlüsselung, DPart-Metadaten und Einbettung von 3D-Messungen oder Querschnittsdaten [22]. Spektralfarben bezeichnen die Regenbogenfarben, die entstehen, wenn weißes Licht durch ein Prisma gebrochen wird. Schwarzpunktkompensation stammt begrifflich aus der Bildverarbeitung. Bei diesem Prozess wird der Schwarzwert eines Bildes so angepasst, dass die Darstellung von dunkleren Bereichen verbessert wird. Ist der Schwarzwert falsch eingestellt, so können dunkle Bildbereiche grau oder „ausgewaschen“ erscheinen, was zu einer Reduktion an Detail und Kontrast führt [39].

## 1.4 PDF Implementierung

PDF ist eine vektorbasierte Page Description Language (PDL) (Seitenbeschreibungssprache) und basiert auf dem PostScript-Format. Der MIME-Type von PDF heißt `application/pdf`. Eine PDL beschreibt den Seitenaufbau, wie die Seite in einem Ausgabeprogramm bzw. Ausgabegerät, z.B. einem Drucker, aussehen soll. PDLs können Seiten mit Vektoren beschreiben. An den Drucker wird durch die PDL ein Datenstrom der zu druckenden Ausgabe erzeugt und an den Drucker gesendet. Der Raster Image Processor (RIP) eines Druckers wandelt die Bildschirmausgabe in die gerasterte Druckerausgabe um. Viele APIs der Hardwareabstraktionsschicht im Computer wie Graphics Device Interface (GDI) oder OpenGL können in PDL ausgeben. Speichert ein Satzprogramm den Seitenbeschreibungscode eines Dokuments in einer Datei, müssen Drucker die PDL nicht selbst verarbeiten. Eine PostScript Printer Description (PPD) Druckerbeschreibungsdatei definiert Fonts, Papiergröße, Auflösung und andere Standardeigenschaften für einen bestimmten PostScript-Drucker [40]. Im Common Unix Printing System, der Standard-Druckersteuerung von Linux hat der PostScript und der PDF-Interpreter `ghostscript` die Aufgabe eines RIP, d.h. er ist für die Umwandlung in die gerasterte Druckerausgabe auf dem Drucker zuständig. Zudem stellen PDLs eine Schnittstelle zum Quellcode eines Dokuments bzw. zu Programmen, die Quellcode verwalten oder das Dokument formatieren können, dar. Die PDL PDF erweitert die Funktionalität von PostScript um anklickbare Links (Hypertextfunktionalität), die die Navigation im Dokument erleichtern und URLs, die sich automatisch im Browser öffnen [41].

### 1.4.1 PostScript

Sowohl die PostScript als auch PDF haben zum Ziel die Seiten eines Dokuments vollständig für die Ausgabe in der Druckvorstufe zu beschreiben. Die abwärtskompatible, stackorientierte, Turning-vollständige Hochsprache PostScript als PDL wurde in den 1980er Jahren von Adobe erfunden [42], [43]. Hinzu wurden weitere PostScript-Technologien entwickelt, die aus der Programmiersprache PostScript, Grafik-, Textformatierungsanwendungen, Treibern und Abbildungssystemen bestehen. PostScript hat sich als Industriestandard etabliert. Die letzte Version ist PostScript 3 von 1997. Seine primäre Anwendung gemäß des Adobe Imaging Models findet sich in der Beschreibung von Textdarstellung, graphische Formen und Bildern auf gedruckten oder auf dem Bildschirm angezeigten Seiten. Dabei ist die Beschreibung des Dokuments geräteunabhängig und eine PostScript-Datei ist sequentiell organisiert. PostScript unterstützt unter anderem beliebige geometrische Formen, Zeichenoperationen in Graustufen, RGB, CMYK und CIE (Yxy-Farbraum), vorinstallierte oder benutzerdefinierte Fonts, Digitalbilder jeglicher Auflösung je nach Farbmodell und ein allgemeines Koordinatensystem.

In PostScript wird eine Seite, die ein Koordinatensystem umspannt, als Grafik betrachtet, die verschiedene Grafikelemente enthalten kann. Dabei werden die Textzeichen eines Fonts, gemäß des Adobe Imaging Models, als graphische Formen betrachtet auf denen Grafikoperationen möglich sind. Das Koordinatensystem unterstützt alle linearen Transformationen, die auf alle Seitenelemente angewandt werden können. Die Seitenbeschreibung in PostScript kann auf jedem Gerät, was einen PostScript-Interpreter implementiert, gerendert werden. In diesem Prozess wird die high-level PostScript-Beschreibung in low-level Rasterdatenformate für das jeweilige Gerät übersetzt. Jede PostScript-Datei muss durch einen RIP interpretiert und die Dateien können in American Standard Code for Information Interchange (ASCII) vorliegen [42]. Der PostScript-Interpreter als RIP rechnet die Benutzerkoordinaten in Gerätetapixel um, wobei auch die technischen Eckdaten des jeweiligen Geräts mitberücksichtigt werden. Theoretisch kann derselbe PostScript-Code auf verschiedenen Endgeräten mit unterschiedlicher Auflösung eine mehr oder weniger identische Ausgaben erreichen. Den Interpreter gab es früher als Hardware-RIP, der allerdings nicht mehr zum Einsatz kommt. Heute gibt es lediglich Software-RIPs, die von einem Betriebssystem kontrolliert werden und hardwareunabhängig arbeiten. Fast alle RIP-Hersteller orientieren sich am Standard und somit sind PostScript-Fehler in der Druckvorstufe minimiert worden [8].

### 1.4.2 Adobe Imaging Model

PDF und die PostScript Programmiersprache haben das Adobe Imaging Model als Gemeinsamkeit. Es kann nahtlos zwischen PDF und PostScript konvertiert werden und beide erzielen das gleiche Ausgabeergebnis beim Druck. Dennoch fehlt PDF das general-purpose Framework der PostScript Programmiersprache. Stattdessen stellt ein PDF Dokument eine statische Datenstruktur optimiert für den random-access auf beliebigen Seiten dar und enthält zusätzlich Seitennavigationsinformationen für interaktives Lesen. Im Kontrast dazu

sind PostScript-Dateien seriell organisiert.

Das high-level Imaging Model beschreibt die Elemente, die auf der Seite dargestellt werden, also Text, Geometrie oder Vektorgrafiken, als abstrakte graphische Elemente aus Vektorobjekten und Bézierkurven, anstatt als Pixeldefinitionen. Pfad-Objekte werden durch verbundenen Punkten, Linien und Kurven mathematisch berechnet. Text-Objekte bilden eine eigene Datenstruktur (Fonts), die als Glyphen aus Pfad-Objekten bestehen. Bild-Objekte sind aus einzelnen Pixelwerten in einer rechteckigen Fläche aufgebaut und enthalten eine eindeutige Position im Rechteck und einen Farbwert. Die abstrakte Beschreibung graphischer Elemente macht das Imaging Model zu einem geräteunabhängigen Modell und es kann hochwertige Ausgaben auf vielen verschiedenen Druckern und Bildschirmen liefern.

Eine Anwendung generiert zuerst die geräteunabhängige Beschreibung des gewünschten Ausgabegeräts in der PDL. Daraufhin interpretiert eine Firmware oder Software eines spezifischen Ausgabegeräts für Rasterausgaben die Beschreibung und rendert sie im Ausgabegerät. Hierbei hat die PDL die Rolle eines Austauschstandards für die Übertragung und Speicherung von druckbaren oder auf Displays darstellbaren Dokumenten [42]. Die Flexibilität des Adobe Imaging Models zeichnet sich durch seine flexible Ausgabefähigkeit auf jeglichen Rastergeräten und hochauflösenden Displays. Die Größe des Pixels wird durch die Ausgabeauflösung des Rastergeräts bestimmt, die bei Monitoren zwischen 75 und 110 Pixels per inch (ppi) und bei Tintentstrahl- bzw. Laserdruckern zwischen 300 und 1400 ppi liegt.

Später wurde das Imaging Model für die Unterstützung von Transparenzen erweitert. Diese Funktionalität wurde speziell für PDF implementiert und wird nicht von PostScript unterstützt. Bei PostScript überschreibt das zuletzt gezeichnete Objekt alle darunterliegenden Objekte im Hintergrund [8].

### 1.4.3 Dateiformataufbau

PDF ist ein reines objektbasiertes Dateiformat und PDF-Dateien enthalten Dokumentdaten in binärer Form. PDF-Dateien bestehen aus Sequenzen von 8-Bit-Binärdaten bzw. 7-Bit-ASCII [8]. Ein Dokument entspricht immer einer Datei. Das Einbetten von binären Dateien in beliebigen Formaten oder anderer PDF-Dateien ist möglich.

Die Struktur besteht im Wesentlichen aus 4 Komponenten. Zunächst spezifiziert der Header die Version der PDF-Spezifikation (Signature) und den Charset Identifier [44]. Zwei Beispiele eines Headers sind in den Abbildungen 1.3 und 1.4 gezeigt. Der Body enthält die Daten der Objekte, aus denen das Dokument besteht. Objekte im Body sind in einer komplizierten hierarchischen Struktur, dem Dokument, verknüpft. Zur Dateigrößenoptimierung werden komplexe Verbindungen zwischen den Daten hergestellt und die Daten eines mehrfach vorkommenden Objektes müssen nur einmal gespeichert werden [10]. Jedes Objekt wird im Body mit obj und endobject eingekapselt und jeder Stream mit stream und endstream [8]. Eine Beispielabbildung 1.5 ist weiter unten zu sehen. Die Cross-Reference Table (Xref) deckt die Informationen über die Position der indirekten Objekte in der Datei ab. Liegt ein

Verweis auf ein Objekt in der Xref, so kann es für andere Seiten wiederverwendet werden. In Xref sind alle Informationen für den random-access eingetragen. Neben Objekteinträgen können auch Cross-Reference-Streams hinterlegt werden. Xref ist der einzige Teil in PDF mit einem konstanten Format und kann aus mehreren Cross-Reference-Sections und Subsections jeweils mit Objekteinträgen für das inkrementelle Update bestehen. Ein Objekteintrag ist wie folgt aufgebaut: Die ersten 10 Bytes für die Byteposition (Offset), mit Leerzeichen als 1 Byte getrennt, die folgenden 5 Bytes für die eindeutige Generation Number und zuletzt eine ebenfalls durch ein Leerzeichen getrennte Markierung mit f oder n. f steht für free entry, d.h. gelöschttes Objekt, und n für in use entry. Das erste Objekt in Xref hat eine Generation Number von 0 und wird nicht verwendet. Eine beispielhafte Xref ist in einer Abbildung 1.6 gezeigt. Zuletzt definiert der Trailer die Startposition der Cross-Reference Table als Pointer startxref und von speziellen Objekten im Body [45]. Außerdem enthält der Trailer die ID der PDF-Datei, einen Size Entry, Metadaten und eine Referenz zum /Root Objekt (Katalog) im Body. Abschließend markiert %%EOF das Dateende [44], [45]. Zwei Trailerbeispiele sind in Abbildungen 1.7 und 1.8 dargestellt.

Beim inkrementellen Update wird am Ende der Original-Trailers ein Body Update, eine neue Xref-Section und ein Updated Trailer der Datei hinzugefügt. In der neuen Version der Xref-Section werden alle Objekte aufgeführt, die gelöscht, geändert oder ersetzt wurden. Der Updated Trailer umfasst alle Änderungen bezüglich des originalen Trailers [8].

PDF-Viewer prozessieren PDF-Dateien im Prinzip vom Ende bis zum Anfang, d.h. vom Trailer zum Body[45]. Beim Parsen wird zunächst die Signature überprüft, dann wird die Position von %%EOF und startxref gesucht, was die Position der Xref angibt. Die Xref stellt die Offsets jedes Objektes zur Verfügung und der Trailer zeigt auf den /Root Entry des Root-Objekts. Nachfolgend werden alle Objekte geparkt und überprüft, ob /Root den /Pages Entry, /Pages ein Seiten-Array, jede /Page eine Größe der /MediaBox hat, /Contents als Stream-Objekt vorliegt und /Resources das /Font dictionary definiert. Zuletzt wird die Seite gerendert durch BeginText, Auswahl des Fonts, Bewegung des Cursors, Anzeigen des Strings und EndText [44]. Referenzen werden nicht in der parse time ausgewertet, sondern nur nach Verwendung [46].

Seitenobjekte und die meisten PDF-Strukturen sind gerichtete azyklische Graphen [46]. PDF-Objekte können in den folgenden Typen vorliegen: Booleans, Integers oder reelle Zahlen, Strings, Namen, die mit einem / Zeichen beginnen, Arrays, Dictionaries, Streams, Null Objekt oder Kommentare mit einem vorangestellten %. Strings können als <Length> <string> oder <string> <terminating symbol> definiert werden. Dictionary Objekte sind als ein Paar von Objekten, genannt Entries, implementiert. Aktionen werden beispielsweise als Entries gespeichert [47].

Text in AcroForms wird als Stream gespeichert. In Streams kann alles gespeichert werden und sie werden nicht interpretiert. Die Objekte in Streams können Referenzen auf andere Objekte vor allem Seiten enthalten [45]. Objekte können so gruppiert werden, wodurch eine

bessere Komprimierung erreicht wird, vor allem bei der Gruppierung von Linien [8].

Es gibt graphics state-Operatoren, die eine Datenstruktur, genannt graphics state, manipulieren. Graphics state ist ein globales Framework mit dem andere Grafikoperatoren ausgeführt werden. Es enthält die aktuelle Transformationsmatrix (CTM), welche die Benutzerortskoordinaten in Ausgabegerätekoordinaten mappt, die aktuelle Farbe, den aktuellen Clipping Pfad und andere Parameter, die implizite Operanden von Zeichenoperatoren sind. Außerdem gibt es noch Pfaderstellungsoperatoren, Pfadzeichenoperatoren und Textoperatoren. Zusätzlich werden marked-content Operatoren für den Dokumentenaustausch verwendet[48] .

Grundsätzlich besteht eine PDF-Datei aus 5 Seitenrahmen als Boxen für jede Seite. Diese Boxen werden weder gedruckt, noch standardmäßig angezeigt. Die äußerste und größte Box ist die MediaBox. Sie entspricht der physischen Größe des Mediums und dem Papierformat. Sie muss immer in einer PDF-Datei vorhanden sein und enthält auch alle Objekte, die über den Rand der Seitengröße hinausragen, wobei diese über die MediaBox gehen können. Innerhalb der MediaBox liegt als nächste Box die CropBox. Sie entsteht durch das Beschneiden der Seite und definiert den Ausschnitt zur Anzeige in Acrobat. Zusätzlich wird sie meist zum Platzieren von PDF-Dokumenten in anderen Programmen und zum Ausdrucken aus Acrobat verwendet. Beim Erstellen der PDF-Datei hat die CropBox die Größe der MediaBox und ist immer vorhanden. Darunter liegt die BleedBox. Sie definiert die Beschnittzugabe, die in der Praxis meist auf 3 mm gesetzt wird. Beschnittzugabe wird in der Druckvorstufe verwendet, damit keine weißen Blitzer am Rand des beschnittenen Druckbogens zu sehen sind. Die optionale BleedBox sollte kleiner als die MediaBox sein. Druckmarken wie Passkreuze, Schnittmarken oder Farbbalken sollten immer außerhalb der BleedBox liegen. Die TrimBox steht für die finale Größe des gedruckten und zugeschnittenen Dokuments. Ein zu druckendes Dokument benötigt zwingend die im PDF-Dateiformat optionale TrimBox, deren Größe kleiner oder gleich der BleedBox und MediaBox sein sollte. Der Standardwert für die TrimBox ist die Größe der CropBox. Ganz innen im Boxmodell von PDF liegt die ArtBox. Sie stellt einen Rahmen um alle druckbaren Objekte dar und legt somit den Inhalt fest. Meist sind ArtBox und TrimBox von der Größe her identisch. Im Bezug auf PDF/X-Dateien darf nur entweder die ArtBox oder die TrimBox vorhanden sein. Da die ArtBox optional ist, dient sie vor allem in Ausschussprogrammen als Default-Box, falls keine TrimBox angelegt wurde. Abbildung 1.2 zeigt eine Grafik des verschachtelten Box-Modells der PDF-Boxen.

Erstellt man eine PDF-Datei muss man zwischen composite oder separiert wählen. Bei einer separierten Ausgabe gibt es für jeden Farbauszug bei CMYK inklusive aller Sonderfarben einen eigenen Farbauszug. Inhalte einer Composite-PDF-Datei können einfach verändert werden. Farbsimulationen und die Nutzung der Überdruckvorschau sind in einem separierten PDF-Dokument nicht mehr möglich. Separierte PDF-Dateien sind nicht medienneutral, da eine Farbverrechnung bei der Separation erfolgt. Überfüllung bleibt im Composite-PDF nicht erhalten, jedoch Überdrucken und Aussparen. In modernen Workflows der Druckindustrie hat man sich vom separierten Workflow abgewendet.




Abbildung 1.2 verschachtelte PDF-Boxen [2]

Eine PDF-Datei besitzt 3 verschiedene Layers, womit nicht die Optional Content Layers gemeint sind. Zunächst enthält die Content Layer alle druckbaren Objekte, sprich Grafiken, Bilder und Texte. Elemente dieses Layers können ausschließlich mit Acrobat Pro bearbeitet werden. Oberhalb der Content-Layer liegt die Enhancement Layer. In ihr sind Lesezeichen, Hyperlinks, Thumbnails, digitale Signaturen, Annotationen, Formularfelder und alle Multimedia-Elemente wie Video und Audio abgelegt. Die unsichtbare Information Layer umfasst alle Basisinformationen zu Schriftdaten, Formularfeldinhalten, Verschlüsselungsinformationen, Querverweistabellen und PDF-spezifische Informationen [8].

PDF-Layouts können in linear oder nicht linearer Form aufgebaut sein. Nicht lineare PDFs sind kleiner, aber langsamer und die Seiten sind in der Datei an verschiedenen Stellen. Lineare PDFs sind für den Online-Bereich vorgesehen und werden auf die Festplatte in einer linearen Art und Weise gespeichert. Online-PDF-Viewer können somit die Datei schon anzeigen bevor sie komplett geladen wurde [48].



```

1 %PDF-1.7
2 %îÊÛ
3 1 0 obj
4 <<
5 /Metadata 4 0 R
6 /PageLayout /OneColumn
7 /PageMode /UseNone
8 /Pages 2 0 R
9 /Type /Catalog
10 >>
11 endobj
12 2 0 obj
13 <<
14 /Count 6
15 /Kids [ 6 0 R 34 0 R 37 0 R 40 0 R 53 0 R 65 0 R ]
16 /Type /Pages
17 >>
18 endobj
19 3 0 obj
20 <<
21 /CreationDate (D:20220629125956+00'00')
22 /ModDate (D:20220629125956+00'00')
23 /Producer
24 (py\000A\000s\000c\000e\000n\000s\000i\000o\000\040\000s\000y\000s\000t\000e\000m\000
25 \040\000S\000I\000A\000\040\000C\000o\000p\000y\000r\000i\000g\000h\000t\000\040\000\
26 050\000c\000\051\000\040\0002\0000\0001\0008)
27 >>
28 endobj
29 4 0 obj
30 <<
31 /Length 5 0 R
32 /Subtype /XML
33 /Type /Metadata
34 >>
35 stream
36 <?xpacket begin="ï¿" id="W5M0MpCehiHzreSzNTczkc9d"?>
37 <x:xmpmeta xmlns:x="adobe:ns:meta/" x:xmptk="3.1-701">
38 <rdf:RDF xmlns:rdf="http://www.w3.org/1999/02/22-rdf-syntax-ns#"
39 <rdf:Description rdf:about="" xmlns:pdf="http://ns.adobe.com/pdf/1.3/">
40 <pdf:Producer>Ascensio System SIA Copyright (c) 2018</pdf:Producer>
41 </rdf:Description>
42 <rdf:Description rdf:about="" xmlns:xmp="http://ns.adobe.com/xap/1.0/">
43 <xmp:CreatorTool>ONLYOFFICE</xmp:CreatorTool>
44 <xmp:CreateDate>2022-06-29T12:59:56+00:00</xmp:CreateDate><xmp:ModifyDate>2022-06-29T
45 12:59:56+00:00</xmp:ModifyDate></rdf:Description>
46 </rdf:RDF>
47 </x:xmpmeta><?xpacket end="w"?>
48 endstream
49 endobj
50 5 0 obj
51 629
52 endobj
53 6 0 obj
54 <<
55 /Contents 7 0 R
56 /MediaBox [ 0 0 595.29999 841.90002 ]
57 /Parent 2 0 R
58 /Resources <<
59 /ExtGState <<
60 /E98 27 0 R
61 >>
62 /Font <<
63 /F1 9 0 R
64 /F2 18 0 R
65 >>
66 /Pattern <<
67 /P1 32 0 R
68 >>
69 /ProcSet [ /PDF /Text /ImageB /ImageC /ImageI ]
70 >>
71 /Type /Page
72 >>
73 endobj
74 7 0 obj
75 <<
76 /Filter [ /FlateDecode ]
77 /Length 8 0 R
78 >>
79 stream
80 xœ4ZY< $É
81 ~- QDf sBRœ0P3TUW6SCôEG;PM?i×fÜYXI,y4NAKŠ#NAK'™ÝÖ,x†j*â' Bútfpz*%ž>4âPMâuúâÉ' (SvX
82 Ú çø(êLç×037>PScââEùô'âŠgÂ*ôÉ†,8EiO(04> yé_e-038?ôâÉ, )BSyôôçñÇ"30Bž
83 ôEùD3e|âO*(EhBVBp\ùsâİs~ùâ N/>:côu4zeU;A<u"+8C@'H•E+uBpó\6Y4*°ô2MueôôôôéTTE;ÝDPS

```

Abbildung 1.3 Header und Beginn eines Bodys des PDF-Dateiformats in Notepad++

```

1 %PDF-1.5
2 %µµµµ
3 1 0 obj
4 <</Type/Catalog/Pages 2 0 R/Lang(de-DE) /StructTreeRoot 35 0 R/MarkInfo<</Marked
5 true>>>>
6 endobj
7 2 0 obj
8 <</Type/Pages/Count 2/Kids[ 3 0 R 25 0 R] >>
9 endobj
10 3 0 obj
11 <</Type/Page/Parent 2 0 R/Resources<</Font<</F1 5 0 R/F2 7 0 R/F3 9 0 R/F4 11 0 R/F5
12 13 0 R/F6 18 0 R/F7 23 0 R>>/ProcSet[/PDF/Text/ImageB/ImageC/ImageI] >>/MediaBox[ 0
13 0 595.32 841.92] /Contents 4 0
14 R/Group<</Type/Group/S/Transparency/CS/DeviceRGB>>/Tabs/S/StructParents 0>>
15 endobj
16 4 0 obj
17 <</Filter/FlateDecode/Length 8365>>
18 stream
19 xœi|Ü8~*StÿAG{ 'VDYNAKEOTya4U=SOHFvrsÄif/*mpjœmÿY;ý[SI0/ù
20 ó"+Ä*c10"mEb"€EOMRVA3
21 É'SUAbñeÉ: Lf5{puE°2iVÜœyüð0*œ*7y|ún-IÜ0i'E*œÜ0"/ñ,4z034úœNówœZBSG
22 *ç8BA?i,0rœÜ+âyâ~>ç\Ÿ.,2iUS?úy0ýœEUSMEWNéVRSZjñ?/Çœ0WL|U"">œŠ'RS'E1F34z;àÇS4?4p84
23 F'q<ZÑ"xUFWBES,;RC2dä*40x 9É>bðñE.),hBAUÇAN;N°Ç0I,ÖiZ00œ*œ=ýRSúœ)*USB0W US
24 <EzÄZ0*SYN$4s0q1*SU0B,VA iÉCSGÄ*+œZ,SI0CSñfçVWœ||VA3B10ir/u0œ|yvá
25 AC<|œy<E*Y)çÄ{;xFWX0°US:~BZUSçZÜLLYRSFœY0A° œ!œüHyM24çZ'ä+0"qHFSUNUFWX
26 Ø~>c10œçRC4?B10>.kSOHYli:*(Iw<DRI):f|/rúpyÜMÇN60œwtœRC9óy;A1W6
27 ACBéFBE$7M0dVWx=NAK;EM~dY^~+íPDC3ää;SYN1Y<yÄAC0>àSOHd"#NSURIA36=Ç+6iiÄK,sei0F
28 œ(f3US:~B<0Ä*dÜ0Ag? Y+St=RAÄ-DBœGouçQ0ü7ÜÄ+RC2p2BSOHSWYIZ+~wÜD03
29 +ÄÄ~>çEWS|:äei+~B ...FZRC3;CS5zm...{BNC0*pÄYStXZ, wu0EýBONÄ*œaoA/*sNUU~"iVBM
30 |s+st-ñi|2FWXU'CS10SIUS

```

Abbildung 1.4 Header, Beginn eines Bodys mit Katalog und Binärdaten des PDF-Dateiformats in Notepad++

```

313 CùAq;oeA8SCgcEiupA1Qú-0*-3SYNa\A8E0f\USE3FWXf\03f0æzúCQWx\o\afds$!...l00)UWBVB
314 ç\!15E>C\US$1:y:šA1\8S8W+<-ç"æQqioæM\8U8çka\PC8ÉbsG,"BNO=GANŠØ~--0ÙeÉEvpa\8S
315 Y0úwí<3æã\øBE=i</Z\A4p\8WB?0D:jo<i<V8/0n°NABç gAŠJeqUS=-Gfñ PCABç
316 0æfúV0I.JE0}be?+ñ)Z)æE8Sç0!>m*U^C8SnR+·IYofU«2s;\8WxH0"·SUB
317 Agðæ8Wúwifæ~T21(....+*d",\08S~0æxm'000100w-áv,yI0Y08{#ç|Þ-B8{çCÅ=8RS
318 L'VuEYvU-Xu~>xiPa·pnV8\088Y2Záç=HP6'8nA\I'DIæ=ç;L0'ày}io'áf\08fU08{ñ+>s\0AB0æ0\08
319 I·u0Hh=rc4'8WB8SUBkoey8W9<'\0CANoy'Þ;æU'U-wBNO?00A006E[ExwYfYfYwY8WY+Þ8Cf
320
321 endstream
322 433 0 obj
323 [
324   228 0 0 0 0 0 0 273 273 0 479 228 273 228 228 456 456 456 456 456 456 456
325   456 456 228 0 0 479 479 456 0 547 547 0 592 547 501 638 592 228 0 547 456 683 0 638
326   547 638 592 547 501 592 547 774 547 547 501 0 0 0 0 0 456 456 410 456 456 228 456
327   456 182 182 410 182 683 456 456 456 456 273 410 228 456 410 592 410 410 410 0 0 0 0
328   0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
329   0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
330   0 0 0 0 0 0 0 0 0 592 0 0 501 0 0 456 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
331   0 0 0 456]
332
333 endobj
334 434 0 obj
335 <</Filter/FlateDecode/Length 33948/Length1 101432>>
336
337 stream
338 xref
339 [TE0i<0ç04W>ÓK'ÓŠYI"06\PC2\PC2v4,%,I"(8WY8ON8WY+DA*

```

Abbildung 1.5 PDF Bodyauszug des PDF-Dateiformats in Notepad++

#### 1.4.4 Implementierung von Fonts

Schriften werden als Konturen (Outlines) digital gespeichert und mit Instruktionen (Hints) versehen, sodass sie generisch skaliert werden können. Fonts werden in PDF als eigenständige Dateien behandelt und die Darstellung wird durch einen speziellen Font-Interpreter bewerkstelligt. Innerhalb der Datei werden Fonts als Dictionary registriert, worin u.a. Fonttyp als Subtype, PostScript-Name, Verschlüsselung und Schriftklasse (für eine mögliche Ersatzschrift) abgelegt sind. Für jeden verwendeten Font wird ein Font-Descriptor in der Datei hinterlegt. PDF verarbeitet 2 Klassen von Fonttypen: Simple-Fonts und Composite-Fonts.

Jede Glyphe im Dokument wird über einen Character-Code prozessiert. Daraufhin erfolgt eine Zuordnung des Character Codes zum hinterlegten Encoding (Mapping). Zuletzt wird die Glyphe im aktuellen Font über die Glyphen-ID zum Zeichen der Glyphe aufgerufen. Folglich erzielt das Mapping des Codes und der Aufruf der Glyphe die benötigte Konturbe-

```

3127 xref
3128 0 454
3129 0000000035 65535 f
3130 0000000017 00000 n
3131 0000000125 00000 n
3132 0000000188 00000 n
3133 0000000482 00000 n
3134 0000008922 00000 n
3135 0000009098 00000 n
3136 0000009356 00000 n
3137 0000009537 00000 n
3138 0000009799 00000 n
3139 0000009959 00000 n
3140 0000010184 00000 n
3141 0000010360 00000 n
3142 0000010605 00000 n
3143 0000010730 00000 n
3144 0000010760 00000 n
3145 0000010913 00000 n
3146 0000010987 00000 n
3147 0000011218 00000 n
3148 0000011358 00000 n
3149 0000011388 00000 n
3150 0000011556 00000 n

```

Abbildung 1.6 PDF Xref des PDF-Dateiformats in Notepad++

```

10763 trailer
10764 << /Size 467 /Root 438 0 R /Info 1 0 R /ID [ <034581ec832f8e851b69c8ecbfbb94a0>
10765 <034581ec832f8e851b69c8ecbfbb94a0> ] >>
10766 startxref
10767 1158066
10768 %%EOF

```

Abbildung 1.7 Kurzer Trailer des PDF-Dateiformats in Notepad++

```

3581 0000375647 00000 n
3582 0000398023 00000 n
3583 trailer
3584 <</Size 454/Root 1 0 R/Info 34 0
R/ID[<C5AF47CFA4702847AAF5ABBD07AB5874><C5AF47CFA4702847AAF5ABBD07AB5874>] >>
3585 startxref
3586 399162
3587 %%EOF
3588 xref
3589 0 0
3590 trailer
3591 <</Size 454/Root 1 0 R/Info 34 0
R/ID[<C5AF47CFA4702847AAF5ABBD07AB5874><C5AF47CFA4702847AAF5ABBD07AB5874>] /Prev
399162/XRefStm 398023>>
3592 startxref
3593 408402
3594 %%EOF

```

Abbildung 1.8 Ende einer Xref und Trailer des PDF-Dateiformats in Notepad++

schreibung. Ein optionales Unicode-Mapping ToUnicode ist von Nöten, damit die Glyphen auch über Unicode verarbeitet werden kann. Ist dieses Mapping nicht vorhanden, so kann

keine Textsuche und das Kopieren von Text stattfinden. Fehler im Mapping oder Modifikation von Schriften können zu falsche Ausgabebuchstaben, mangelnde Wiederverwendung und fehlerhafte Textkonvertierung führen.

Eine Font-Einbettung kann als zweite Option als Object-Stream gespeichert werden bzw. können Fonts sich auf eine externe Referenz beziehen. Die Beschreibung von Glyphen ist bei eingebettete Schriften als Stream im Eintrag FontFile registriert. Falls die Schrift nicht eingebettet wurde fehlt dieser Eintrag. Schriftsubstitution findet immer dann statt, wenn der Character-Code nicht mit der Encoding-Tabelle übereinstimmt. Häufig fehlen bestimmte Glyphen im Font. Falls eine Outline-Beschreibung des Fonts zum Erstellungszeitpunkt nicht verfügbar ist, wird die Einbettung des Fonts verhindert. Dies kommt vor allem dann vor, wenn ein Font ein Schutzflag besitzt. Weitere Probleme bei der Schrifteinbettung sind u.a. Laufweitenfehler in Schriften, Fehler in der Buchstabenbeschreibung oder beim Cachen von Fonts. Zwecks der Schriftsubstitution müssen folgende allgemeine Informationen zu einem Font in der PDF-Datei gespeichert sein: Name der Schrift, Fontfamilie, Typ, Subtyp, Schriftstärke (Font Weight), Zeichenbreite, Laufweite, maximale Ausprägung der FontBox, Dickteninformationen, Positionsangaben über Versal- und x-Höhe und Winkel für Italic (kursiv). Diese Informationen sind selbst bei nicht eingebetteten Schriften vorhanden [8].

## 1.5 PDF Sicherheitsaspekte

Etwa 40 % der Unternehmen setzen PDFs für geschützte Inhalte ein. In den letzten 2 Jahren ist die Nutzung der elektronischen Signaturfunktion in PDFs um mehr als 150 % gestiegen [49]. Diese Statistik zeigt keine gute Entwicklung, da PDF-Dokumente nicht für vertrauliche Inhalte verwendet werden sollten. Obwohl PDF Verschlüsselung implementiert, erlaubt das Dateiformat eine Vielzahl von Angriffen, um die Sicherheit von PDF-Dokumenten zu untergraben. Ich werde im Folgenden die Sicherheitsmechanismen von PDF, sowie PDF Signature Spoofing und PDFex als Risikostufen für Schwachstellen näher beleuchten.

Neben den im weiteren Verlauf detailliert beschriebenen Attacken aus dem Jahr 2019, gibt es noch weitere Attacken auf PDF-Dokumente, die ich aber nur kurz benennen und nicht weiter ausführen werde. 2020 wurden Shadow Attacks entdeckt, die sich auf ein PDF Dokument mit 2 Inhaltsebenen beziehen. Zum einen wird Inhalt sichtbar, der beim Ersteller der Signatur angezeigt wird und zum anderen wird ein alternativer versteckter Inhalt dem Opfer gezeigt, nachdem das Dokument signiert wurde. Weitere unsichere Features würden im Jahr 2021 in PDFs untersucht. Man fand Möglichkeiten für Denial-of-Service (DOS) attacks, die sich auf den Host beziehen, der das Dokument bearbeitet, Information disclosure attacks, die persönliche Daten aus dem Computer des Opfers freilegen können, Data manipulation auf dem System des Opfers und Code execution auf dem Computer des Opfers. Zuletzt im Jahr 2021 wurden Sicherheitslücken in der PDF-Spezifikation entdeckt, die Evil Annotation Attack (EEA) und Sneaky Signature Attack (SSA) realistisch machen. Nutzt der Angreifer diese Sicherheitslücken aus, so kann er den sichtbaren Inhalt eines Dokuments verändern, indem er bösartigen Inhalt über dem zertifizierten Inhalt anzeigt.

Nichtsdestotrotz bleibt das Zertifikat gültig und die PDF-Anwendung zeigt keine Warnung an [50].

In den Sicherheitseinstellungen eines PDF-Dokuments können Dokumentensicherheit und Zugriffsregeln justiert werden. PDF unterstützt Verschlüsselung und die Vergabe von Passwörtern. Eventuell kann beim Öffnen einer Datei ein Passwort gefordert werden oder das Kopieren von Teilinhalten, jeglichem Inhalt, Ausfüllen von Formularfeldern, Dokumentveränderungen (z.B. Struktur, Inhalt, Kommentare), das Einbetten und Editieren von Schriften oder das Ausdrucken kann vom Ersteller des Dokuments gesperrt worden sein. Das Schwärzen von Dokumenten, d.h. ein schwarzer Balken liegt auf dem Text, führt nicht dazu, dass der geschwärzte Text aus der Datei verschwindet. Er kann weiterhin ausgelesen werden, ebenso Metadaten [13].

### 1.5.1 Digitale Signatur

Digitale Signaturen sollen die Identität des Unterzeichners des Dokuments authentifizieren und sicherstellen, dass der Inhalt nach der digitalen Signatur nicht geändert wurde. Der Verfasser benötigt für die digitale Signatur ein Signatur-Zertifikat. Das Zertifikat bescheinigt die Echtheit der Signatur bzw. Herkunft und wird von einem möglichst vertrauenswürdigen Zertifizierungsanbieter ausgestellt. Zusätzlich können Zertifikate ablaufen oder entzogen werden und müssen gültig sein. Jede digitale Signatur kann mit einem Zeitstempel versehen werden. Ein externer Zeitstempel-Anbieter (ZSA) belegt den Zeitpunkt, wann die digitale Signatur geleistet wurde [10].

Eine digitale Signatur ist eine spezielle Art von elektronischer Signatur, die kryptographische Techniken implementiert. Im Gegensatz dazu kann eine elektronische Signatur verschiedene Formen annehmen, beispielsweise eine gescannte handschriftliche Unterschrift, ein getippter Name, eine biometrische Signatur oder eine digitale Signatur. Elektronische Signaturen sind der Oberbegriff und digitale Signaturen sind eine Unterart davon. Elektronische Signaturen bieten variierende Sicherheitsgrade [13].

Digitale Signaturen verwenden asymmetrische Kryptographie. Anfangs wird ein Algorithmus zur Schlüsselgenerierung initiiert. Als Ausgabe werden ein Private Key und Public Key erzeugt. Ein Signierungsalgorithmus erstellt den einzigartigen Hash-Wert des PDF-Dokuments und verschlüsselt ihn mit dem geheimen Private Key, was die digitale Signatur als Output produziert. Zuletzt überprüft ein Signaturvalidierungsalgorithmus die Authentizität des PDF-Dokuments, indem er erneut einen Hash des Dokuments berechnet. Die Signatur wird mit dem Public Key entschlüsselt und gibt ebenfalls einen Hash aus. Falls der berechnete Hash im Signaturvalidierungsalgorithmus mit dem entschlüsselten Hash übereinstimmt, ist die Authentizität des PDF-Dokuments gesichert [51].

Eine PDF-Datei ermöglicht mehrere digitale Signaturen, jedoch muss jede neue Signaturen in einem inkrementellen Update geleistet werden. Alle digitalen Signaturen muss mit einem Unterschriftsfeld im Dokument verbunden sein. Optional kann das Unterschriftsfeld mit einem Widget gekoppelt sein. Dann wird die Signatur graphisch dargestellte. Signaturen

ohne Widgets sind versteckte digitale Signaturen [10]. Auf dem Markt werden Desktop-Anwendungen und Online-Validierungsservices zur Überprüfung der digitalen Signatur angeboten.

### 1.5.2 PDF Signature Spoofing

Die PDF-Spezifikation ist sehr ungenau im Bezug auf digitale Signaturen bzw. auf welche Art und Weise sie validiert werden müssen. PDF-Viewer haben eine hohe Toleranz beim Öffnen, Validieren und Anzeigen von beschädigten PDF-Dateien.

Im Jahr 2019 wurden 3 Attacken zum Vortäuschen von validen PDF Signaturen erforscht: Incremental Saving Attack (ISA), Signature Wrapping Attack (SWA) und Universal Signature Forgery (USF). Das attack scenario sieht wie folgt aus: Der Angreifer besitzt das signierte PDF mit einer gültigen digitalen Signatur und manipuliert es. Das manipulierte signierte PDF wird an das Opfer geschickt und die Signatur bleibt gültig, obwohl der Inhalt geändert wurde.

Die ISA nutzt das incremental update Feature von PDF aus, um böartigen Inhalt in das PDF des Opfers zu schleusen. Im Prozess des Signierens wird ein incremental update verwendet, um die Signatur zu speichern. Am Ende des Originaltrailers wird ein neuer Katalog und ein neues Signatur-Objekt als Body Updates angehängt, was den Signaturwert und Informationen über den Ersteller der Signatur enthält. Danach kommt eine updated Xref section und ein updated Trailer. Beim incremental update können Objekte mit anderem Inhalt neu definiert werden. Bei einem Spezifikation-konformem incremental update wird der updated Body hinter dem Originaltrailer am Dateiende angehängt. Darunter zeigt die updated Xref section auf das neue Objekt und der updated Trailer wird ganz am Ende angefügt. Abbildung 1.9 zeigt den Vorgang des Speicherns einer digitalen Signatur mittels incremental update.

Zuerst hat man bei der ISA geprüft, ob die PDF-Reader gegen eine Attacke anfällig waren, bei der hinter dem incremental update, was die digitale Signatur enthält, eine weitere Sektion mit Body Updates, Xref und Trailer angefügt wurde. Ausschließlich LibreOffice wurde mittels diese Vorgehensweise getäuscht. Alle weiteren Strategien produzieren beschädigte nicht Standard-konforme PDF-Dateien, jedoch PDF-Viewer sind sehr fehlertolerant. Als Nächstes haben die Forscher hinter dem updated Trailer des incremental updates der Signatur Body Updates hinzugefügt. Einige getestete PDF-Viewer haben lediglich überprüft, ob eine neue Xref und Trailer vorhanden sind. Da sie fehlten, blieb die Signatur gültig, die zusätzlichen Body Updates wurden ausgeführt und die Modifikation blieb ohne Warnung unbemerkt. Andere PDF-Viewer benötigten neben zusätzlichen Body Updates noch einen Trailer ohne Xref dazwischen, damit keine Warnung geworfen wurde. Die komplexeste Vorgehensweise, bei der neue Body Updates mit einer Kopie des Signatur-Objekts am Dateiende angebracht wurde, hat einige PDF-Viewer wie Foxit gezwungen die Signatur 2 Mal zu validieren und die Body Updates wurden eingefügt. In der Grafik 1.10 werden die Techniken visualisiert,

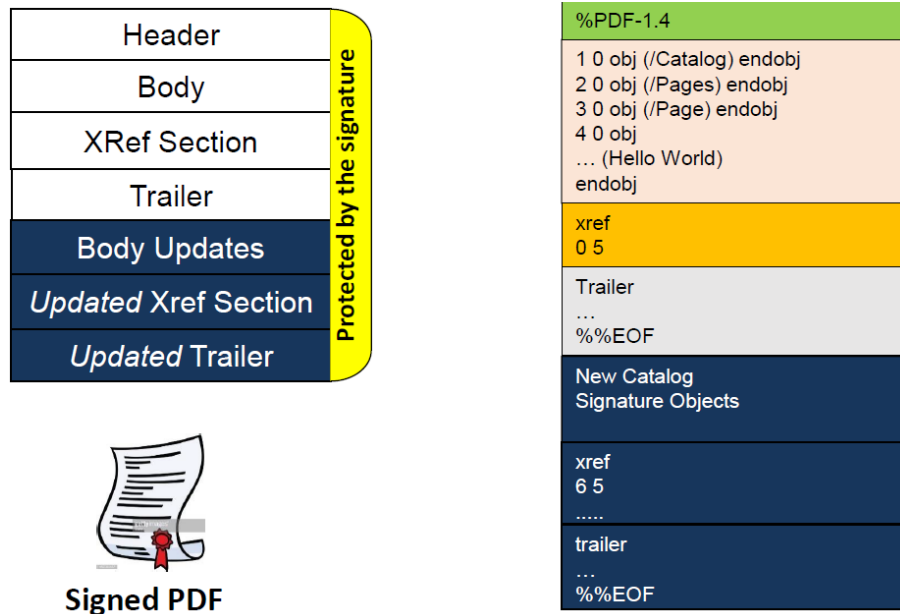


Abbildung 1.9 incremental update mit digitaler Signatur [52]

sowie die PDF-Viewer dargestellt, die anfällig für die ISA-Vorgehensweise waren.



Abbildung 1.10 ISA-Methoden mit anfälligen PDF-Viewern [52]

Bei der SWA werden die Werte der signierten /ByteRange modifiziert und Platz wird für das Einschleusen von böartigen Inhalten geschaffen. Das Signatur-Objekt besteht aus einem /Contents entry mit dem Signaturwert und einem /ByteRange entry mit 4 Werten, was den signierten Teil im Dokument anzeigt. Die ersten 2 Einträge der /ByteRange beziehen sich auf den Beginn des Dokuments bis zum Anfang des Signaturwerts. Hingegen definieren die letzten beiden ByteRange-Einträge den Bereich nach dem Signaturwert bis zu %%EOF. Diese beiden Bereiche wurden nicht angerührt. Die erfolgreiche Idee war eine zweite /ByteRange hinter dem Signaturwert mit einem angepassten dritten Wert, der Platz für böartige Objekte, etwas Padding und eine böartige Xref, die auf die Objekte des Angreifers zeigt, zu setzen. Lediglich die Position der neuen Xref ist im Trailer vorgegeben, der nicht verändert werden kann. Das Schaubild 1.11 zeigt, wie die SWA arbeitet.

Mittels USF wird die Signaturvalidierung außer Kraft gesetzt. Dennoch wird die Meldung „PDF is validly signed“ dem Benutzer angezeigt. Vor allem die Adobe-Produkte waren anfällig



Abbildung 1.11 SWA-Methodik [52]

für diese Attacke. Die Vorgehensweise gestaltete sich wie folgt: Die Forscher versuchten `/Contents` oder `/ByteRange` der Signatur entweder wegzulassen oder unüblichen Werten wie kein Wert oder null zuzuweisen. Zwei PDF-Viewer versagten, wenn man `/Contents` auf 0 Bytes setzte. Das Weglassen der `/ByteRange` oder das Gleichsetzen mit null brach die Sicherheitsmechanismen von Adobe. Die Grafik 1.12 zeigt die USF-Varianten, die von den Forschern getestet wurde.



Abbildung 1.12 USF-Varianten [52]

Mittels dieser Attacken ist es den Forschern gelungen zu zeigen, dass 21 von 22 PDF-Viewer inklusive denen von Adobe und 6 von 8 Online-Anbieter anfällig waren. Der einzige PDF-Viewer, der gegen alle Attacken immun war, war die veraltete Version von Adobe Reader 9, die jedoch remote code execution enthält [45].

### 1.5.3 PDFex PDF Encryption Attacks

PDFex bezeichnet Attacken auf die PDF-Verschlüsselung mit Passwortschutz, die im Jahr 2019 entdeckt wurden. Die Forscher haben 27 PDF-Viewer auf diese Attacken getestet und alle Viewer inklusive Adobe Reader, Chrome and Firefox waren mindestens für eine Attacke



anfällig. Es gibt 2 Attack-Klassifizierungen: Direct Exfiltration und Cipher Block Chaining (CBC) malleability gadgets oder crypto gadgets genannt. Das attacker model gestaltet sich wie folgt: 2 Personen Alice und Bob wollen ein vertrauliches PDF mit Passwortschutz austauschen. Wir nehmen an, dass ein Angreifer durch eine Man-in-the-middle (MITM) attack das verschlüsselte PDF unbemerkt abgreifen konnte als Alice das Dokument zu Bob geschickt hat. Daraufhin modifiziert der Angreifer das Dokument, sodass die Veränderungen unerkennbar sind für Bob, und schickt seine Version des Dokuments an Bob. Bob entsperrt das Dokument mit seinem Passwort und das entschlüsselte PDF wird automatisch zurück zum Server des Angreifers übertragen [45], [53].

Ein verschlüsseltes PDF enthält einen Objekt-Stream als verschlüsselten ciphertext im Body und einen /Encrypt entry, der Informationen darüber enthält, wie die Daten entschlüsselt werden sollen. Der Großteil der PDF-Dateistruktur liegt unverschlüsselt vor. Ausschließlich alle Strings und Streams für Inhalte ohne die anderen Objekttypen wie Integer oder Booleans, die dokumentstrukturbeschreibend sind, werden verschlüsselt. Der Grund dafür ist, dass die PDF-Spezifikation weiterhin die random-access Optimierung im Dateiformat beibehalten möchte. Folglich ist die gesamte Dokumentenstruktur unverschlüsselt und eine ganze Reihe an wichtigen Informationen wie Anzahl und Größe der Seiten, verwendete Objekte oder Hyperlinks können vom Angreifer ausgelesen werden.

PDF verwendet einen speziellen Streamfilter-Typ, genannt crypt filter für die Verschlüsselung. Jeder Standard-Filter eines Streams kann vom crypt filter überschrieben werden. Ein standard identity filter wird bei besonderen Streams für z.B. Dokumentmetadaten gesetzt, damit diese in einem verschlüsselten Dokument unverschlüsselt bleiben. Diese Unterstützung von partieller Verschlüsselung kann einem Angreifer ermöglichen seinen Inhalt mit verschlüsseltem zu vermischen ohne das Passwort zu wissen. Forscher fanden 18 verschiedene Angriffsvarianten für eine ganze Reihe von PDF-Readern [45].

Bei der direct exfiltration attack wird die Kryptografie nicht angerührt. Bei allen Strings im verschlüsselten PDF von Alice überschreibt der Angreifer die crypt filter mit identity filter. Jetzt kann der Angreifer bei Bedarf Strings verändern und kann weitere Objekte mit unverschlüsselten Strings hinzufügen. Außerdem kann er verschlüsselte Teile des Dokuments in Inhalte einfügen, die er kontrolliert, d.h. er kann auf verschlüsselte Streams oder Strings in seinem Inhalt referenzieren und zugreifen. Nachfolgend fügt er eine submit-form action hinzu, die Namen und Werte von AcroForms zu einer Ziel-URL überträgt. Der Text des Formularfelds wird als Stream gespeichert. Kombiniert der Angreifer eine OpenAction, die ausgeführt wird, sobald das Dokument geöffnet wird, mit einer submit-form action zu attacker.com, so kann der vertrauliche entschlüsselte Inhalt an den Angreifer zurück als POST request gesendet werden. Die OpenAction wird ausgelöst, sobald Bob sein Passwort eingegeben hat. Die direct exfiltration attack mittels submit-form action ist im PDF-Dateiformatausschnitt 1.13 zu sehen. Statt einer submit-form action kann man auch einen Hyperlink oder JavaScript verwenden. Jedes Objekt kann als Hyperlink definiert werden, was einen GET request zu attacker.com triggert [45], [53].

PDF verschlüsselt durch AES-256 mit einer Schlüssellänge von 256 Bit und operiert im

```

1 1 0 obj
2   << /Type /Catalog
3     /AcroForm << /Fields [ << /T (x) /V 2 0 R >> ] >>      % value set to 2 0 obj
4     /OpenAction << /S /SubmitForm /F (http://p.df) >>      % attacker's URI
5   >>
6 endobj
7
8 2 0 obj
9   << /Filter [/Crypt] /DecodeParms [ << /Name /StdCF >> ] % encryption with StdCF
10   /Length 32
11   >>
12   stream
13   [encrypted data]                                          % content to exfiltrate
14 endstream
15 endobj

```

Abbildung 1.13 Direct exfiltration attack mittels submit-form OpenAction [45]

CBC mode ohne Message Authentication Code (MAC) Integritätsschutz. AES gehört zu den Blockchiffren und ist ein symmetrisches Verschlüsselungsverfahren. Bei symmetrischer Verschlüsselung gibt es nur einen Schlüssel fürs Verschlüsseln und Entschlüsseln. Ein Block ist 128 Bit lang. Der subkey (Rundenschlüssel) hat immer eine Länge von 128 Bit. Die Schlüssellänge beeinflusst den key schedule, d.h. die Art und Weise wie Rundenschlüssel vom master key abgeleitet werden, sowie die Anzahl an Runden. Während der Algorithmus ausgeführt wird, wird ein 4 x 4 Array aus je 1 Byte (insgesamt 128 Bit), genannt state, in 14 Runden verschlüsselt. Im ersten einzigen Schritt, der KeyExpansion, werden die Rundenschlüssel für jede Runde plus 1 weiterer Rundenschlüssel aus dem master key berechnet. Anfangs wird der state gleichgesetzt mit dem der zu unverschlüsselten Nachricht (plaintext). Auf dem state Array wird bitweises XOR mit dem Rundenschlüssel im AddRoundKey-Schritt angewendet. Jedes Byte vom state wird dabei mit einem Byte vom Rundenschlüssel kombiniert. Die Grafik 1.14 zeigt den AddRoundKey-Schritt. Im SubBytes (substitution) Schritt wird jedes Byte des aktualisierten state Arrays mit einem Byte durch eine Substitutionstabelle (S-Box) ersetzt. Dadurch werden die Bytes im state vermischt. Eine weitere Grafik 1.15 stellt den SubBytes-Schritt dar. Danach kommt die ShiftRows-Sequenz. Die Bytes in jeder Zeile von state werden unterschiedlich nach links verschoben: Die 1. Zeile bleibt unberührt, die 2. Zeile wird um 1 verschoben, die 3. um 2 und die letzte um 3 Positionen. Die überlaufenden Zellen werden rechts an die jeweilige Zeile wieder angehängt. Im Schaubild 1.16 ist die Funktionsweise von ShiftRows gezeigt. Als Vorletztes jeder Runde außer der letzten Runde kommt MixColumns dran. Hier werden Spalten vermischt, indem jede Spalte mit einer konstanten Matrix zu einer neuen Spalte multipliziert wird. Anschaulich wird MixColumns im Schaubild 1.17 graphisch umgesetzt. Abschließend zu jeder Runde wird nochmals AddRoundKey mit dem aktuellen Rundenschlüssel ausgeführt, also state bitweise XOR verknüpft mit dem Rundenschlüssel. Im letzten Schritt produziert AddRoundKey den ciphertext. Die invertierte Operation des Algorithmus wird beim entschlüsseln angewendet und alle Funktionen werden umgekehrt aufgerufen [54]–[56].

Während des CBC mode wird ein vorheriger ciphertext block mit dem nächsten plaintext




Abbildung 1.14 AddRoundKey-Schritt im AES-Algorithmus [57]




Abbildung 1.15 SubBytes-Schritt im AES-Algorithmus [57]

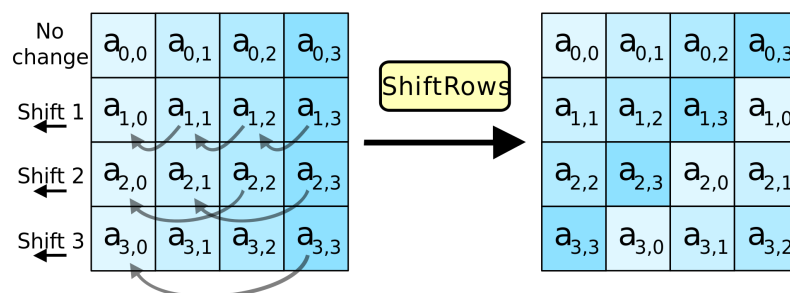


Abbildung 1.16 ShiftRows-Schritt im AES-Algorithmus [57]



Abbildung 1.17 MixColumns-Schritt im AES-Algorithmus [57]

block durch XOR verknüpft. Das Ergebnis und der Schlüssel dienen als Input für den AES-Algorithmus und produzieren den verschlüsselten Output als ciphertext block. Außerdem wird der Output des vorherigen Blocks (ciphertext) als Input für die XOR-Verknüpfung des nächsten Blocks (plaintext) wiederverwendet. Im ersten Schritt wird der erste plaintext block mit einem Initialisierungsvektor IV (nonce) als Zufallszahl oder Zeitstempel mit XOR verknüpft. IV sollte nur einmal verwendet werden und wird dem Empfänger vom Sender mit dem ciphertext übertragen, jedoch muss IV nicht geheim bleiben. Bei mindestens einer Bitmanipulation oder einem einzigen Bitfehler im ciphertext block werden die Entschlüsselung dieser Blocks und alle nachfolgenden Blöcke beeinflusst. Grafik 1.18 zeigt das Prinzip von Verschlüsselung und Entschlüsselung im CBC mode.



Abbildung 1.18 CBC mode Verschlüsselung und Entschlüsselung [58]

Ein MAC ist eine kryptographische Prüfsumme, die aus dem Datensatz und dem symmetrischen Schlüssel von Sender und Empfänger gebildet wird. Im Gegensatz zu einem

Hash kann der MAC nur von Sender und Empfänger berechnet und ebenfalls von beiden verifiziert werden [59].

Nicht alle PDF-Viewer unterstützen teilweise verschlüsselte Dokumente. Solche Viewer sind immun gegen direct exfiltration attacks. Trotzdem können Angreifer CBC malleability gadgets verwenden, um die Exfiltration des Texts zu erhalten, da keine MAC für den ciphertext beim PDF-Standard verwendet wird. Für die Ausführung der Attacke müssen 2 Vorbedingungen erfüllt sein: Zum einen muss ein plaintext-Segment dem Angreifer vorliegen. Beim aktuellsten AESV3-Algorithmus kann der plaintext als 16 Bytes aus dem verschlüsselten /Perms entry (extended permissions) einer PDF-Datei abgeleitet werden. Die zweiten 4 Bytes sind die permissions /P, die unverschlüsselt im PDF-Dokument herausgelesen werden können. Das Byte aus T oder F wird entsprechend des EncryptMetadata Booleans gesetzt. Abschließend kommen 3 Konstante characters ädbünd 4 random Bytes. Die Tabelle 1.19 bietet eine Übersicht des /Perms entries. Der /Perms entry wird mit dem gleichen Schlüssel für Streams und Strings verschlüsselt, daher kann man ihn verwendet um CBC gadgets zu konstruieren. Obwohl der /Perms-Wert mit Electronic Code Book (ECB) mode verschlüsselt wird, ist der output ciphertext gleich seinem plaintext, wenn man ihn mit CBC verschlüsselt und dabei einen initialization vector von 0 verwendet würde. Bei älteren Versionen des AES-Algorithmus in PDF muss der bekannte plaintext aus dem Objekt, auf das die Exfiltration angewendet werden soll, extrahiert werden [45], [53].

1...1	P Value	“T”/“F”	“adb”	random
4 byte	4 byte	1 byte	3 byte	4 byte

Abbildung 1.19 Bytebelegung beim /Perms (extended permissions) entry in einer verschlüsselten PDF-Datei [45]

Alice verschlüsselt eine Nachricht aus 2 Blöcken  $p_0$  und  $p_1$  zum initialization vector IV,  $c_0$  und  $c_1$  und Bob kann diese Nachricht wieder zu  $p_0$  und  $p_1$  entschlüsseln. CBC gadgets kann man konstruieren mit einem bekannten plaintext (known plaintext) von 16 Bytes  $p_0$  und kann dadurch vom Angreifer ausgewählte plaintext blocks (chosen plaintext)  $g_0$  und  $g_1$  in eine entschlüsselte plaintext message einfügen. Beispielsweise könnte  $g_1$  die URL vom Angreifer enthalten, sodass er sich die entschlüsselte Nachricht  $p_1$  von Bob zu seinem Server schicken lassen kann. Der Angreifer erhält die verschlüsselte Nachricht aus IV,  $c_0$  und  $c_1$  von Alice durch eine MITM attack und konstruiert 2 neue initialization vectors  $x_0$  und  $x_1$ . Nimmt man IV XOR  $p_0$  erhält man ausschließlich Nullen.  $X_0$  als vom Angreifer erstellter IV wird durch IV XOR  $p_0$  XOR  $g_0$  und  $x_1$  als zweiter vom Angreifer erstellter IV wird durch IV XOR  $p_0$  XOR  $g_1$  gebildet. Eine neue verschlüsselte Nachricht wird durch die Konkatination von  $x_0$ ,  $c_0$ ,  $x_1$ ,  $c_0$  und  $c_1$  gebildet. Der ursprüngliche  $c_0$  Block wird 2 Mal verwendet.  $X_0$  und  $x_1$  sind die neuen IV und  $x_1$  ist lediglich an dieser Stelle zwischen  $c_0$  in der Verkettung, um sie beizubehalten.  $X_1$  wird zu unkontrollierbaren Bytes ohne Sinn entschlüsselt.  $C_1$  ist der ciphertext block von Alice, der die Zieldaten, enthält. Bei der Entschlüsselung erhält Bob den chosen plaintext block  $g_0$ , die unkontrollierten Bytes, den zweiten chosen plaintext block  $g_1$  und die entschlüsselten Zieldaten von Alice  $p_1$ . Abbild 1.20 zeigt das Wirkungsprinzip von CBC gadgets. Als Exfiltration Channel kommen

AcroForms oder Hyperlinks in Frage, um die entschlüsselte Nachricht von Bob zurück an den Angreifer zu schicken [45], [59], [60].



Abbildung 1.20 CBC malleability gadget mit konstruierten initialization vectors x0 und x1, um chosen plaintext einzuschleusen [60]

Hauptursache des Problems ist, dass viele Datenformate eine Teilverschlüsselung erlauben, z.B. XML, S/MIME und PDF, was dem Angreifer ermöglicht eigene Inhalte einzuschleusen und exfiltration channels bilden zu können. Des Weiteren enthält AES-CBC keinen Integritätsschutz wie einen MAC, sogar nicht in PDF 2.0. Diese Sicherheitslücken sollten ohne Rückwärtskompatibilität in zukünftigen PDF-Spezifikationen entfernt werden [53].

## 2 Open Source PDF Web App

### 2.1 Anforderungen und Konzept

Das Thema der Bachelorarbeit „*Entwicklung einer webbasierten Applikation zur Bearbeitung von PDF Dateien*“ habe ich selbst gewählt. Ziel der Arbeit ist eine PDF-Webapplikation zu entwickeln, die gängige Funktionalitäten, die man bei üblicher PDF-Bearbeitung benötigt, bieten soll. Gängige Funktionalitäten sind für mich ein PDF-Reader, das Editieren von Seiten und die grundsätzlichsten Grafikoperationen. Mir war außerdem wichtig, dass die PDF Web App auf allen Desktop-Plattformen Windows, macOS und Linux einsetzbar ist, da PDF genauso ein plattformunabhängiges und hardwareunabhängiges Format ist. Ich habe mir selbst die Vorgabe gestellt, dass die PDF Web App lediglich als Desktop-App funktionieren muss und nicht optimiert für Tablet oder Smartphone sein soll. PDF-Bearbeitung macht für mich am meisten Sinn in einer Desktopumgebung, da der Bildschirmabmessungen auf Tablets und vor allem bei Smartphones nicht besonders groß bis sehr klein ist. PDF-Bearbeitung nimmt viel Zeit in Anspruch und am besten setzt man sich an den Schreibtisch vor einen großen Bildschirm und setzt seine PDF-Modifikationen mit der Maus und Tastatur um.

Ursprünglich war die PDF Web App als offline Webseite angedacht. Die Webseite sollte man auch ohne Internetverbindung wie ein Programm verwenden können, nur dass keine Installation notwendig ist. Das einzige Programm, was man benötigt für die Ausführung der PDF Web App soll ein Browser sein. Durch Öffnen der index.html im Browser kann man die PDF Webapp auf einfache Art und Weise starten und benutzen. Eine Anforderung an mich selbst ist, dass sie als Open Source-Projekt für jeden kostenlos nutzbar sein soll, da ich selbst nur kostenlose PDF-Bearbeitungsprogramme verwende. So soll die PDF Web App auch u.a. für Studenten mit wenig Geld zur Verfügung stehen. Das Open Source-Projekt soll als öffentliches Repository auf Github vorhanden sein und jeder kann es downloaden. Da das PDF-Dateiformat ein offenes Dateiformat ist, bin ich der Ansicht, dass die Bearbeitungsprogramme für PDF-Dateien ebenfalls kostenlos sein sollten. Auf dem öffentlichen Github Repository soll man ausschließlich die PDF Web App mit Tutorials und einer Beschreibung ohne Werbeprogramme oder ähnliches herunterladen können.

Des Weiteren wollte ich mich nur auf HTML, CSS und JavaScript beschränken. Folglich ist die PDF Web App eine reine Frontend Web Anwendung und ich wollte kein Backend oder eine Datenbank implementieren. Dadurch habe ich die Programmierung und den Verwaltungsaufwand meiner PDF Web App simpler gemacht. Die Bedienung sollte möglichst intuitiv, eingängig und einfach gehalten sein, damit ein Nutzer nicht seitenlange Tutorials

lesen muss. In der Praxis bedeutet das, dass die Einstellmöglichkeiten möglichst durch reines Ausprobieren erfasst werden können. Um diese Anforderung zu erreichen, sollte eine GUI mit simplem, übersichtlichem und strukturiertem Design verwendet werden. Verschlüsselung wollte ich Außerachtlassen, da das PDF-Dateiformat unsicher ist und generell nicht für vertrauliche Inhalte verwendet werden sollten. Formulare und Kommentare, sowie das incremental update wollte ich ebenfalls nicht implementieren, um den Arbeitsaufwand geringer zu halten und weil ich diese Anwendungsgebiete kaum verwende. Ich wollte mich lediglich auf die wichtigsten Funktionen zur Bearbeitung beschränken.

Eine weitere Vorgabe der Gutachterin der Bachelorarbeit ist eine Marktübersicht inklusive der Beschreibung anderen PDF Wettbewerberprogramme zu erarbeiten. Daraufhin habe ich mir einige freie und kostenpflichtige PDF-Programme und Onlinedienste ausgesucht:

- Adobe Acrobat
- foxit
- pdf-it
- PDF24
- PDFelement
- Soda PDF
- Nitro PDF Pro
- Ashampoo PDF Pro 3
- Infix 7
- PDFsam Basic und Advanced
- DrawboardPDF
- PDF Director 2 PRO
- Perfect PDF

Darüber hinaus soll ich Anwendungen recherchieren, die PDF zu Word oder Latex konvertieren können.

### 2.1.1 Vorgaben für den Funktionsumfang der PDF Web App

Bei der Planung der PDF Web App habe ich den Funktionsumfang selbstständig zusammengestellt. Im Prinzip sollte die PDF Web App aus 8 Modulen bestehen, wobei die letzten 4 Module in der Liste den Editor bilden:

- Reader



- Creator
- Merger
- Splitter
- Writer
- Drawer
- Geometry Editor
- Images Editor

Im Editor sollen die aktuellen Koordinaten des Mausursors angezeigt werden. Der Reader sollte eine Navigationseinheit enthalten, die die aktuelle Seitenzahl anzeigt, zu einer beliebigen Seite springen kann, eine Zoomfunktionalität implementiert und zur vorherigen und nächsten Seite blättern kann. Zusätzlich soll eine Druckfunktionalität enthalten sein. Der Creator ist ein Modul zur Erstellung von leeren PDF-Dokumenten als Download mit beliebiger Größe, Anzahl an Seiten, Möglichkeiten, die Orientierung (Portrait, Landscape, quadratisch), zu justieren und Presets zur DIN A Größe. Es gibt 2 Module zur Verwaltung von kombinierten PDF-Dokumenten. Zum einen soll der Merger mehrere PDF-Dateien zusammenfügen und als eine Datei speichern können. Dabei soll die Reihenfolge der einzelnen PDF-Dateien in einer Liste anpassbar sein und eine Druckfunktion enthalten. Hingegen soll der Splitter ein PDF zerteilen und als einzelne PDF-Dateien speichern können. Dabei gibt es verschiedene Split-Operationen: Der Splitter soll nach jeder, nach jeder ungeraden, nach jeder geraden, nach einer bestimmten und nach einer Liste an Seiten das PDF zerteilen können. In meiner PDF Web App ist Speichern ein Synonym für den Download eines bearbeiteten PDFs. Beim Download soll man immer einen benutzerdefinierten Dateinamen setzen können. Diese 4 Module sind im Diagramm 2.1 graphisch dargestellt.

Der Editor besteht aus den restlichen 4 Modulen. Alle Editoroperationen beziehen sich lediglich auf bereits hinzugefügte Elemente. Es sollen keine schon im geöffneten PDF bestehende Objekte bearbeitet werden können. In jedem Editorteil soll es möglich sein, zu drucken und das PDF zu downloaden, sowie alle neuen Elemente auf einen Schlag zu löschen. Außerdem sollen Elemente in beliebiger Reihenfolge übereinander stapelbar sein, d.h. man kann Elemente in den Vordergrund holen oder weiter nach hinten Richtung Hintergrund verschieben. Im Diagramm 2.2, was zeigt, wie die Editormodule aufgebaut sind, ist die zuletzt genannte Funktionalität mit z-axis order gekennzeichnet. Mittels des Writers soll Text hinzugefügt werden können. Dieser neue Text kann gelöscht, verschoben, gedreht, die Schriftgröße und font family angepasst und eingefärbt werden. Als Font kann man zwischen Times Roman, Helvetic oder Courrir und dessen Schriftschnitten wählen bzw. einen benutzerdefinierten Font verwenden. Im Drawer hat man die Möglichkeit zu zeichnen und zu radieren. Dabei kann man die Größe und Farbe des Stifts bzw. Radierers anpassen. Das Geometry Editor-Modul soll geometrische Formen, wie Rechteck, Dreieck oder Ellipse hinzufügen, ihre Größe und Farbe verändern, Formen löschen, verschieben und drehen können. Zuletzt soll der Images Editor Bilder vom Dateisystem hinzufügen, löschen,




Abbildung 2.1 Anforderungen an den Reader, Creator, Merger und Splitter der PDF Web App

verschieben und drehen können.




Abbildung 2.2 Anforderungen an den Editor der PDF Web App

### 2.1.2 Qualitätsanforderungen

Ich habe den Ansporn, dass die PDF Web App sehr stabil und mit minimalen zeitlichen Verzögerungen arbeiten soll. Konkret bedeutet das, dass sich die Seite schnell aufbauen kann und die Seiten von geöffneten PDFs in einer akzeptablen Zeitspanne laden sollen. Genauso wichtig ist mir eine gute Funktionalität, d.h. keine Laufzeitfehler bzw. dass die PDF Web App immer genau gleich funktioniert und nicht abstürzt. Maximale Effizienz sollte gegeben sein, indem die PDF Web App als reine Frontend App ohne Backend auskommen

kann. Es müssen keine Daten gespeichert werden bzw. muss sich der Benutzer nirgendwo registrieren und einloggen. Genauso wichtig ist eine gute Benutzbarkeit. Genauer gesagt soll der Anwender sich die Funktionalität der PDF Web App möglichst selbstständig durch Ausprobieren erschließen können. Die Beschriftung der Buttons sollte selbsterklärend sein und die Layoutfarben so eingesetzt, dass sie eine Designkonsistenz zur Vermittlung von Funktionalitätsgruppen aufweist. Die Änderbarkeit und Erweiterbarkeit sollte auf einfache Weise möglich sein, sodass auch andere Entwickler an der PDF Web App arbeiten können. Des Weiteren sollte die Portierbarkeit hoch sein, denn die PDF Web App muss auf den Desktop-Betriebssystemen Windows, macOS oder Linux immer gleich funktionieren. Eine Tablet- oder Mobilversion ist nicht geplant. Mir war wichtig, dass man die PDF Web App als Offlinewebsite im Browser verwenden kann, quasi wie ein eigenständiges Programm, was man nicht installieren muss. Alle gängigen Browser sollten die index.html-Datei der PDF Web App öffnen und ausführen können. Außerdem soll man ausschließlich die PDF Web App und eventuelle Tutorials bzw. eine Beschreibung auf Github downloaden können. Es sollen keine zusätzlichen Werbedateien oder -programme zum Download angeboten werden. Die wichtigste Bedingung, dass die PDF Web App ein kostenloses Open Source-Projekt sein soll, muss auch für zukünftige Releases und Updates, gültig bleiben.

## 2.2 Realisierte Funktionalität und Bedienung der PDF Web App

Mein öffentliches Github Repository für die PDF Web App ist unter dem folgenden Link erreichbar:

<https://github.com/JaninaAlona/MultiPDFmin/>

Das Projekt heißt dort MultiPDFmin. Ich habe die PDF Web App auf Github Pages hochgeladen. Sie ist unter diesem Link zu benutzen: <https://janinaalona.github.io/MultiPDFmin/>

Der letzte gültige Commit-Hash der git history lautet wie folgt:

In der PDF Web App habe ich alle geplanten Module Reader, Creator, Splitter, Merger, Writer, Drawer, Geometry Editor und Images Editor realisiert. Wenn man die PDF Web App zum ersten Mal öffnet, findet man die im Screenshot 2.3 abgebildete Startseite vor.




Abbildung 2.3 Startseite der PDF Web App

Bei fast allen Modulen gibt es Möglichkeiten Benutzereingaben zu machen. Die Benutzereingaben sind so umgesetzt, dass sie bei ungültigem Input automatisch korrigiert werden oder die darauf bezogene Operation nicht ausgeführt wird. Gibt man in ein input field, wo eine Zahl erwartet wird, einen String ein, so wird dessen Funktion nicht angewendet. Liegt eine Benutzereingabe als Zahl unter oder über dem minimalen oder maximalen Schwellenwert des Eingabefeldes, so wird die Eingabe mit dem niedrigsten oder obersten Wert substituiert. Manche Eingabefelder erwarten Integers, anstatt Floats, z.B. das Eingabefeld für die Seitenzahl. In diesem Fall wird die Nachkommastelle automatisch von der Benutzereingabe entfernt. Haben sich beim Benutzer ein oder mehrere Leerzeichen in die Eingabe eingeschlichen, so werden diese Leerzeichen von der Anwendung automatisiert erkannt und entfernt. Falls eine andere Dateart als PDF in der PDF Web App geöffnet wurde, unabhängig vom Modul der App, erscheint die Fehlermeldung in Screenshot 2.4.




Abbildung 2.4 Fehlermeldung bei einer nicht-PDF-Datei

Auch beim Versuch eine verschlüsselte PDF-Datei zu öffnen, wird eine in Screenshot 2.5 dargestellte Fehlermeldung angezeigt.




Abbildung 2.5 Fehlermeldung bei einem verschlüsselten PDF

Bei diesen gezeigten Fehlermeldungen kann man erneut den Dateibrowser im jeweiligen Modul öffnen und eine unverschlüsselte PDF-Datei auswählen oder einen anderen Hauptmenüpunkt wählen, damit die Fehlermeldung verschwindet.

Ist ein Modul der PDF Web App geöffnet, so wird der entsprechende Hauptmenübutton durch einen dunkelgrauen Hintergrund mit grüner Schrift symbolisiert. Initial ist der Reader ausgewählt. Der Button Create führt zum Creator für leere PDFs, Split zum Splitter für das Seiten Zerteilen, Merge zum Merger für das Zusammenfügen von PDF-Dateien, Text zum Writer für Textbearbeitung, Draw zum Drawer fürs Zeichnen, Shape zum Geometry Editor zur Geometrieerstellung und Image zum Image Editor zur Bildbearbeitung. Jedes Modul der PDF Web App hat einen grünen Save Button, mit dem der Benutzer das veränderte

PDF downloaden kann. Es wird im Downloads-Ordner im lokalen Dateisystem abgelegt. Bewegt man die Maus über den Save Button erscheint eine schwarze Dialogbox, in der man einen benutzerdefinierten Dateinamen vergeben kann. Der Screenshot 2.6 bildet diese Dialogbox ab.




Abbildung 2.6 Dateibenennungsdialog des Save Buttons der PDF Web App

Ansonsten wird der in dem input field abgebildete default Dateiname für den Download verwendet. Bei Read, Text, Draw, Shape und Image erscheint zunächst der Choose file Button, damit man im Dateisystem ein PDF-Dokument auswählen kann zum Lesen oder Bearbeiten. Klickt man auf Choose file wird der Dateibrowser geöffnet und man kann ein einzelnes PDF zum Öffnen auswählen. Ein geöffnetes Dokument passt seine Zoomgröße automatisch an das Browserfenster an, falls es bei 100 % über das Browserfenster hinausragen würde, sodass es fast formatfüllend mit etwas Abstand zum Rand in den Viewport des Browserfensters passt.

### 2.2.1 Bedienung des Readers

Der Reader mit geöffneter PDF-Datei präsentiert sich in Screenshot 2.7.

Hat der Anwender eine PDF-Datei im Reader geöffnet, so entdeckt er 2 dunkelgraue Leisten mit Funktionsbuttons. Mittels Previous und Next kann der Benutzer zur vorherigen bzw. nächsten Seite blättern. Zwischen diesen Buttons informiert das page counter input field über die aktuelle Seite im Viewport und rechts daneben ist die Anzahl an Seiten im Dokument zu sehen. Im page counter input field kann man eine Seitenzahl des Dokuments eingeben und der Reader springt direkt zu dieser Zielseite. Alternativ kann man mit dem Scrollbar am linken Browserfensterrand oder dem Scrollrad der Maus durch die Seiten scrollen. Mittels der Buttons Plus und Minus kann man in 20 %-Schritten rein- bzw. rauszoomen. Der aktuelle Zoomwert in Prozent wird im input field dazwischen signalisiert. Der Anwender kann den Zoomwert auch auf einen gewünschten Wert mit oder ohne Prozentzeichen setzen. Wird kein Prozentzeichen über die Tastatur eingegeben, sondern nur der Wert, so wird ein Prozentzeichen von der Anwendung hinzugefügt. Dabei werden nur ganze Zahlen ohne Nachkommastellen berücksichtigt. Außerdem wird der minimale und maximale Zoomwert in Prozent angezeigt. Spin CW und Spin CCW dreht die aktuelle Seite, die im page counter steht, um 90 Grad-Intervalle im Uhrzeigersinn (clockwise) und gegen den Uhrzeigersinn (counterclockwise). Durch den Button Drag kann man die aktuelle Seite im Viewport verschieben. Das ist beispielsweise nützlich, wenn man an das PDF

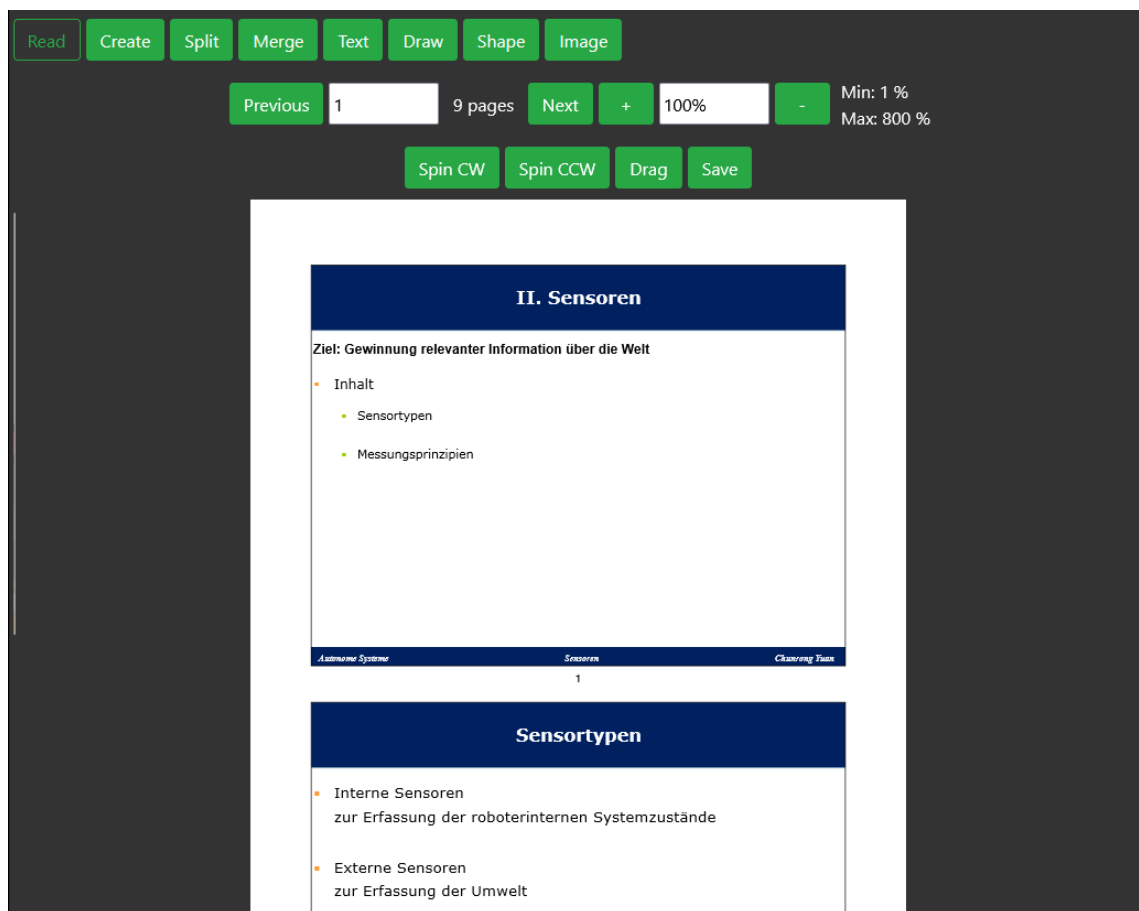


Abbildung 2.7 Geöffnetes PDF im Reader der PDF Web App

besonders nah rangezoomt hat und die Seite nur teilweise sehen kann, weil man einen kleinen Laptopbildschirm besitzt. Dabei klickt man zuerst auf Drag, hält die Maustaste auf der aktuellen Seite gedrückt und bewegt sie in die gewünschte Richtung. Dabei verschiebt sich nicht nur die aktuelle Seite, sondern alle Seiten und der Mauscursor wechselt das Aussehen zu einem weißen Kreuz mit Pfeilen an den Enden.

### 2.2.2 Bedienung des Creators

Der Creator ist mittels des Create Buttons im Hauptmenü aufrufbar. Im Screenshot 2.8 ist die GUI vom Creator dargestellt.

Abbildung 2.8 Creator GUI der PDF Web App

Man gibt eine Anzahl an gewünschten Seiten des leeren PDFs ein, sowie die Breite und Höhe in mm. Wahlweise kann man den Selector verwenden um ein DIN A-Preset zu verwenden. Mittels der Schnellauswahl kann man die Orientierung bestimmen: Portrait, Landscape oder Quadratisch. Minimale und Maximale Werte für die Anzahl an Seiten und die Breite und Höhe sind ebenfalls abgebildet.

### 2.2.3 Bedienung des Splitters

Zum Splitter kann man mit dem Split Button gelangen, dessen GUI vom Screenshot 2.9 gezeigt wird.

Hat man eine Datei ausgewählt, so wird der Dateiname und die Anzahl an Seiten des Dokuments angezeigt. Durch erneutes Klicken des Choose file Buttons öffnet sich erneut der Dateidialog und man kann ein anderes PDF auswählen. Dabei ersetzt das neue PDF das vorherige, denn man kann nicht mehrere PDF-Dateien gleichzeitig splitten. Im Auswahlmenü kann man zwischen Zerteilen nach jeder, jeder geraden, jeder ungeraden und einer Liste von Seiten auswählen, was in Abbildung 2.10 dargestellt ist. Wählt man list of pages aus, so kann man die einzelnen Seitennummern mit Komma separiert oder auch nur






Abbildung 2.9 Splitter GUI der PDF Web App




Abbildung 2.10 Splitter Selector der PDF Web App

eine einzelne Seitennummer eintippen. Die Seitenzahlen müssen nicht in aufsteigender Reihenfolge angegeben werden.

#### 2.2.4 Bedienung des Mergers

Der Merger ist mit dem Hauptmenüpunkt Merge zu öffnen. Abbildung 2.11 zeigt die Startseite des Mergers.

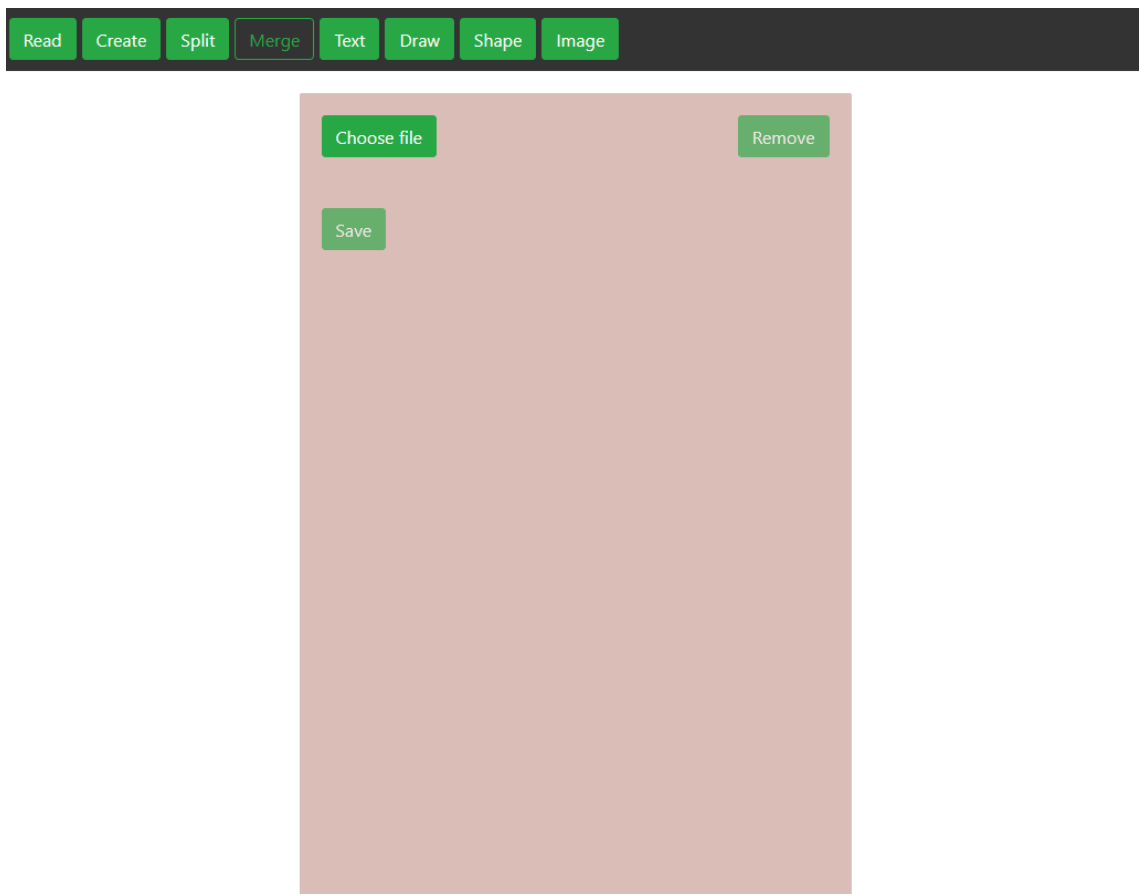


Abbildung 2.11 Merger Startseite der PDF Web App

Hier kann man nacheinander mehrere Dateien mittels Choose file öffnen und sie erscheinen je nach Auswahlreihenfolge untereinander in einer scrollbaren Liste, wobei die zuerst ausgewählte Datei am Anfang der Liste steht. In der Liste kann man dann eine Quelldatei mit gedrückter Maustaste zu einer Zieldatei in der Liste ziehen. Lässt man die Maustaste los, so wird die mit der Maus bewegte Datei in diese Listenposition eingefügt. Man kann außerdem eine Datei in der Liste selektieren und mittels des Remove Buttons wieder aus der Liste entfernen. Eine selektierte Datei wird durch einen schwarzen Hintergrund, was der Screenshot 2.12 verdeutlicht, symbolisiert.

Der Benutzer kann zu jeder Zeit erneut den Dateibrowser bedienen, unabhängig davon, ob die Dateiliste bereits modifiziert wurde und der Save Button merkt alle PDF-Dateien in der gegenwärtigen Liste mit der obersten Datei zuerst und der letzten am Schluss des Output PDFs.




Abbildung 2.12 Merger Dateiliste der PDF Web App mit selektierter Datei

### 2.2.5 Bedienung des Editors

Der Editor ist über den Text, Draw, Shape oder Image Button erreichbar. Öffnet man zum ersten Mal den Editor, so wird initial der Text Button des Hauptmenüs ausgewählt. Befindet man sich im Editor, so kann man dann auch Draw, Shape oder Image selektieren. Genau wie im Reader erscheint zuerst ein Button Choose file. Je nachdem ob man nach erstmaligem Öffnen einer PDF-Datei auf Text, Draw, Shape oder Image geklickt hat, wird als erstes der Writer, Drawer, Geometry oder Image Bearbeitungsmodus des jeweiligen Editormoduls geöffnet. Hat man eine Datei geöffnet, so befindet sich der Reader ohne die Operationen zum Seiten Drehen ebenfalls in jedem Editormodul. Alle input fields im Editor sind mit dem gültigen Wertebereich für Benutzereingaben als Information Min: Max: versehen. Der Editor samt dargestellter PDF-Datei besteht aus einem grauen waagerechten Operations Bar, einem linken Ebenen Seitenmenü in Rosa und einem rechten grünen Tools Seitenmenü. Mit dem ganz linken grünen Button Layers im Operations Bar kann das Ebenen Seitenmenü aus- und eingeblendet werden. Daneben zeigt oder verbirgt der Button Tools das Tools Seitenmenü. Standardmäßig sind die Ebenen und Tools Seitenmenüs ausgeklappt.

#### Textbearbeitung

Hat man den Writer aufgerufen, so präsentiert sich einem der Texteditor in den folgenden Abbildungen 2.13 und 2.14.

Mit dem Button Text in dem Operations Bar und nachfolgendem Klick aufs geöffnete Dokument kann man einen Text mit dem Platzhaltertext dummy hinzufügen. Unter dem Text erscheint eine dunkelrote control box, auf die man alle Operationen im Operations Bar und dem Tools Seitenmenü im Box Mode anwenden kann. Ich werde zunächst alle Operationen im Box Mode beschreiben und später auf den Layer Mode eingehen. Der Box Mode ist standardmäßig eingestellt. Operationen können durch die grünen Buttons zum Erstellen neuer Elemente, Delete oder Move im Operations Bar und allen weißen Buttons im Tools Seitenmenü getriggert werden. Hat man eine Operation getriggert, so befindet man sich im Modus dieser Operation im Box Mode und man kann darauffolgend in alle im Dokument verfügbaren control boxes sämtlicher Elementtypen klicken, um die Operation auf das betreffende Element auszuführen. Das bedeutet außerdem, dass man in jedem Editormodul nur neu hinzugefügte Elemente editieren und nicht bereits im geöffneten Dokument eingebettete Objekte verändern kann. Alle Operationen im rechten Tools Seitenmenü beziehen sich jeweils auf das Element des aktuellen Editormoduls und sind nur auf diesem anwendbar. In der Praxis bedeutet das, dass man mehrere Texte, ohne erneut den grünen Text Button drücken zu müssen, dem PDF-Dokument hinzufügen kann. Für jedes neu hinzugefügte Editorelement wird eine Ebene mit einem elementspezifischen Standardnamen erstellt, die im linken rosa Ebenenmenü erscheint. Die obere linke Ecke der quadratischen control box sämtlicher Editorelemente wird generell dort platziert, wo man mit der Maus auf die Seite geklickt hat. Alle control boxes werden nicht im Output PDF gespeichert, denn sie dienen lediglich der Steuerung von Editorelementen, um Operationen im Box Mode

The screenshot displays the PDF Web App Text Editor interface. At the top, a dark toolbar contains buttons for Read, Create, Split, Merge, Text (highlighted), Draw, Shape, and Image. Below this, a navigation bar shows 'Previous', a page number '1' in a text box, '9 pages', 'Next', '+', '100%', and '-' buttons, along with zoom settings 'Min: 1 %' and 'Max: 800 %'. A second row of buttons includes Layers, Tools, Text, Delete, Move, Drag, and Save. On the left, a vertical sidebar has 'Layers' and 'Menu' buttons. The main editing area shows three slides:

- Slide 1:** Title 'II. Sensoren'. Content: 'Ziel: Gewinnung relevanter Information über die Welt'. A bulleted list under 'Inhalt' includes 'Sensortypen' and 'Messungsprinzipien'. The footer shows 'Autonome Systeme', 'Sensoren', and 'Classroom Tools'.
- Slide 2:** Title 'Sensortypen'. Content: A bulleted list with 'Interne Sensoren zur Erfassung der roboterinternen Systemzustände', 'Externe Sensoren zur Erfassung der Umwelt', and 'Klassifikation externe Sensoren' (with sub-points: 'taktil', 'Berührungslos', 'akustische/optische/sonstige'). The footer is identical to Slide 1.
- Slide 3:** Title 'Sensortypen'. Content: A bulleted list with 'Physikalische Eigenschaften' (with sub-points: 'Bewegung', 'Orientierung/Ausrichtung', 'Position').

On the right, a green sidebar contains a 'Cursor' section with 'X: 4' and 'Y: 97'. Below it is a text input field containing 'dummy'. Further down are controls for 'Text' (a button), 'Text Line Height' (a range from 'Min: 1' to 'Max: 300' with a dropdown showing '34' and a text box with '34'), a 'Line Height' button, 'Font Selection' (a dropdown showing 'TimesRoman'), and a 'Font' button.

Abbildung 2.13 Startseite des Texteditors der PDF Web App




Abbildung 2.14 Mehr Tools der Startseite des Texteditors der PDF Web App

anwenden zu können. Mit dem Delete Button und nachfolgendem Klick in eine oder mehrere control boxes im Box Mode können Texte wieder gelöscht werden. Move verschiebt einzelne Texte durch eine mit der Maus gedrückte und zur Zielposition bewegte control box. Wenn die Maus losgelassen wird, nachdem die control box verschoben wurde, springt der Text an die Zielposition auf der PDF-Seite. Dabei ist wichtig zu beachten, dass man die control box langsam verschiebt, denn der Mauszeiger muss innerhalb control box bleiben. Delete und Move kommen in allen Editormodulen vor und funktionieren immer gleich. Jedoch wirken sich Delete und Move nur auf die im jeweiligen Editor zu bearbeitenden Elemente aus. Ganz oben im Tools Seitenmenü werden dem Betrachter die x- und y-Koordinaten des Mauscursors auf der PDF Seite angezeigt, wenn die Maus über eine Seite bewegt wird. Diese Mauscursorkoordinaten kommen in jedem Editormodul vor. Darunter kann man in der textarea den Text editieren. Es werden auch Zeilenumbrüche berücksichtigt. Nachdem man den dummy Text in der textarea überschrieben hat, einem Klick auf den weißen Text Button und der Anwendung auf control boxes, wird der Platzhaltertext mit dem aktuellen Text in der textarea substituiert. Alle Operationen in Tools in allen Editormodulen werden genau gleich ausgeführt: Man tätigt seine Einstellung, drückt mit der linken Maustaste auf den weißen Button für die jeweilige Operation und klickt daraufhin auf ein oder mehrere control boxes von Elementen nacheinander. Unterhalb der Texteditierungsoperation kann man den Zeilenabstand einstellen. Entweder verwendet man das selection menu mit voreingestellten Werten oder man gibt einen gewünschten Wert manuell in das input field ein. Alle selection Menüs und input fields in jedem Editormodul zeigen die default Werte, mit denen ein neu hinzugefügtes Element konfiguriert ist, an. Falls man zuletzt das selection Menü betätigt hat, überschreibt es den im input field befindlichen Wert und umgekehrt. Maßgeblich ist, was man zuletzt betätigt hat. Dieses Verhalten habe ich bei jeder selection menu und input field Kombination programmiert. Einen benutzerdefinierten TrueType-Font kann man durch den dunkelgrauen Choose file Button vom Dateisystem auswählen und er erscheint in einer Liste. Der zuletzt geöffnete Font wird ausgewählt. Mittels Clear kann man alle Fonts aus der Liste entfernen, was nicht heißt, dass sie auch auf den angewendeten Textelementen entfernt werden. Abbildung 2.15 zeigt 2 geöffnete .ttf Schriftdateien in der Liste.

Die Fontgröße kann man ebenfalls wie die Zeilenhöhe mit selection menu und input field justieren. Bei der Fontfarbe klickt man auf das initial schwarze Quadrat, was die aktuelle Farbe zeigt, und es öffnet sich ein color picker menu. Hier kann man die Farbe und Transparenz einstellen. Die Farbwerte kann man sich in RGBA, HSLA oder HEX formatieren lassen. Mit Klick auf die beiden kleinen senkrechten Pfeile im color picker wird jeweils das Format gewechselt. Das Fenster des color pickers für die Fontfarbe ist in Abbildung 2.16 abgebildet.

Als vorletzte Option kann man den Text absolut drehen. Durch den weißen Button Rotation und der entsprechenden Benutzerinteraktion durch selection Menu oder input field wird das Textelement rotiert. Absolute Rotation bedeutet, dass es eine feste Rotationsskala gibt anhand der das Element rotiert wird. Folglich passiert keine Veränderung, wenn man den gleichen Rotationswert 2 Mal hintereinander ausführt. Stellt man einen Rotationswinkel von 0 Grad ein, so wird das Element wieder zurück auf die Ausgangsrotation bei Erstel-

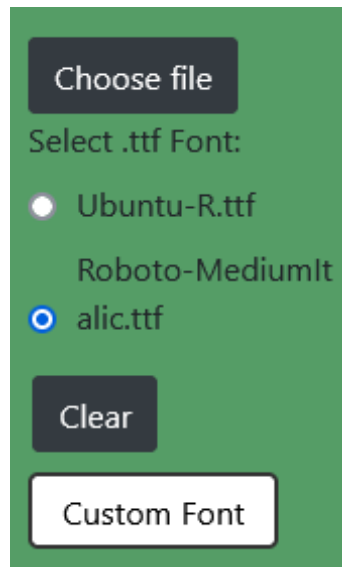


Abbildung 2.15 Benutzerdefinierte Fontliste im Texteditor der PDF Web App




Abbildung 2.16 Color picker für die Fontfarbe des Texteditors der PDF Web App



lung gedreht. Alle Editormodule verwenden absolute Rotation. Abschließend können alle Textelemente im Dokument mit dem Remove Button auf einen Schlag gelöscht werden. Beim Zeilenabstand und der Schriftgröße wird der Benutzer außerdem über den Wertebereich von Benutzereingaben informiert. Die Textoperationen werden in Abbildung 2.17 demonstriert.




Abbildung 2.17 Bearbeiteter Text im Writer der PDF Web App

## Zeichnungen erstellen

Der Drawer ist in Screenshot 2.18 abgebildet.

Das Ebenenmenü und Tools Seitenmenü des Drawers erscheint selbst, wenn man zuerst in einem anderen Editormodul ein Dokument geöffnet hat. Generell braucht man nur einmalig ein PDF zu öffnen und kann dann in die jeweiligen Bearbeitungsmodi jedes Editormoduls wechseln. Um ein neues PDF zu öffnen kann man entweder die PDF Web App neu laden oder man klickt erst auf Read, Create, Split oder Merge und anschließend wieder auf ein Editormodul, damit der Choose file Button erneut angezeigt wird. Mit dem Zeichnen kann man beginnen, indem man auf Pencil klickt. Bei gedrückter Maustaste auf einer PDF Seite erscheint eine schwarze Linie dort wo die Maus sich bewegt hat. Zusätzlich wird an der Stelle, wo man angefangen hat die Maus zu drücken, eine Magenta farbige control box hinzugefügt. Das Zeichnen funktioniert auch mit einem Graphic Tablet. Es wird immer auf der zuletzt gezeichneten Ebene auf der zugehörigen Seite gemalt bzw. wenn man eine Ebene auswählt im Ebenen Seitenmenü wird auf der ausgewählten Ebene gezeichnet. Ein Klick auf New Layer und anschließender Zeichenmodus mit Pencil erstellt für die neue Zeichnung eine weitere Ebene. Wurde auf einer Seite bisher noch nichts gezeichnet, so wird bei der ersten Zeichnung auf dieser Seite eine neue Ebene automatisch angelegt und man muss

The screenshot displays the PDF Web App interface. At the top, a dark toolbar contains buttons for Read, Create, Split, Merge, Text, Draw (highlighted), Shape, and Image. Below this, a navigation bar shows 'Previous', '1' (current page), '9 pages', 'Next', '+', '100%', and '-' (zoom controls), along with 'Min: 1 %' and 'Max: 800 %'. A secondary toolbar below the navigation bar includes Layers, Tools, New Layer, Pencil, Eraser, Delete, Move, Drag, and Save.

The main canvas area is divided into three sections. The top section, titled 'II. Sensoren', contains the text 'Ziel: Gewinnung relevanter Information über die Welt' and a bulleted list under 'Inhalt': 'Sensortypen' and 'Messungsprinzipien'. The middle section, titled 'Sensortypen', contains a bulleted list: 'Interne Sensoren zur Erfassung der roboterinternen Systemzustände', 'Externe Sensoren zur Erfassung der Umwelt', and 'Klassifikation externe Sensoren' (with sub-points: 'taktil', 'Berührungslos', 'akustische/optische/sonstige'). The bottom section, also titled 'Sensortypen', contains a bulleted list: 'Physikalische Eigenschaften'.

On the right side, a green control panel contains various settings: 'Cursor X: 6' and 'Cursor Y: 81'; 'Min: 0.1' and 'Max: 20' for 'Width Factor' (set to 1) and 'Height Factor' (set to 1), with a 'Scale' button; 'Pencil Color' (black square) and a 'Pencil Color' button; 'Pencil/Eraser Size' (set to 4) with 'Min: 0.1' and 'Max: 500', and a 'Pencil Size' button; 'Rotate' (set to 0) and a 'Rotation' button; and a 'Remove' button.

Abbildung 2.18 Drawer der PDF Web App

dafür nicht New Layer drücken. Die Zeichenelemente sind die einzigen Elemente, bei denen der Nutzer selbst die Ebenen einer Seite zuweisen kann mit New Layer. Bei allen anderen Elementen, sei es Text, Geometrie oder Bilder, wird jedes neue Element automatisch einer Ebene zugeteilt. Der Radierer ist mit dem Eraser Button Operations Bar aufrufbar. Zuerst drückt man Eraser und geht dann mit gedrückter Maustaste über die Zeichnungen auf einer Seite, die man entfernen möchte. Auch hier gilt, das auf der ausgewählten Ebene radiert wird. Dort, wo bei gedrückter Maustaste die Maus die Linie berührt, wird die Linie wegradiert. Zeichnen und Radieren bekommen jeweils ein neues Mauscursorsymbol: Beim Zeichnen hat man ein schwarzes dünnes Kreuz und beim Radieren ein weißes dickes Kreuz. Im Tools Seitenmenü kann man eine Zeichnung relativ skalieren, indem man einen Faktor eingibt. Der Faktor kann auch ein Float sein und multipliziert sich immer mit der aktuellen Größe, d.h. die aktuelle Größe wird als 100 % berechnet. Darunter kann man mit dem color picker menu die Farbe und Transparenz der Stiftfarbe definieren. Sie wird mit einem Klick auf Pencil Color auf die nächste Zeichenoperation angewendet. Außerdem definiert sie auch gleichzeitig die Radierfarbe, was sich nur bei Transparenzen unter einem Wert von 1 bemerkbar macht. Ansonsten ist jede Radierfarbe gleich, jedoch bei einer Transparenz von unter 1 radiert der Radierer weniger deckend, so als ob man einen Radiergummi weniger stark auf das Papier drückt. Dann kann man die Größe des Stiftes bzw. Radierers einstellen. Sie greift auch ab der nächsten Zeichnen- bzw. Radieroperation. Ebenfalls kann man Zeichnungen samt radierten Partien absolut rotieren. Wurde eine Zeichnung gedreht, so wird eine weitere Ebene von der Anwendung neu angelegt, falls man versucht, auf eine rotierte Zeichnung zu malen. Zum Schluss kann man mit Remove alle Zeichnungen im Dokument löschen. Teilweise transparente Zeichnungen werden im Bild 2.19 dargestellt.

### Geometrie hinzufügen

Die Startseite des Geometry Editor ist in den Screenshots 2.20 und 2.21 abgebildet.

Der Geometriety kann durch die Buttons Rectangle für Rechteck, Triangle für Dreieck oder Ellipse und einem oder mehreren Klicks auf eine PDF-Seite bestimmt werden. Jedem Shape wird eine orangene control box mehr oder weniger mittig hinzugefügt. Im Tools Seitenmenü des Geometrieditors gibt es eine einzige Operation, die nur auf Dreiecke angewendet werden kann. Es handelt sich um die oberste Einstellung für die Position des dritten Punktes des Dreiecks. Hiermit kann der rechte Punkt der langen Spitze des default Dreiecks bearbeitet werden. Alle anderen Einstellmöglichkeiten können auf allen Geometrieelementen Rechteck, Dreieck und Ellipse arbeiten. Man hat 2 Möglichkeiten einen Shape zu skalieren. Zum einen kann man die Breite und Höhe unabhängig voneinander einstellen, was eine absolute Skalierung bedeutet, oder man verwendet den Skalierungsfaktor, der relativ vergrößert, genauso wie beim Drawer. Für die Shape Umrandungslinien kann man auf der einen Seite die Farbe inklusive Deckkraft und auf der anderen Seite die Breite der Linie justieren. Die Strichfarbe muss mit der Checkbox Use Stroke in Grün eingeschaltet sein, was sie beim ersten Öffnen des Editors auch ist. Deaktiviert man die Use Stroke Checkbox schaltet sich automatisch die Use Fill Checkbox an und umgekehrt. Man kann auch beide Checkboxes

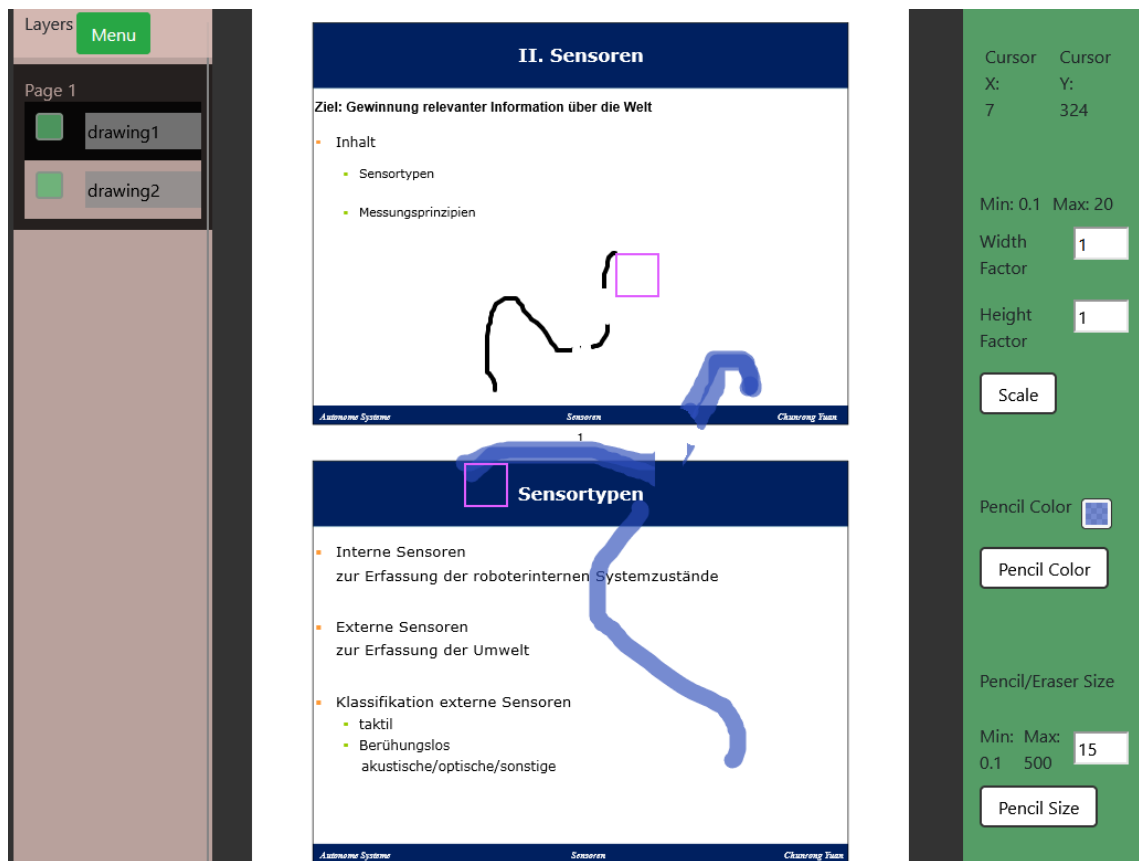


Abbildung 2.19 Zeichnungen im Drawer der PDF Web App

einschalten, aber nicht beide zusammen ausschalten. Ist Use Stroke Rosa, d.h. deaktiviert, und man wendet die Strichbreite an, dann hat Stroke Width keinen Effekt. Use Fill muss Grün sein, um die Füllfarbe anzuwenden. Bei Strich- und Füllfarbe wird ein wie in dem Writer und Drawer der gleiche color picker verwendet. Alle Shapes können mit absoluter Rotation rotiert werden. Die control boxes werden bei den Shapes mitgedreht. Zuunterst entfernt der Remove Button alle Geometrieelemente im geöffneten PDF. Der Screenshot 2.22 hebt mehrere bearbeitete Geometrieelemente hervor.

### Bilder einfügen

Der Image Editor ist im Bild 2.23 dargestellt.

Um ein Bild mit dem Image Button im Operations Bar hinzuzufügen, muss man erst ein Bild mittels dem schwarzen Choose file Button vom Dateisystem ausgewählt haben. Dann erscheint der Bildname wie im Writer bei einem benutzerdefinierten Font in der Liste unter Choose file. Man kann mehrere Bilder nacheinander im Dateidialog auswählen. Sie werden alle in der Liste untereinander angezeigt. Das zuletzt ausgewählte Bild wird zuunterst in der Liste angefügt und ausgewählt. Das Bild muss mit der runden Checkbox in Blau ausgewählt sein, um es mit Image und einem Klick auf eine Dokumentenseite auf dem PDF zu platzieren. Weiße Checkboxes stellen nicht ausgewählte Bilder dar. Mittels des dunkelgrauen Clear Buttons wird die Bildliste gelöscht. Die Bildselektionssektion funktioniert analog zum




Abbildung 2.20 Geometrieeditor der PDF Web App

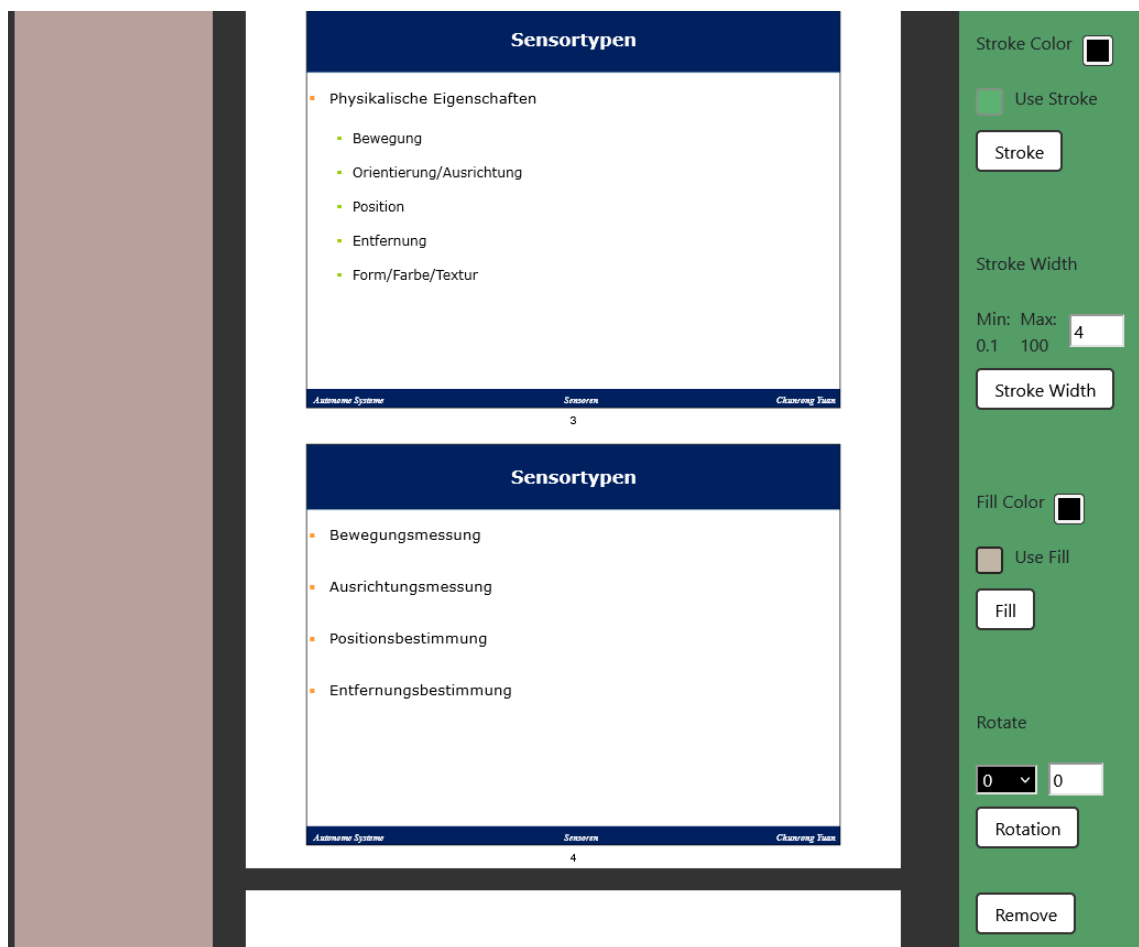


Abbildung 2.21 Mehr Tools des Geometrieditors der PDF Web App




Abbildung 2.22 Shapes im Geometrieeditor der PDF Web App




Abbildung 2.23 Zeichnungen in der PDF Web App



benutzerdefinierten Fontselektionsbereich im Writer. Bei der Bildplatzierung wird eine hellblaue control box dem Bildelement hinzugefügt. Ein Bild kann in Breite und Höhe unterschiedlich absolut skaliert werden und proportional mit einem Skalierungsfaktor relativ verkleinert bzw. vergrößert werden. Unter den Skalierungsoptionen kann man die Deckkraft eines Bildes bestimmen. Ebenfalls kann man ein Bild absolut drehen. Zuletzt können alle hinzugefügten Bildelemente im PDF mit dem Remove Button entfernt werden. Die Abbildung 2.24 zeigt den Image Editor in Aktion.




Abbildung 2.24 Platzierte Bilder im Bildeditor der PDF Web App

### Ebenensteuerung

Die in Abbildung 2.25 gezeigten Ebenenmenüschaltflächen lassen sich mit einem Klick auf Menu im rosa linken Ebenen Seitenmenü hervorholen oder verbergen.

Standardmäßig sind die Schaltflächen eingeklappt. Fügt man ein Element unabhängig vom Typ einer PDF-Seite hinzu wird für dieses Element eine Ebene angelegt, die dann automatisch ausgewählt ist. Eine ausgewählte Ebene ist Rosa und eine abgewählte schwarz. Es können mehrere Ebenen ausgewählt werden. Wenn eine Ebene angelegt wird, bekommt sie einen Standardnamen gesetzt, der durch den Elementtyp und einem numerischen Index




Abbildung 2.25 Ausgeklapptes Ebenenmenu im Editor der PDF Web App

gekennzeichnet ist. Der Standardname kann durch Tastatureingabe im grauen input field auf der Ebene überschrieben werden. Ebenen werden nach Seitenzahlen in einer schwarzen Box, die oberhalb mit der Seitenzahl gekennzeichnet ist, gruppiert. Dies verdeutlicht die Abbildung 2.26.

Im Ebenenschaltflächenmenü kann man zwischen Box Mode und Layer Mode wechseln. Ist der Modus Button grün, so ist der betreffende Modus eingeschaltet. Hingegen ist ein ausgeschalteter Modus mit einem weißen Button versehen. Man kann nur entweder im Box Mode oder im Layer Mode sein, aber nicht in beiden Modi gleichzeitig. Mit dem dunkelgrauen Copy Button kann der Benutzer ausgewählte Ebenen kopieren. Folglich werden die beinhaltenden Elemente dubliziert. Wird eine Ebene kopiert, so wird an den Ebenennamen copy angehängt. Mit Lock und Unlock kann man Ebenen sperren bzw. entsperren. Eine gesperrte Ebene kann nicht verändert werden, d.h. keine Operationen können auf ihr beinhaltendes Element angewendet werden. Eine gesperrte unausgewählte Ebene ist weiß und eine gesperrte ausgewählte ist rosa mit weißer Umrandung, was auf Abbildung 2.27 verdeutlicht wird.

Die dunkelgrauen Select All und Deselect All Buttons stellen Auswahlfilter dar. Bewegt man die Maus auf die Buttons klappt sich ein Filtermenü auf, was im Bildausschnitt 2.28 gezeigt wird.

Bei Select All kann man mehrere Ebenen nach Seiten auswählen, nach Elementtyp und ob sie gesperrt oder nicht gesperrt sind, d.h. die Ebenen werden rosa markiert. Ist ein Filter aktiviert, werden die Buttons im Filtermenü grün. Bei weißen Buttons oder einer leeren Liste an Seiten ist kein Filter aktiviert. Bei der Seitenliste muss man die Seiten durch Komma trennen und sie müssen nicht in aufsteigender Reihenfolge angegeben werden. Die Filter werden mit einem Klick auf Select All angewendet. Ist kein Filter aktiviert, was der Standardzustand ist, so werden alle Ebenen mit Klick auf Select All ausgewählt. Deselect All hat die gleiche Funktionalität, nur dass die Filter zum Auswahl aufheben angewendet werden, d.h. Ebenen werden auf Schwarz gesetzt. Ein Klick auf Deselect All




Abbildung 2.26 Ebenen mit Elementen allen Typs im Editor der PDF Web App




Abbildung 2.27 Teilweise gesperrte Ebenen im Editor der PDF Web App

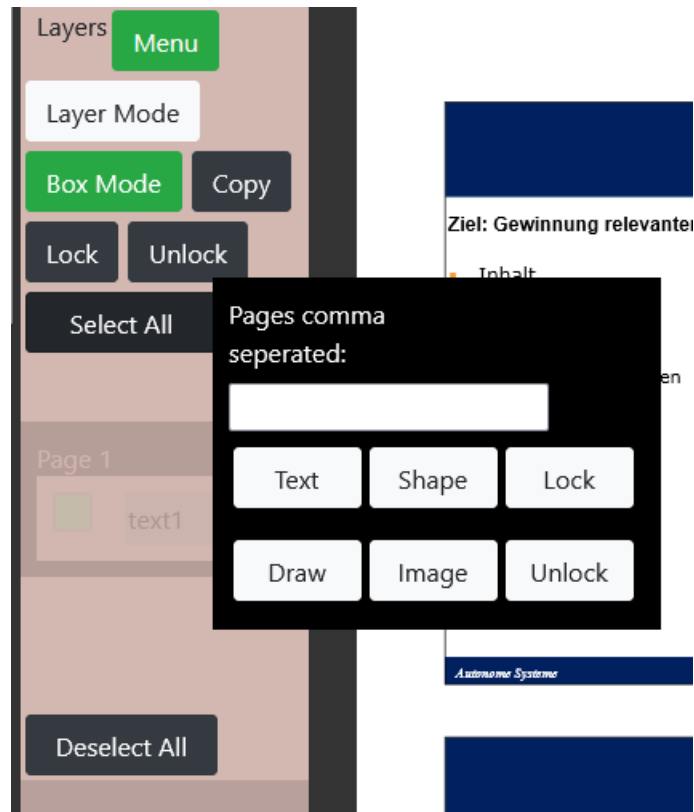


Abbildung 2.28 Selection Filtermenü im Editor der PDF Web App

ohne Filter wählt alle Ebenen im Dokument ab. Im Bildausschnitt ?? ist ein Beispiel von Deselect All Filtern abgebildet. Laut des Beispiels würde die Auswahl auf allen ungesperrten Textelementen auf Seite 1 und 2 aufgehoben werden.

Sowohl bei Select All als auch bei Deselect All habe ich eine Benutzereingabekontrolle beim der Seitenlistenfilter implementiert. Falls der Benutzer ungültige Eingaben gemacht hat, z.B. Seiten als Float oder Strings, so wird die Eingabe bei Auslösung des Filters gelöscht. Leerzeichen können zwischen gültigen Seitenzahlen verwendet werden. Folglich wird Select All bzw. Deselect All so angewendet, als ob kein Filter für die Seiten eingestellt wurde, d.h. aktivierte Filter für Elementtypen oder gesperrte bzw. ungesperrte Ebenen greifen dennoch. Die Reihenfolge der Elemente in der z-Achse kann über die Ebenen gesteuert werden. Man kann ein einzelnes Element mit gedrückter Maustaste auf eine andere Ebene verschieben, um die Position zu ändern, wie Elemente übereinander liegen. Dabei ändert sich das Maussymbol. Man muss zwecks Verschiebung in der z-Achse auf den Ebenen Namen oder auf die rosa Fläche initial die Maus drücken und dann ziehen. Dabei kann man sogar ein Element in eine andere Ebenengruppe ziehen, sodass das Element auf der entsprechenden Seite erscheint. Links neben jedem Ebenennamen ist eine grüne Checkbox abgebildet. Wenn man sie abwählt, färbt sie sich rosa und das Element wird samt control box unsichtbar. Dann können ebenfalls keine Operationen angewendet werden. Ein erneuter Klick auf die Ebenencheckbox schaltet sie wieder in Grün ein und das Element wird auf der Seite erneut sichtbar.

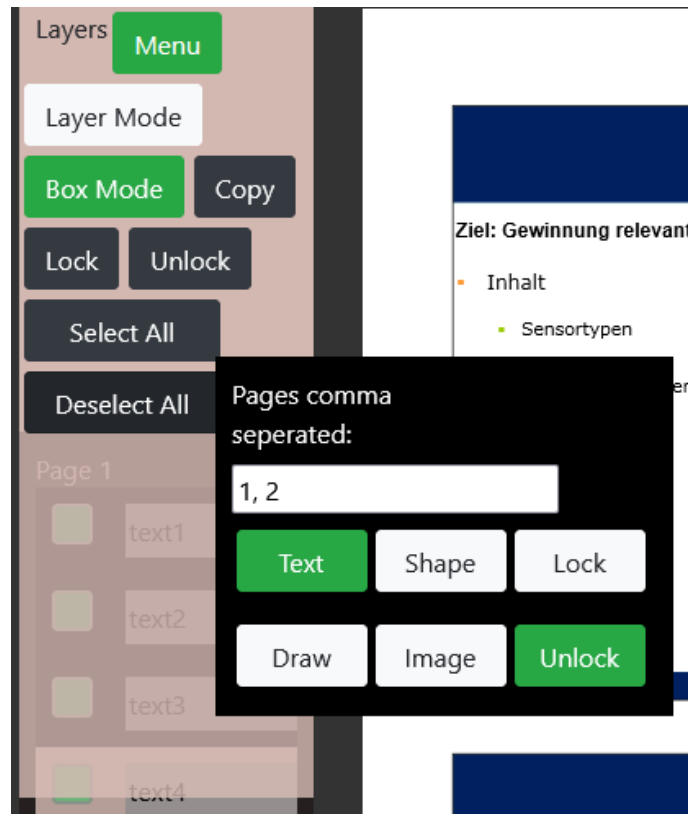


Abbildung 2.29 Deselection Filtermenü mit aktivierten Filtern im Editor der PDF Web App

### Arbeiten im Layer Mode

Ich habe bisher alle Operationen im Box Mode beschrieben. Es gibt außerdem den Layer Mode, den man im Ebenenschaltflächenmenü aktivieren kann. Im Layer Mode kann der Benutzer ein oder mehrere Ebenen auf allen PDF-Seiten selektieren und dann Move, Delete und alle Operationen im Tools Seitenmenü auf sie anwenden. Um dies umzusetzen, muss man bei Tools seine gewünschte Einstellung machen und auf den jeweiligen weißen Button klicken. Sofort werden die Einstellungen auf die selektierten Ebenen mit einem einzigen Klick angewendet. Es ist nicht mehr nötig in irgendeine control box zu klicken. Dabei sind die Einstellungen in Tools elementspezifisch. Wird beispielsweise eine Tools-Einstellung des Writers auf eine Shape Ebene angewendet, wird sie ignoriert. Ist dabei auch noch eine Textebene ausgewählt, so wird die Operation nur auf die Textebene angewendet. Delete und Move können in jedem Editormodul im Layer Mode auf alle Elementtypen angewendet werden. Vor allem bei Move muss man in einer control box, dessen Ebene ausgewählt ist, die Maus drücken und auf eine gewünschte Stelle auf der PDF-Seite ziehen. Alle anderen Ebenen, die zusätzlich ausgewählt wurden, werden mit gleichem proportionalem Abstand zueinander um die gewünschten Verschiebungskoordinaten verschoben. Wenn die control box losgelassen wird, springen die Elemente an die jeweiligen Stellen. Ob man lieber im Box Mode oder Layer Mode arbeitet, ist Geschmackssache. Jeder Modus bringt seine Vor- und Nachteile mit sich, die ich im Kapitel Diskussion und Kritik aufzeigen werde.

## 2.3 Implementierung der PDF Web App

### 2.3.1 Werkzeuge

- Entwicklungsumgebung: Visual Studio Code
- ausführende Programme: Browser Firefox, Opera, Google Chrome, Microsoft Edge
- Sprachen: JavaScript, CSS, HTML
- Libraries: Vue JS 3, PDF-LIB, PDF.js, downloadjs
- PDFelement
- Soda PDF
- Nitro PDF Pro
- Ashampoo PDF Pro 3
- Infix 7
- PDFsam Basic und Advanced
- DrawboardPDF
- PDF Director 2 PRO
- Perfect PDF

## 2.4 Testdurchführung der PDF Web App

### 2.4.1 Funktionale User Tests

### 2.4.2 Stress Tests

### 2.4.3 Browserunterschiede

## 3 Marktübersicht und PDF Wettbewerberprogramme

Die Popularität von PDF-Dateien ist seit 2008 rasant angestiegen in der globalen Informationsübertragung. Täglich werden weltweit 2,5 Milliarden PDF Dokumente erzeugt. Seine Beliebtheit verdankt PDF vor allem an der plattformübergreifenden Kompatibilität (Desktop-Computer, Tablets und Smartphones), denn PDF Dokumente ist auf mehr als 1,5 Milliarden Geräten ohne zusätzliche Software lesbar. Über 80% der geschäftlichen Dokumente werden als PDF Datei weitergegeben. [49] 90 % der Büroangestellten wollen auf das PDF Dateiformat nicht mehr verzichten. Drei Viertel aller archivierten Dokumente sind PDF Dokumente (2023). Bis 2025 werden über 3 Milliarden Dollar jährlich für PDF Editoren ausgegeben werden (2023) [61]. Im Jahr 2015 gab es 1,6 Milliarde PDF-Dokumente im Web und im Jahr 2019 wurden PDF-Dateien bei ca. 99 % Firmen und Regierungsinstitutionen weltweit verwendet [45].

### 3.1 Die Firma Adobe Systems Incorporated

1982 wurde die Firma Adobe Systems Incorporated von John Warnock und Chick Geschke gegründet. Adobe Illustrator war das erste auf PostScript basierende Grafikprogramm, welches 1988 auf den Markt gebracht wurde [8].

### 3.2 Aktueller Stand von Forschung und Technik

Artificial Intelligence (AI) Tools können das Arbeiten mit PDF erleichtern.

Information Extraction (IE) ist eine Unterkategorie von Natural Language Processing (NLP) und ist relevant für die Identifizierung von relevanten Informationen in Text und die Extrahierung dieser Informationen zu spezifischen Output-Formaten. Bei der Relation Extraction (RE) werden relevante Einheiten im Text in Beziehung zueinander gesetzt. Normalerweise wird zunächst eine Texterkennungsphase eingeleitet, in der Stellen identifiziert werden, wo sich Informationen befinden. Auf diese Stellen werden Textboxen generiert. Danach liest die OCR-Engine den Inhalt jeder Box im Bild und konvertiert ihn zu Text. Zuletzt wird ein Algorithmus eingesetzt, der eine post-OCR pipeline oder language model sein kann, um extrahierte Informationen zu klassifizieren. Beispiele für solche Anwendungen sind Amazon Textract und Microsoft Azure AI Document Intelligence. Eine bessere Alternative für OCR-Anwendungen stellt die OCR-freie Lösung Donut dar. Donut ist ein Visual Document Understanding model, was ein Bild als input akzeptiert und textbasierte Aufgaben lösen



kann, wie Informationsgewinnung und Beantwortung von visuellen Fragen. Mit Fokus auf deep learning img2seq Modelle verwendet Donut als Ersatz zur OCR-Technologie einen visuellen Encoder (Swin-B Transformer) und einen Textdecoder (BART). Swin-B ist eine Transformer-Architektur, die speziell auf image processing zugeschnitten ist. Bilder werden vom Transformer in Segmente unterteilt und hierarchisch verarbeitet, um lokale und globale kontextuelle Informationen zu erfassen. Die Bildsegmente werden mittels eines shifted window-based multi-head self-attention Moduls analysiert, um die Beziehungen zwischen benachbarten Segmenten zu erfassen. Danach ermöglicht eine two-layer multilayer perception (MLP)

Amazon Textract ist ein ML-Service, der automatisch Text, Handschrift, Layoutelemente und Daten von gescannten Dokumenten, Bildern oder PDF-Dateien ohne manuelle Konfiguration extrahieren kann. Bei Textract handelt es sich um einen Cloud-Dienst von Amazon Web Services. Im Gegensatz zu traditionellen OCR-Anwendungen kann Textract außerdem strukturierte Informationen aus Tabellen oder Formularen erfassen. Nebst Zeichenerkennung werden auch Formatierungen, sowie die Struktur des Text herausgearbeitet. Der Service kann per Konsole, Command Line Interface (CLI) oder Application Programming Interface (API) verwendet werden. Mittels der Detect Document Text API wird eine OCR-Schnittstelle bereitgestellt, um handschriftliche oder gedruckte Texte aus Dokumenten zu entnehmen. Zusätzlich hat die Analyze Document API das Aufgabenfeld, strukturierte Daten einzulesen und Beziehungen bzw. Schlüsselwertpaare aus Tabellen- oder Formularfelder zu erstellen. Extrahierte Informationen sind mit einem Confidence-Score versehen, um dem Benutzer mitzuteilen, wie exakt und verlässlich die Daten sind. Handschriftlicher und gedruckter Text kann mit hoher Genauigkeit und Zuverlässigkeit erkannt werden. Die Extraktion der Daten geschieht sehr performant in kurzer Zeit. Das Pricing des Produkts ist nutzungsabhängig [62].

Claude 2 von Anthropic ist ein AI assistant, der PDFs parsen und die Dokumentstruktur mittels Machine Learning (ML) Techniken erfassen kann. Es hat eine eingebaute PDF analyser Komponente. Die maximale Dateigröße ist 10 MB. Der Benutzer kann Claude Fragen stellen, die im PDF-Dokument behandelt werden und Claude liefert die Antworten. Direkte Zitate können aus der PDF-Datei gefunden werden und Claude zeigt die Seitenzahl an, wo das Zitat vorkommt. Unglücklicherweise ist Claude zurzeit nicht für Deutschland verfügba [63]r.

Perplexity AI ist ein Werkzeug für NLP mit Dokumenten. Eine PDF-Datei als Dateiformat, plaintext oder Code kann hochgeladen werden und Perplexity verwendet dessen Dateiinhalte, um Antworten auf Fragen zum PDF inklusive Zitate mit Quellenangaben zu formulieren. Bei kurzen Dateien wird das gesamte Dokument beim language model analysiert. Umfangreiche PDFs können manuell in Themenbereiche unterteilt werden und als input für Generative Pre-trained Transformer 4 (GPT-4) für Kreatives Schreiben verwendet werden. Wissenschaftliche Artikel können verglichen, ihre Unterschiede herausgearbeitet, themenverwandte Dokumente durch eine query gefunden, Daten analysiert, Überblicke von verschiedenen Quellen generiert, Daten visualisiert, Grafiken von Quellen erstellt und Text in eine andere Sprache übersetzt

werden. Bei der kostenlosen Version ist der Benutzer auf eine bestimmte Anzahl an Anfragen begrenzt [63].

ChatGPT Plus Mitglieder können seit Oktober 2023 ein PDF-Analysefeature als Beta-Version genießen. Benutzer können PDF-Dateien und andere Dokumente hochgeladen werden und der chatbot kann Zusammenfassungen erstellen und Graphen oder Tabellen basierend auf die Dokument-Daten erstellen [63].

### 3.3 Freie PDF Programme und Onlinedienste

PDF Dateien lassen sich in vielen Programmen einfach über den Druckdialog erstellen. Apple hat das Lesen von PDF Dokumenten in seiner Apples Vorschau integriert. Viele Webbrowser stellen PDF Viewer bereit, so Google Chrome seit 2010 [2].

#### 3.3.1 foxit

Produktseite: <https://www.foxit.com/> Die Firma foxit hat einen kostenlosen PDF Editor auf den Markt gebracht, der sehr umfangreiche Funktionen bietet.

#### 3.3.2 PDF24

Produktseite: <https://www.pdf24.org/en/>

#### 3.3.3 PDFsam

Produktseite: <https://pdfsam.org/>

#### 3.3.4 DrawboardPDF

Produktseite: <https://www.drawboard.com/pdf/pdf>

#### 3.3.5 PDFCreator

PDF Dokumente und Dateien erzeugen

#### 3.3.6 LibreOffice

PDF Dokumente und Dateien erzeugen

### 3.3.7 OpenOffice

PDF Dokumente und Dateien erzeugen

### 3.3.8 ghostscript

## 3.4 Kostenpflichtige PDF Programme und Onlinedienste

### 3.4.1 Adobe Acrobat

Die nicht-Pro Version von Acrobat kann prüfen, ob es sich bei dem geöffneten PDF-Dokument um ein PDF/A-Dokument handelt und auf dessen Konformität prüfen. Zusätzlich kann man sich die Kompatibilität mit anderen PDF-Dateiformaten PDF/X, PDF/E, PDF/VT und PDF/UA anzeigen lassen. [29] Acrobat kann über JavaScript ferngesteuert werden. Dazu muss man die Berechtigung zur Ausführung von JavaScript erteilen. [8]

### 3.4.2 Adobe Acrobat Pro

PDF-Inhalte können bearbeitet und Dokumente mit digitalen Signaturen unterzeichnet werden. [34] Eine PDF-Datei kann in eine PDF/A-Datei inklusive seiner Varianten, PDF/X, PDF/UA, PDF/VT oder PDF/E konvertiert werden. Außerdem kann die Kompatibilität mit diesen Formaten überprüft werden in Preflight-Profilen. [29] Die Barrierefreiheit kann automatisch validiert werden oder ein neues Dokument kann direkt barrierefrei erstellt werden. Adobe Acrobat Pro kann andere Dokumentenformate wie HTML, DOC, DOCX, TXT und RTF in PDF konvertieren, PDF in andere Dateiformate wie Microsoft Word exportieren oder Dokumente unterschreiben. [64] Mit dem Werkzeug Scan & OCR kann man Pixelbilder als PDF und gescannte PDF-Dokumente in ein durchsuchbares PDF umwandeln. [34] Installiert man Acrobat Pro in Windows, steht dem Anwender ein Adobe PDF-Drucker mit entsprechender PPD-Datei zur Verfügung. [8]

### 3.4.3 Onlinetools von Acrobat

Produktseite:

<https://www.adobe.com/de/acrobat/online.html>

<https://www.adobe.com/de/acrobat/online/convert-pdf.html> Mit den Adobe Acrobat Onlinetools kann man über den Browser verschiedene Dateitypen in PDF umwandeln, unter anderem PDF in JPEG oder andere Bildformate, PDF Dateien bearbeiten und Kompression anwenden. Die Onlinetools können außerdem PDF in Word umwandeln. [34] Der Adobe Acrobat PDF-Converter der Onlinetools kann DOCX, DOC, XLSX, XLS, PPTX, PPT, TXT, RTF, JPEG, PNG, TIFF, BMP, sowie Adobe eigene AI-, INDD- und

PSD-Dateien in PDF konvertieren. [64] Die kostenlose Version des PDF-Converters kann nur begrenzt oft genutzt werden.

#### 3.4.4 Acrobat Distiller

In Acrobat Distiller als Software-Interpreter können PostScript-Dateien in PDF konvertiert werden und umgekehrt. Bei der Erstellung einer PDF-Datei schneidet Distiller an der MediaBox-Grenze herausragende Elemente ab. [8]

#### 3.4.5 Microsoft Word

Aus einem Word-Dokument lässt sich in Microsofts Word eine PDF-Datei, inklusive im PDF/A-Dateiformat, erstellen. [29]

#### 3.4.6 pdf-it

Produktseite: <https://www.pdf-it.com/>

#### 3.4.7 PDFelement

Produktseite: <https://pdf.wondershare.com/>

#### 3.4.8 Soda PDF

Produktseite: <https://www.sodapdf.com/>

#### 3.4.9 Nitro PDF Pro

Produktseite: <https://www.gonitro.com/>

#### 3.4.10 Ashampoo PDF Pro 3

Produktseite: <https://www.ashampoo.com/de-ch/pdf-pro>

#### 3.4.11 Infix 7

Produktseite: <https://www.iceni.com/infix.htm>

#### 3.4.12 PDF Director 2 Pro

Produktseite: <https://pdfdirector.de/funktionen>

#### 3.4.13 Perfect PDF

Produktseite: <https://soft-xpansion.de/products/perfect-pdf-12/>

### 3.5 PDF zu Word Programme und Onlinedienste

In PDF ist keine automatische Anpassung des Seiteninhalt-Layouts, wie z.B. in Microsoft Word, möglich. Daher kann ein PDF-Dokument nicht sinnvoll in das Word-Format umgewandelt werden ohne möglicherweise das ursprüngliche PDF-Layout zu beeinflussen und zu ändern, sowie die maximalen Bearbeitungsmöglichkeiten von Word ausschöpfen zu können.

### 3.5.1 UPDF

### 3.5.2 WPS

### 3.5.3 LightPDF

## 3.6 PDF zu Latex Programme und Onlinedienste

## 3.7 Zielgruppenanalyse

### 3.7.1 Soziodemographische Kriterien

### 3.7.2 Psychographische Kriterien

## 3.8 Umfeldanalyse

### 3.8.1 Politische Aspekte

### 3.8.2 Soziographische Aspekte

## 3.9 Relevanz von PDF in verschiedenen Marktbranchen

Die PDF-Datei ersetzt als elektronisches Informationsaustauschformat in privaten Organisationen, Behörden und im Bildungswesen Papier basierte Arbeitsprozesse.

Vor allem in Behörden wird der E-Mail-Verkehr noch frequent verwendet. Starke Kompressionsalgorithmen ermöglichen es, wenig speicherintensive PDF-Dateien auf leichtem Wege per E-Mail verschickt werden.

Die PDF Spezifikation ist offen und sehr detailliert über sämtliche Aspekte des Dateiformats. Dadurch können Softwareunternehmen eigene Programme schreiben, die PDF Dokumente erzeugen, lesen und bearbeiten können.

Durchsuchbare PDFs werden in Verträgen, Rechnungen und Geschäftsunterlagen verwendet, damit Mitarbeiter\*innen Informationen gezielter suchen und Daten abteilungsübergreifend effizienter verwaltet werden können. In Forschungsarbeiten und wissenschaftlichen Artikeln werden durchsuchbare PDFs bei der Überprüfung von Quellen oder dem Extrahieren von Zitaten hauptsächlich verwendet. Behörden, Bibliotheken und Unternehmen digitalisieren Dokumente zur Archivierung und wandeln sie in ein durchsuchbares PDF um, was den langzeitigen Bestand der Dokumente sichert. [34]

Das PDF/A-Dateiformat wird in Bibliotheken und Archiven zur digitalen Archivierung von Büchern, Zeitschriften und historischen Dokumenten verwendet. Auch im Behördenzweig

und Verwaltungssektor hat PDF/A für die Aufbewahrung von Verwaltungsakten und rechtlichen Dokumenten seine Existenzberechtigung. Im Gesundheitswesen wird es außerdem zur Speicherung von Patientenakten und medizinischen Unterlagen verwendet. Hingegen im Finanzwesen werden mit ihm Geschäftsunterlagen und Finanzdokumente verwahrt. Unternehmen und Organisationen können mit PDF/A gesetzliche und Compliance-Vorschriften einhalten. [29]

PDF/VT-Dateien werden im Direktmarketing verwendet. Personalisierte Werbematerialien erhöhen die Wahrscheinlichkeit einer positiven Reaktion bei den Kund\*innen auf die Werbebotschaft und verbessert die Bindung von Unternehmen und Kund\*innen. Der Transaktionsdruck findet bei Finanzdienstleistungen, Versicherungen und E-Commerce besonderen Anklang. Beliebte Transaktionsdokumente sind Rechnungen, Kontoauszüge, Versicherungspolicen oder Bestellbestätigungen. [31]

PDF-Dokumente mit der PDF/UA-Kennzeichnung stärken den Ruf und die Reputation eines Unternehmens oder einer Organisation durch Engagement für Inklusion. [33]

Digitale Signaturen werden bei digitalen Freigabe-, Abnahme-, Genehmigungs- und Vertragsprozesse verwendet. PAdES wird in Rechtssystemen, Finanzwesen und Regierungssektor eingesetzt. [13]

### 3.10 Rolle von PDF in der Druckvorstufe und Designbranche

PDF hat sich zum Standard für den elektronischen Austausch von Dokumenten entwickelt und unterstützt beliebige Seitenformate. Vor allem in der grafischen Industrie wird PDF gerne verwendet, weil es eine plattformübergreifende Visualisierung auf allen Betriebssystemen bietet. Außerdem kann PDF für die schnelle Webansicht optimiert werden. Vor allem Bilder lassen sich ohne sichtbaren Qualitätsverlust und geringem Datenvolumen speichern, da sehr leistungsfähige Kompressionsalgorithmen in PDF implementiert wurden. Im Vergleich zu PostScript-Dateien erzielen die kompaktere Codierung von Seiteninhalten, dem einmaligen Speichern von identischen Bildern und die Verwendung von Kompressionsalgorithmen eine maßgeblich kleinere Dateigröße bei PDF. Korrekturänderungen in PDF-Dateien sind kurz vor dem Druck noch möglich und PDF entwickelte sich zunehmend zum Containerformat für alle grafischen Elemente. Die Produktion von Druckerzeugnissen wird somit wesentlich flexibler und sicherer. Downsampling und Kompression beschleunigt den Transport von der Agentur zum Dienstleistungsbüro enorm. Heute ist es das meist eingesetzte Format bei der Produktion von Druckvorlagen in der digitalen Druckvorstufe. Das Dateiformat funktioniert mit allen Druckern und überwindet Kompatibilitätsprobleme.

Textmodifikationen sind am meisten gefordert in der Druckvorstufe. Farbänderungen bzw. Farbkonvertierungen sind ebenso erforderliche Eingriffe. Änderungen am Layout oder Neugestaltungen von Seiten müssen im Originalprogramm erledigt werden und das modifizierte

PDF muss in das Druck-PDF integriert werden. Ständige visuelle Kontrollen der PDF-Datei des Kunden mit der korrigierten Version werden durch eine Fachkraft im Betrieb durchgeführt. Am Ende jeder Korrektur steht die Prüfung auf PDF/X-Konformität, um als technisches Gütesiegel weitere Fehler für den Druck zu reduzieren.

Für die Betrachtung von Druckvorstufen-PDF-Dateien sollte immer Acrobat Pro bzw. Adobe Reader verwendet werden, da viele Drittanbieter-PDF-Viewer druckvorstufenrelevante Informationen nicht fehlerlos darstellen können. Dank der Profile für unterschiedliche Geräte und Bedruckstoffe, kann eine Simulation des Ergebnisses am Monitor oder durch einen Prüfdruck bewerkstelligt werden. Dadurch steigt die Reproduktionssicherheit bei gleichbleibender Qualität und die Produktionszeiten verkürzen sich enorm. In den meisten Druckprojekten steht zu Beginn noch nicht fest, wann, wo und auf welchem Bedruckstoff gedruckt werden soll. Die zeitintensive Optimierung der Druckdaten kann durch PDF auf einen späteren Zeitpunkt verlegt werden [8].

In der Werbebranche werden PDF-Dateien vor allem für Korrekturabzüge verwendet. Ein Korrekturabzug ist eine Skizze bzw. Designvorlage des Werbeprodukts in vom Kunden gewünschten Position und Größe des Druckmotivs auf dem Werbeartikel. Als digitales Layout wird der Korrekturabzug mit dem Kunden abgestimmt und seine Änderungswünsche vor dem Druck entgegengenommen [65]. Zum Erstellen von PDF-Dateien mit geringer Dateigröße für den Online-Bereich muss der Output-Intent mit dem angehängten ICC-Profil entfernt werden, da ICC-Profile eine eher größere Dateigröße aufweisen. Für eine korrekte farbliche Simulation am Monitor in der Druckvorstufe ist es in einigen Fällen wünschenswert, dass ein Output-Intent gesetzt wird. Bei der Erzeugung einer ISO-konformen PDF-Datei, z.B. bei PDF/X, PDF/A oder PDF/E wird immer ein Output-Intent angelegt. Je nach Standard wird auch das Zielprofil eingebettet. Die direkte Ausgabe von PDF-Dateien über den Druckdialog in Acrobat Pro ist in der Praxis nicht mehr gängig, da alle gängigen Workflow-Systeme auf einem PostScript-3-RIP basieren. Intern konvertiert der PostScript-RIP die PDF-Datei in eine PostScript-Datei automatisch. Die Ausgabe von PostScript aus Acrobat Pro heraus spielt noch für Laserdrucker, Farbkopierer und Broschüren auf Farbdruckern eine Rolle.

In der Ausgabe ist die effektive Auflösung maßgeblich. Effektive Auflösung ist die Bildauflösung, die aus der Anzahl der Bildpunkte und der Fläche resultieren, auf der das Bild platziert wurde. Downsampling beeinflusst diese effektive Auflösung. Starke Artefakte fallen im Offsetdruck weniger auf als im Digitaldruck. Bilder sollten nach der PDF-Bearbeitung anschließend geschärft werden. Das wird vom Datenersteller oftmals vergessen. Falls im Druck-PDF ein falscher Zielfarbraum eingestellt wurde, wirkt sich das auf den Gesamtfarbauftrag aus. Eine Farbraumkonvertierung in den für das Druckergebnis gewünschten Farbraum muss vorgenommen und der maximale Gesamtfarbauftrag muss angepasst werden. Bilder, die nicht im Zielfarbraum vorliegen müssen erst in den Ausgabefarbraum überführt,



separiert ausgegeben und Transparenzen reduziert werden. Jegliche Transparenzen in Objekten, vor allem Texte, Grafiken oder Bilder, werden beim speichern in ein Dateiformat, welches keine Live-Transparenzen unterstützt, reduziert. Zu diesen Dateiformaten gehören u.a. Encapsulated PostScript (EPS), JPEG, GIF, BMP, PDF 1.3 und niedriger. Nach der Transparenzreduzierung sollten für die Ausgabe Quellfarbprofile von den reduzierten Objekten entfernt werden, da sie oftmals zu unerwünschten Farbtransformationen im Ausgabegerät führen können. Das Anbringen von Transparenzen auf Objekte mit Volltonfarben ist mit Ausnahme der Deckkraftänderung verboten. Bilder können unscharf werden, wenn in den meisten Fällen eine zu niedrige Reduzierungsauflösung global eingestellt ist. Der Prozess der Transparenzreduzierung sollte auf den letztmöglichen Zeitpunkt in der Produktion von digitalen Daten verschoben werden.

Von einer medienneutralen Druckproduktion spricht man, wenn die Farbraumkonvertierung der neutral abgespeicherten Daten ausschließlich in RGB oder in RGB und CMYK zu einem möglichst späten Zeitpunkt stattfindet. Bei Logos werden medienneutrale PDF-Dokumente nicht bevorzugt. Durch das medienneutrale Konzept gewinnt man an Flexibilität und reduziert Mehrarbeit im Produktionsprozess, z.B. wenn ein späterer Wechsel des Druckverfahrens und der Papierklasse erfolgt. Der Gegensatz zur medienneutralen Arbeitsweise ist die verfahrensangepasste Arbeitsweise. In der Praxis ist primär der PDF-Empfänger für die Rastereinstellungen des RIPs verantwortlich. Die Anzahl der Sonderfarben ist in keinem PDF/X-Standard beschränkt. In der Verpackungsindustrie werden Mehrkanalproduktionen verwendet. Der Begriff Binding bezeichnet im Prozess der Druckdatenerstellung die Farbkonvertierung in die gewünschten Druckbedingungen. Beim Early Binding liegen alle verfahrensangepasste Daten schon im gewünschten Zielfarbraum vor. Hingegen bei medienneutralen Daten kann bei der PDF-Erzeugung eine Konvertierung in den Zielfarbraum erfolgen. Dies wird als Intermediate Binding bezeichnet. Im Prozess des Late Bindings wird die Konvertierung in den Zielfarbraum bei medienneutralen Daten erst in der Ausgabe vorgenommen.

Vor allem Office-Dokumente müssen für den Druck aufbereitet werden. Marketingabteilungen von Industrieunternehmen sind gezwungen auf die zur Verfügung stehenden Werkzeuge, den Microsoft-Office-Programmen bzw. OpenOffice-Programmen zurückzugreifen bei der Druck-PDF-Erzeugung. Meistens liegen dann alle Objekte in RGB vor, es fehlt die TrimBox und der Anschnitt, sowie keine Einzelseiten-PDFs liegen zum Ausschneiden vor [8]. Ausschneiden bezeichnet den Prozess, dass die einzelnen Seiten des Druckerzeugnisses in der Seitenmontage seitenverkehrt so angeordnet werden, dass sie nach dem Druck und der Weiterverarbeitung (Falzen) die korrekte Reihenfolge vorweisen [16]. Alle RGB-Farbräume müssen nach CMYK umgewandelt werden. Im Besonderen müssen beim Offsetdruck schwarze Texte auf den Farbaufzug K in CMYK gebracht werden. Schmuckfarben werden in CMYK oder eine andere Schmuckfarbe konvertiert bzw. gemappt. Die hinterlegten Alternativ-Farbwerte für Schmuckfarben weichen in der Vielfalt der Programme voneinander ab. Ursächlich ist, dass

unterschiedliche Pantone Libraries implementiert wurden. Häufig sind in PDF-Dateien verschiedene Farbwerte für dieselbe Farbe anzutreffen.

Schriften können bei Einbettung in PDF exakt wiedergegeben werden, unabhängig ob es sich um eine Windows oder MacOS Schrift handelt. Da allgemeine Schriftinformationen immer eingebettet sind und die Zeilenlängen im Prinzip immer stimmen, können Druckvorstufenbetriebe zumindest immer erkennen, welche Schrift bzw. Schriftschnitt der Ersteller der PDF-Datei ursprünglich vorgesehen hatte, falls die Schrift nicht eingebettet wurde. Fehlende Schriften in PDF-Dateien sind in der Druckvorstufe katastrophal. Beim nachträglichen Einbetten von Schriften in letzter Minute muss die richtige Schrift gesucht werden, denn der richtige Schriftname beschreibt nicht notwendigerweise dieselbe Schrift mit derselben Codierung bzw. Laufweite. Fehlende Zeichen, überlappende Buchstaben, unregelmäßige Abstände zwischen den Buchstaben, usw. sind gängige Probleme. Schriften können auch durch die PDF-Bearbeitung extrahiert (ausgebettet) werden. In der Druckvorstufe müssen Schriftbezeichnungen für die Ausgabe eindeutig benannt werden.

In der Praxis werden PDF-Dateien mit Hilfe von Prüfprofilen überprüft, Agenturen entwickeln nach eigenen Kriterien vorgefertigte Prüfroutinen und einen automatisch generierten Prüfbericht (Report). Der Prüfbericht sollte auf schnelle Fehlersuche im überprüften Dokument optimiert sein. Notwendige Korrekturen können im Originaldokument, bei PDF-Erstellung oder im vorliegenden PDF-Dokument ausgeübt werden je nach Schweregrad des Fehlers. Korrekturen im Originaldokument sind vorzuziehen, da sie Folgefehler minimieren können, jedoch liegt der Agentur oftmals nicht das Originaldokument oder ausschließlich eine unvollständige PDF-Datei des Originaldokuments vor. Eine Erstellung von Korrekturprofilen für Änderungen an der gesamten PDF-Datei kann dabei hilfreich sein. Man kann zwischen einer Vielzahl an voreingestellten Prüfprofilen und einer wesentlich kleineren Menge an Korrekturprofilen im Preflight in Adobe Acrobat Pro wählen. Außerdem kann der Prüfbericht als Kommunikationsmittel zwischen Auftraggeber und Agentur dienen, falls der Agentur das Originaldokument nicht ausgehändigt wurde. Das Preflight-Werkzeug in Acrobat Pro ist ein gängiges Werkzeug in der Druckvorstufe. Die Kontrolle von PDF-Dateien mit Preflight kann viel Geld sparen. Im tiefgreifenden Preflight-Check, der ein System vor dessen Einsatz überprüft, kann man die besten Ergebnisse erzielen, wenn das zum Job passende Prüfprofil verwendet wird. Beim Preflighting-Prozess werden fehlerhafte und Objekte mit speziellen Anforderungen gefunden, ihr Zustand abgefragt und dann dementsprechend ein Fehler, eine Warnung oder eine Information ausgegeben. Im Warnungsfall muss die Agentur entscheiden, ob das Objekt, was die Warnung verursacht hat, sich negativ auf das Endprodukt auswirkt. Folglich können durch Preflight frühzeitig Mängel im Produktionszyklus beseitigt werden. Ein Report sollte für die automatisierte Auswertung in weiterführenden Workflow-Systemen im XML-Standard vorliegen. Erfolgreiche selbst erstellte Prüfprofile basieren auf qualitativ hochwertig gewählte Kriterien, wobei nicht zu viele verwendet werden sollten. Prüfprofile können als wichtigste Prüfkriterien das Dokument, Seiten, Bilder, Farbe, Zeichensätze, Rendering und Standard-Konformität enthalten. Nach

der Einbringung von Korrekturen im PDF sollte eine technische und visuelle Überprüfung der Druckdatei stattfinden. In einem korrigierten Kunden-PDF sind die für die Druckerei wichtigen Druck-, Schneide- und Passermarken sowie der Bereich des Anschnitts meistens unerwünscht. Um diesen Bereich und alle Druckmarken unsichtbar zu machen wird die CropBox auf die Größe der TrimBox skaliert. PDF-Dateien, die nicht aus professionellen Anwendungen der Druckvorstufe erstellt worden sind, fehlen in den meisten Fällen die TrimBox bzw. BleedBox. Hat der Datenersteller Schnittmarken sehr genau manuell platziert, so können fast alle PDF-Bearbeitungswerkzeuge davon die TrimBox bzw. BleedBox ableiten. Umschläge und Rücken werden häufig als Druckbogen als einseitiges PDF ausgegeben. Falls der Umschlag versehentlich als PDF-Datei aus Einzelseiten erstellt wurde, müssen diese Seiten zu einem Druckbogen zusammengeführt werden. Für die Weiterverarbeitung sollten leere Seiten und nicht druckbare Objekte, die als solche gekennzeichnet sind oder sich außerhalb des druckbaren Bereichs befinden, entfernt werden. Große Dateien sind bei der Verarbeitung sehr zeitaufwendig und weniger ressourcenschonend. PDF-Dateien können sich durch Output-Intents, eingebettete Dateien, unzureichende Komprimierung von Bildern und Objekten, zu hohe Auflösung und die Präsenz nicht druckbarer Objekte in ihrer Dateigröße aufblähen. Häufig wird in der Agentur ein Abzug-PDF zur Druckfreigabe an den Auftraggeber versandt. Die Seiteninhalte eines Abzug-PDFs sollten gerastert werden, da fehlerhafte Grundeinstellungen im Adobe Reader zu einer abweichenden Darstellung des PDFs im Vergleich zum Aussehen nach dem Druck führen kann. Abzug-PDFs sollten eine Qualität besitzen, die ausreichend ist für eine Ansicht, jedoch für die Produktion bei einem anderen Druckdienstleister nicht genügt und der Output-Intent sollte zwecks Dateigrößenoptimierung entfernt werden. Falls viele Vektoren in einem Druckdokument enthalten sind, würde trotz PDF-Optimierung weiterhin eine hohe Auflösung in Vektorgrafiken bestehen bleiben und folglich nur eine geringe Dateigrößenreduktion erzielt werden. Das Rastern des Inhalts bietet einen praxisnahen Lösungsweg. Hierbei werden zu überdruckende Objekte in das Bild eingerechnet und Vektoren gerendert, wodurch eine maßgebliche Dateigrößenoptimierung erzielt werden kann. Speziell bei PDF/X-Dateien müssen bestimmte Inhalte als Metadaten vorliegen, wie der Dokumententitel, das Änderungsdatum der Datei, das PDF-Erstellerprogramm und das Setzen des Trapping Keys. Jeglicher Schutz oder Sperren sollte an einer druckvorstufentauglichen PDF-Datei vermieden werden, selbst wenn lediglich das Editieren gesperrt ist. Aktionen sind innerhalb druckfähiger Dateien untersagt, unabhängig von JavaScript oder Aktionen von Acrobat.

Das Entfernen von Druckmarken ist für den Datenersteller und die Druckvorstufe, die mehrere Seiten auf einem Druckbogen ausschießen muss, ein gängigere Arbeitsschritt. Die letzte Arbeitsphase im PDF-Workflow ist das Überfüllen bzw. Unterfüllen, um weiße Blitzer zu vermeiden. Spezialisten in der Druckvorstufe sollten das Hinzufügen von Traps übernehmen bzw. über dessen Notwendigkeit entscheiden. Der Druckvorstufenbetrieb gibt dem Auftraggeber den ISO-Standard der PDF-Datei für das Druckerzeugnis vor. Nur wenn sich die Ausgangsdatei mit der zum Druck verwendeten Enddatei in allen Einzelheiten deckt, kann man sich Reklamationen, Geld, Zeit und Diskussionen sparen. Sind die Druckdaten

erstellt, müssen die enthaltenen Druckseiten noch in der Druckvorstufe für die Ausgabe auf die Druckplatte bzw. für die Bebilderung von Digitaldrucksystemen in eine korrekte Anordnung gebracht werden. Dieser Prozess, genannt Ausschießen, wird üblicherweise von der Druckvorstufe digital ausgeführt. In Produktionsumgebungen, wo auf Digitaldrucksystemen direkt ausgegeben wird, muss das Ausschießen auch vom Datenersteller selbst vor Ort vorgenommen werden. Ziel des Ausschusses ist eine schnellere und kostengünstigere Produktion durch die bestmögliche Ausnutzung des Papiers bzw. Materials und nachfolgenden Schritte (Zusammentragen, Binden und Schneiden) der Endverarbeitung zu ermöglichen und vereinfachen. In der Praxis wird am häufigsten der Ausschuss durch eine Softwarelösung nach dem Designprozess praktiziert. Vor allem in der Magazin- und Zeitungsproduktion, wo Personen zu gleicher Zeit auf unterschiedlichen Seiten arbeiten und diese zu schwankenden Zeitpunkten fertigstellen, wird nach dem Designprozess ausgeschossen. Es gibt jedoch auch die Möglichkeiten im Erstellungsprogramm, beim Drucken auf dem Drucker oder im RIP auszuschießen. Da der wirtschaftliche Druck auf die produzierenden Unternehmen immer mehr zunimmt, müssen einzelne Produktionsschritte immer mehr zeitlich gestaucht werden und im Idealfall automatisch ablaufen. Für einen automatisierten PDF-Workflow muss dem Trapping-Key ein eindeutiger Wert zugewiesen werden. Elemente, die nicht für den Druck vorgesehen werden, müssen aus dem druckbaren Bereich entfernt werden [8].

Statische PDF-Dateien sind nicht responsive, d.h. eine optimale Anpassung an verschiedene Endgeräte ist nicht garantiert und sie haben eine lange Ladezeit. Daher erstellt man einen PDF-Online-Blätterkatalog oder ePaper. Es handelt sich um eine Konvertierung von PDF in HTML5 mit entsprechenden Tools. Den PDF-Blätterkatalog kann man in seine Homepage einbinden oder einfach über Social-Media-Kanäle oder per Newsletter teilen [66].

### 3.11 Wettbewerbsanalyse

### 3.12 Unternehmensanalyse

#### 3.12.1 Unternehmensziele

#### 3.12.2 SWOT-Analyse

### 3.13 Marketingstrategie

#### 3.13.1 Produkt

#### 3.13.2 Preis

#### 3.13.3 Promotion

#### 3.13.4 Platzierung

#### 3.13.5 Personal

## 4 Diskussion und Kritik

Es gibt einige Kritikpunkte in meiner PDF Web App, die zur weiteren Diskussion anregen. Eine wichtige Vorgabe habe ich nicht umgesetzt. Ich hatte zuerst einen Print Button im Reader implementiert. Als ich dann später das Drehen von Seiten programmiert habe, hat die Druckfunktionalität zu viele Probleme bereitet, vor allem, dass sie in einem neuen Tab geöffnet werden sollte. Das Problem liegt hauptsächlich an der same-origin policy in Browsern. Die same-origin policy blockiert den Lesezugriff von Ressourcen, die von einer anderen Herkunft geladen werden. Diese Sicherheitsfunktionalität regelt wie Dokumente und Scripte von einer Herkunft mit Ressourcen anderen Ursprungs interagieren [67]. Es gibt einige Optimierungsmöglichkeiten von bestehenden Funktionalitäten. Im Merger kann man jeweils nur einen Listeneintrag von ausgewählten PDFs, die zusammengefügt werden sollen, auswählen. In dem Fall wäre es praktikabler, wenn man mehrere Menüpunkt auswählen könnte und alle mit Remove aus der Liste entfernen könnte. Genauso sinnvoll wäre es im Dateibrowser mehrere PDF-Dateien im Splitter und Merger selektieren und öffnen zu können.

Beim Radieren von Zeichnungen im Draw Editor könnte man die Ebene, wo die Zeichnung komplett weg radiert wurde automatisch entfernen. Zur Zeit funktioniert die PDF Web App in der Art und Weise, dass der Benutzer die leere Ebene manuell löschen muss. Das automatische Entfernen von leeren Ebenen hat Vor- und Nachteile. Eventuell würde es den intuitiven Arbeitsfluss des Nutzers beim Zeichnen stören, falls die Ebene automatisch entfernt würde. Das Zeichnen auf einem Graphic Tablet funktioniert ohne Probleme. Ebenfalls hat die aktuelle Verwendung von absoluter Rotationen von Elementen Vor- und Nachteile. Relative Rotationen könnten ein intuitives Arbeiten ermöglichen und würden Kopfrechenschritte sparen. Jedoch haben absolute Rotationen den Vorteil, dass die Rotation immer gleich ist und somit besser nachvollziehbar für den Benutzer ist. Außerdem kann der Benutzer dann die Rotation zurücksetzen, indem er einen absoluten Rotationswinkel von 0 Grad wählt. Der Nachteil der absoluten Rotation liegt darin, dass bei der Rotation von mehreren Elementen im Layer Mode vorherige Rotationen von Elementen mit der aktuellen Rotation überschrieben werden. In dem Fall sollte man besser im Box Mode Elemente einzeln unterschiedlich rotieren. Hätte ich eine relative Rotation implementiert, würden vorherige Rotationen in den Element erhalten bleiben. Ich bräuchte dann auch keine automatische neue Ebene zu generieren, wenn man eine Zeichnung rotiert hat. Auf der anderen Seite habe ich bei der Skalierung mit einem Skalierungsfaktor auf eine relative Skalierung zurückgegriffen. Das hat den Vorteil, dass man im Layer Mode unabhängig große Objekte gleich skalieren kann. Zumindest beim Geometry und Images Editor kann man auch absolut mit Breite und Höhe skalieren. Beim Drawer gibt es nur den relativen Skalierungsfaktor, der

Breite und Höhe individuell skalieren kann, was ich bei Zeichnungen als sinnvoll erachtet habe. Zeichnungen sind eher ungenau und brauchen eher keine exakte Größe. Mögliche Probleme könnten bei relativer Skalierung entstehen, da es keine Beschränkung für die Größe des relativ skalierten Elements gibt. Da sollte ich zukünftig noch eine untere und obere Schranke einbauen.

Im Box Mode kann man nur control boxen bearbeiten, wenn sie nicht von anderen control boxen verdeckt sind, wie z.B. bei kopierten Elementen. Wenn man die Move operation im Layer Mode auf von anderen control boxen verdeckten Elementen anwenden möchte, d.h. die Ebenen der verdeckten Elemente sind ausgewählt, ist dies ebenso nicht möglich. Diese Probleme können gelöst werden, indem man die Ebenen der Elemente, die man bearbeiten möchte, in den Vordergrund verschiebt. Der Benutzer der PDF Web App könnte zu der Ansicht gelangen, dass die control boxen etwas zu groß sind. Ich habe sie deshalb so riesig gestaltet, weil ich finde, dass die Boxen zum Anklicken von Elementen in Programmen wie Adobe Illustrator zu klein sind und es anstrengender ist für die Augen Elemente in Adobe Illustrator zu bearbeiten. Folglich kann man in meiner PDF Web App möglicherweise nicht so genau gestalten. Grund hierfür ist, dass die Mauscursorpositionen keine Floats anzeigen und es keine Hilfsmittel wie Lineale oder Hilfslinien für Layoutgestaltung gibt. Außerdem gibt es auch keine Farbpipette, wie in Photoshop, wo man einen spezifischen Farbwert von einem Elementpunkt bestimmen kann. Die PDF Web App hat allerdings nicht den Anspruch eine möglichst genaue Anwendung zum Layouten zu sein, sondern soll die gängigsten schnellen Bearbeitungsmöglichkeiten von PDF-Dokumenten anbieten. Möglicherweise könnte ich in Zukunft eine Ansicht des aktuell modifizierten PDF-Dokuments programmieren, wo die control boxen ausgeblendet sind, da sie doch relativ störend beim visuellen Gesamterscheinungsbildes des geöffneten PDF-Dokuments sind.

Die Programmdesignentscheidung für 2 Modi, den Box Mode und Layer Mode, kam mir erst später in den Sinn. Zunächst hatte ich nur den Box Mode implementiert und als ich dann die z-Achsen-Reihenfolge von Elementen durch Ebenen bestimmen wollte, kam mir der Layer Mode in den Sinn, da es doch naheliegend war, mehrere Ebenen mit ihren Elementen zeitsparend zu modifizieren. Der Vorteil meiner Ebenenimplementierung liegt darin, dass Elemente nicht direkt ausgewählt werden müssen, sondern komplett mit einer Ebene verknüpft sind und somit als Ganzes, unabhängig von der Lage im Vordergrund bzw. Hintergrund oder anderen Elementen, modifiziert werden können. Durch die Änderbarkeit der Ebenenreihenfolge kann man sogar Elemente auf andere Seiten ziehen. Eine benutzerdefinierte Gruppierung von Ebenen, nicht nur nach Seiten, würde die Ebenenimplementierung noch bereichern.

Ein großer Pluspunkt der PDF Web App ist, dass sie nicht installiert werden muss. Dabei werden auch keine zusätzlichen ungewünschten Werbeprogramme im System des Benutzers installiert. Das bedeutet auch, dass keine Deinstallationsdateien übrig bleiben. Ich unterstütze keine Verschlüsselung von PDF-Dokumenten, da PDF-Dateien unsicher sind und nicht für vertraulichen Inhalt verwendet werden sollten. In Zukunft könnte ich versuchen, eine sichere Verschlüsselung zu implementieren, was eher mehr Zeit in Anspruch nehmen

wird.

Insgesamt ist die leichte Bedienbarkeit der PDF Web App zumindest im Editor nicht ganz gelungen. Für das Verständnis von Box Mode und Layer Mode, sowie deren Vorzüge, muss man die Tutorials gelesen haben. Auch die Select All und Deselect All Filter sind nicht ganz eingängig. Als einzige Buttons sind Spin CW (clockwise) und Spin CCW (counterclockwise) weniger aussagekräftig beschriftet.

## 4.1 Erfahrungen bei der Programmierung der Tablet-Version

Vorzugsweise hätte ich die PDF Web App auch auf dem Tablet auf Android und iOS zum Laufen gebracht. Das GUI Layout der PDF Web App ist für eine Tablet-Version optimiert. Zunächst habe ich herausgefunden, dass man auf Android und iOS Browsern keine lokalen HTML-Dateien ausführen kann. Folglich musste ich einen lokalen Webserver auf dem Tablet starten, um per localhost:<port> die Webseite im Browser des Tablets aufrufen zu können. Zu der Zeit hatte ich noch nicht gewusst, dass man die PDF Web App mit Github Pages als kostenlose Webseite betreiben kann. Auf Android hatte ich damals die kostenlose Play Store App Simple HTTP Server gefunden. Diese Play Store App ist unter folgendem Link zu finden:

<https://play.google.com/store/apps/details?id=com.phlox.simpleserver&hl=de&pli=1>

Ich konnte dann im Firefox Browser auf dem Android Tablet die PDF Web App öffnen. Auf dem iPad war es nicht möglich einen lokalen Webserver zu starten und den Browser seiner Wahl für die Seite zu öffnen. Da ich mich im kostenlosen Sektor bewegen wollte, musste ich einen lokalen Webserver auf einem anderen Gerät als dem iPad starten. Als habe ich einen simplen Node JS HTTP-Server mit Express programmiert. Erst dann konnte ich über die IP-Adresse und Port meines Windows-Laptops die PDF Web App auf dem iPad mit dem Browser meiner Wahl testen. Eine andere Möglichkeit auf dem iPad war die iOS App Codesandbox oder iOS App Documents herunterzuladen. Im Folgenden sind die Links zu diesen Apps aufgeführt:

<https://codesandbox.io/codesandbox-for-ios>

<https://apps.apple.com/us/app/documents-file-manager-vpn/id364901807>

Mittels diese Apps konnte ich zumindest die PDF Web App in den eingebauten Browsern der Apps verwenden. Jedoch hat mit diesen Apps kein Dateidownload funktioniert.

Im Verlauf der Implementierung habe ich viele Probleme feststellen können und eine Menge gelernt. Die Mouse Events mousedown, mousemove, mouseup und alle drag Events werden auf dem Tablet nicht ausgeführt. Folglich funktionierten der Pencil, der Eraser, die Move Operationen, das Verschieben von Ebenen in allen Editormodulen und das Position



Ändern von Listeneinträgen im Merger allesamt nicht. Auf Stackoverflow hatte ich dann eine Lösung für meine Mouse mousedown, mousemove und mouseup Events gefunden: Ich muss mousedown mit touchstart, mousemove mit touchmove und mouseup mit dem touchend Event ersetzen. Zusätzlich musste ich event.clientX und event.clientY wie folgt im Codebeispiel ersetzen:

```

1  const clientXReplace = (e.targetTouches[0] ? e.targetTouches[0].pageX : e
    .changedTouches[e.changedTouches.length-1].pageX);
2  const clientYReplace = (e.targetTouches[0] ? e.targetTouches[0].pageY : e
    .changedTouches[e.changedTouches.length-1].pageY);

```

Listing 4.1 e.clientX und e.clientY Ersetzung

Diese Lösung hat jedoch nicht für drag Events funktioniert, d.h. das Verschieben von Ebenen im Editor und Listenelementen im Merger hat mit der Maus nicht funktioniert. Daher habe ich die dragdroptouch JavaScript Library eingebaut. Sie ist auf der folgenden Webseite zu finden:

<https://github.com/Bernardo-Castilho/dragdroptouch>

Mit dieser Library haben zwar die drag Events funktioniert, allerdings nicht mehr die touch Events. Die touch Events wurden auch überschrieben. Eine Lösung habe ich bisher nicht gefunden. Möglicherweise wäre folgende jQuery Library UI Touch Punch zielführend:

<https://github.com/furf/jquery-ui-touch-punch>

Jedoch habe ich diese Library noch nicht ausprobiert, da ich mich dann gegen eine Tablet-Version der PDF Web App entschieden hatte. Dies könnte ein Projekt für die Zukunft sein.

#### 4.1.1 Bewertung der Tests und Performance der PDF Web App

## 4.2 Ideen für zukünftige Releases der PDF Web App

Einige wichtige Funktionalitäten sind noch nicht implementiert und ich plane diese noch in die PDF Web App in den nächsten Releases einzubauen. In meiner PDF Web App fehlt die Spiegelung von Text, Zeichnungen, Geometrie und Bildern als wichtige affine Transformation. Die anderen Transformationen Verschiebung, Skalierung und Rotation sind bereits in der PDF Web App vorhanden. Außerdem fehlt die Searchable PDF-Eigenschaft im Reader bzw. Editor, d.h. der Benutzer kann keinen Text oder Bilder kopieren. Die Searchable PDF-Eigenschaft kann nicht genutzt werden, da ich die PDF Seiten des source Dokuments in Canvas HTML-Elemente rendere. Folglich werden alle Seiten gerastert und die Searchable PDF-Eigenschaft des source Dokuments geht verloren. Am besten benutze ich für diese Eigenschaft eine OCR-JavaScript Library, die jedes geöffnete PDF in Searchable PDFs umwandeln kann. Ein fortschrittliches zukünftige Feature wäre die Editierung von bereits bestehenden Objekten im source Dokument bearbeiten zu können.

Möglicherweise ist dies auch mit der OCR-Technologie realisierbar. Im weiteren Verlauf des Projekts möchte ich unbedingt Text, Geometrie und Zeichnungen mit Vektorpfaden ersetzen. Falls der Browser oder Computer abstürzt und das in der PDF Web App geöffnete Dokument nicht gedownloaded wurde, sind die Daten verloren. Als Gegenmaßnahme könnte man einen Export und Import Button konfigurieren, der die hinzugefügten PDF-Objekte als JavaScript Object Notation (JSON)-Datei speichert. Bei Export würde diese Datei angelegt und im Ordner der PDF Web App gespeichert werden und mittels Import könnte man die PDF-Objekte dem geöffneten Dokument hinzufügen, sodass sie weiter bearbeitet werden können. Zusätzlich könnte man einen automatischen Export der PDF-Objekte als Backup implementieren, der z.B. alle 10 Minuten die hinzugefügten Elemente wie Text, Zeichnungen, Geometrie und Bilder in der JSON-Datei sichert.

Eine Funktionalität, die ich oft benötige, ist die Kompression von PDF-Dokumenten. Anfangs wollte ich gerne eine Funktion dafür bieten, jedoch hatte ich keine geeignete JavaScript-Library für Kompression gefunden. Ich habe darauf verzichtet die Kompression selbst zu implementieren. Nichtsdestotrotz, wurde eine Komprimierung in der PDF-LIB implementiert, die selbst zum Tragen kommt, wenn man am source PDF keine Veränderungen gemacht hat.

## Fazit und Ausblick

## Literatur

- [1] Wikipedia. „PDF.“ (2023), Adresse: <https://en.wikipedia.org/wiki/PDF> (besucht am 23.12.2023).
- [2] Wikipedia. „Portable Document Format.“ (2023), Adresse: [https://de.wikipedia.org/wiki/Portable\\_Document\\_Format](https://de.wikipedia.org/wiki/Portable_Document_Format) (besucht am 19.12.2023).
- [3] Wikipedia. „Offener Standard.“ (2023), Adresse: [https://de.wikipedia.org/wiki/Offener\\_Standard](https://de.wikipedia.org/wiki/Offener_Standard) (besucht am 20.12.2023).
- [4] Wikipedia. „Royalty-free.“ (2023), Adresse: <https://en.wikipedia.org/wiki/Royalty-free> (besucht am 23.12.2023).
- [5] Tobias Lang. „Was ist ein Farbraum?“ (2016), Adresse: <https://themen.rainbowprint.de/farbraum/> (besucht am 30.12.2023).
- [6] Adobe Inc. „Pfade und Formen, Grundlagen.“ (2023), Adresse: <https://helpx.adobe.com/de/indesign/using/paths-shapes.html> (besucht am 30.12.2023).
- [7] Typografie.info. „PostScript Type 0, Bedeutung/Definition.“ (o. D.), Adresse: <https://www.typografie.info/3/wiki.html/p/postscript-type-0-r43/> (besucht am 20.12.2023).
- [8] H. P. Schneeberger, *PDF in der Druckvorstufe das umfassende Handbuch, PDF-Dateien erstellen, prüfen, korrigieren und ausgeben; PDF/X-1a bis PDF/X-5 sicher im Griff; Preflighting, Automatisierung, Standards u.v.m.* (Galileo Design), de. Bonn: Galileo Press, 2014, 910 S., Für Beruf und Ausbildung, ISBN: 978-3-642-38552-0.
- [9] D. S. Peter Bühler Patrick Schlaich, *PDF, Grundlagen - Print-PDF - Interaktives PDF*, de. Berlin: Springer-Verlag GmbH Deutschland, 2018, 97 S., ISBN: 978-3-662-54615-4. DOI: 0.1007/978-3-662-54615-4.
- [10] Soft Xpansion GmbH & Co. KG. „PDF: Grundlagen eines Dateiformats.“ (2013), Adresse: <https://soft-xpansion.com/files/cc/PDF-Grundlagen.pdf> (besucht am 21.12.2023).
- [11] Wikipedia. „XFA.“ (2023), Adresse: <https://en.wikipedia.org/wiki/XFA> (besucht am 21.12.2023).
- [12] Adobe Inc. „PDF-Ebenen.“ (2023), Adresse: <https://helpx.adobe.com/de/acrobat/using/pdf-layers.html> (besucht am 23.12.2023).

- 
- [13] Adobe Inc. „PAdES: Elektronische Signaturen in PDF-Dokumenten. Für was steht die Abkürzung PAdES, welche Vorteile hat das Format und wie kannst du selbst ein Dokument digital signieren. Wir zeigen es dir.“ (o. D.), Adresse: <https://www.adobe.com/de/acrobat/resources/document-files/pdf-types/pades.html> (besucht am 26. 12. 2023).
- [14] Adobe Inc. „PDF/E: das Dateiformat für Engineering und technische Kommunikation. Erfahre, was PDF/E-Dateien auszeichnet, in welchen Bereichen sie Anwendung finden und wie du selbst eine PDF/E-Datei erstellst.“ (o. D.), Adresse: <https://www.adobe.com/de/acrobat/resources/document-files/pdf-types/pdf-e.html> (besucht am 26. 12. 2023).
- [15] Adobe Inc. „PDF/X-Dateien: effizienter drucken. Wir erklären dir, was man unter PDF/X-Dateien versteht, wie sie genau funktionieren und was der Unterschied zu originären PDFs ist.“ (o. D.), Adresse: <https://www.adobe.com/de/acrobat/resources/document-files/pdf-types/pdf-x.html> (besucht am 26. 12. 2023).
- [16] bm - gesellschaft für bildung in medienberufen mbh Köln, *Stoffsammlung Mediengestalter*, de. Köln, o. D., 190 S.
- [17] aktuelle-druckinfos.de. „Halbton- und Vollton.“ (o. D.), Adresse: <https://www.aktuelle-druckinfos.de/wiki-halbton-und-vollton> (besucht am 30. 12. 2023).
- [18] Adobe Inc. „Vollton- und Prozessfarben, Grundlagen.“ (2023), Adresse: <https://helpx.adobe.com/de/indesign/using/spot-process-colors.html> (besucht am 30. 12. 2023).
- [19] ENZYKLO.DE DEUTSCHE ENZYKLOPÄDIE. „Strichbild Bedeutung.“ (o. D.), Adresse: <https://www.enzyklo.de/Begriff/Strichbild> (besucht am 30. 12. 2023).
- [20] BenQ. „ICC-Profil Grundlagen.“ (2021), Adresse: <https://www.benq.eu/de-de/knowledge-center/knowledge/icc-profile-basics.html> (besucht am 20. 12. 2023).
- [21] PREPRESS Secrets. „Die Rolle des Profile Connection Space.“ (2015), Adresse: [https://www.prepress-secrets.at/index\\_files/profile-connection-space.html](https://www.prepress-secrets.at/index_files/profile-connection-space.html) (besucht am 20. 12. 2023).
- [22] PROJECT CONSULT. „PDF Standards.“ (o. D.), Adresse: <https://www.project-consult.de/themen/pdf-standards/> (besucht am 23. 12. 2023).
- [23] Adobe Inc. „Tranzparenz-Reduzierung (Acrobat-Pro), Transparenzen sind ein gern genutztes Stilmittel in der Gestaltung. Bei der Vorbereitung für den Druck müssen sie allerdings in der Regel reduziert werden. Was heißt das?“ (2023), Adresse: <https://helpx.adobe.com/de/acrobat/using/transparency-flattening-acrobat-pro.html> (besucht am 30. 12. 2023).
- [24] Primus-Print.de Die Besten drucken online. „Transparenzen.“ (o. D.), Adresse: <https://www.primus-print.de/daten/transparenzen/> (besucht am 30. 12. 2023).
- [25] Adobe Inc. „Work with color profiles.“ (2023), Adresse: <https://helpx.adobe.com/photoshop/using/working-with-color-profiles.html> (besucht am 30. 12. 2023).

- 
- [26] fine art printer. „Tiefenkompensierung.“ (o. D.), Adresse: <https://www.fineartprinter.de/ger/FAQ/Tiefenkompensierung> (besucht am 30.12.2023).
- [27] Akash Choudhary. „callas software presents pdfDPartner, the first free DPart metadata viewer.“ (2021), Adresse: <https://pdfa.org/callas-software-presents-pdfdpartner-the-first-free-dpart-metadata-viewer/> (besucht am 30.12.2023).
- [28] callas. „Check for print and prepress related PDF 2.0 features.“ (o. D.), Adresse: <https://help.callassoftware.com/m/pdftoolbox/1/1608299-check-for-print-and-prepress-related-pdf-2-0-features> (besucht am 30.12.2023).
- [29] Adobe Inc. „PDF/A: Wie unterscheidet es sich von PDF? Erfahre, was PDF/A-Dateien auszeichnet, was der Unterschied zu einem PDF ist und wie du selbst eine PDF/A-Datei erstellen kannst.“ (o. D.), Adresse: <https://www.adobe.com/de/acrobat/resources/document-files/pdf-types/pdf-a.html> (besucht am 25.12.2023).
- [30] Adobe Inc. „Revisionssichere Archivierung mit einem Dokumentenmanagementsystem (DMS). Lerne, wie du Dateien revisionssicher mit einem Dokumentenmanagementsystem archivierst.“ (o. D.), Adresse: <https://www.adobe.com/de/acrobat/resources/audit-proof-archiving.html> (besucht am 25.12.2023).
- [31] Adobe Inc. „PDF/X-Dateien: effizienter drucken. Wir erklären dir, was der ISO-Standard PDF/VT bedeutet, wofür du den Dateityp brauchst und wie du selbst ein PDF/VT erstellen kannst.“ (o. D.), Adresse: <https://www.adobe.com/de/acrobat/resources/document-files/pdf-types/pdf-vt.html> (besucht am 26.12.2023).
- [32] Mozilla. „MIME types (IANA media types).“ (o. D.), Adresse: [https://developer.mozilla.org/en-US/docs/Web/HTTP/Basics\\_of\\_HTTP/MIME\\_types](https://developer.mozilla.org/en-US/docs/Web/HTTP/Basics_of_HTTP/MIME_types) (besucht am 01.01.2024).
- [33] Adobe Inc. „PDF/UA: So erstellst du barrierefreie PDFs. PDF/UA: So erstellst du barrierefreie PDFs. Wir erklären dir, was eine PDF/UA-Kennzeichnung ist, wofür du sie brauchst und wie du selbst barrierefreie PDF-Dokumente erstellen kannst.“ (o. D.), Adresse: <https://www.adobe.com/de/acrobat/resources/document-files/pdf-types/pdf-ua.html> (besucht am 26.12.2023).
- [34] Adobe Inc. „So erstellst du ein durchsuchbares PDF. Lerne, was ein Searchable PDF ist, welche PDF-Arten es gibt und wie du selbst eine durchsuchbare PDF-Datei erstellst.“ (o. D.), Adresse: <https://www.adobe.com/de/acrobat/resources/document-files.html> (besucht am 25.12.2023).
- [35] Wikipedia. „Internationale Beleuchtungskommission.“ (2023), Adresse: [https://de.wikipedia.org/wiki/Internationale\\_Beleuchtungskommission](https://de.wikipedia.org/wiki/Internationale_Beleuchtungskommission) (besucht am 30.12.2023).
- [36] Wikipedia. „International Commission on Illumination.“ (2023), Adresse: [https://en.wikipedia.org/wiki/International\\_Commission\\_on\\_Illumination](https://en.wikipedia.org/wiki/International_Commission_on_Illumination) (besucht am 30.12.2023).
- [37] PrintWiki, The Free Encyclopedia of Print. „Open Prepress Interface.“ (o. D.), Adresse: [http://printwiki.org/Open\\_Prepress\\_Interface](http://printwiki.org/Open_Prepress_Interface) (besucht am 20.12.2023).

- 
- [38] HELIOS. „Welche Vorteile hat DeviceN für die Druckvorstufe?“ (o. D.), Adresse: [https://www.helios.de/web/DE/news/deviceN\\_prepress.html](https://www.helios.de/web/DE/news/deviceN_prepress.html) (besucht am 20.12.2023).
- [39] Proof.de. „Schwarzpunktkompensation.“ (o. D.), Adresse: <https://www.proof.de/lexikon/schwarzpunktkompensation/> (besucht am 30.12.2023).
- [40] TechTarget. „PPD file (Postscript Printer Description file).“ (o. D.), Adresse: <https://www.techtarget.com/whatis/definition/PPD-file-Postscript-Printer-Description-file> (besucht am 29.12.2023).
- [41] Wikipedia. „Seitenbeschreibungssprache.“ (2021), Adresse: <https://de.wikipedia.org/wiki/Seitenbeschreibungssprache> (besucht am 20.12.2023).
- [42] Adobe Inc. „PostScript, LANGUAGE REFERENCE third edition.“ (1999), Adresse: <https://web.archive.org/web/20090419181826/http://www.adobe.com/devnet/postscript/pdfs/PLRM.pdf> (besucht am 20.12.2023).
- [43] Wikipedia. „PostScript.“ (2023), Adresse: <https://de.wikipedia.org/wiki/PostScript> (besucht am 19.12.2023).
- [44] Ange Albertini. „PDF 101 & PDF Secrets, Learning the PDF basics, applying it to hide/reveal informations in documents.“ (2014), Adresse: [https://media.ccc.de/v/MRMCD2014\\_-\\_6007\\_-\\_en\\_-\\_grossbaustelle\\_ber\\_-\\_201409051830\\_-\\_pdf\\_101\\_pdf\\_secrets\\_-\\_ange\\_albertini](https://media.ccc.de/v/MRMCD2014_-_6007_-_en_-_grossbaustelle_ber_-_201409051830_-_pdf_101_pdf_secrets_-_ange_albertini) (besucht am 29.12.2023).
- [45] Fabian Ising, Vladislav Mladenov. „How to Break PDFs, Breaking PDF Encryption and PDF Signatures.“ (2019), Adresse: [https://media.ccc.de/v/36c3-10832-how\\_to\\_break\\_pdfs](https://media.ccc.de/v/36c3-10832-how_to_break_pdfs) (besucht am 29.12.2023).
- [46] Julia Wolf. „OMG WTF PDF, What you didn't know about Acrobat.“ (2011), Adresse: [https://media.ccc.de/v/27c3-4221-en-omg\\_wtf\\_pdf](https://media.ccc.de/v/27c3-4221-en-omg_wtf_pdf) (besucht am 29.12.2023).
- [47] Ido Solomon. „BADPDF, Stealing Windows Credentials via PDF Files.“ (2019), Adresse: <https://media.ccc.de/v/gpn19-45-badpdf-stealing-windows-credentials-via-pdf-files> (besucht am 29.12.2023).
- [48] FILEFORMAT. „PDF File Format, What is a PDF file?“ (o. D.), Adresse: <https://docs.fileformat.com/pdf/> (besucht am 01.01.2024).
- [49] Mehmet Bayram, formilo. „Popularität und Statistiken der PDF.“ (o. D.), Adresse: <https://www.formilo.com/pdf-formulare/einfuehrung/popularitaet-statistiken/> (besucht am 19.12.2023).
- [50] PDF Insecurity. „Attacks on PDF Certification (May 2021).“ (2021), Adresse: <https://www.pdf-insecurity.org/index.html> (besucht am 03.01.2024).
- [51] DocuSign. „Understanding digital signatures, What is a digital signature, and how can you create one?“ (o. D.), Adresse: <https://www.docusign.com/how-it-works/electronic-signature/digital-signature/digital-signature-faq> (besucht am 01.01.2024).

- 
- [52] Fabian Ising, Vladislav Mladenov. „HOW TO BREAK PDF SECURITY, How to Break PDF Signature / How to Break PDF Encryption.“ (2019), Adresse: <https://www.pdf-insecurity.org/download/2019-12-27-36c3-pdf-security.pdf> (besucht am 05.01.2024).
- [53] Jens Müller, Fabian Ising, Vladislav Mladenov, Christian Mainka, Sebastian Schinzel, Jörg Schwenk. „PDFex: Major Security Flaws in PDF Encryption.“ (2019), Adresse: <https://web-in-security.blogspot.com/2019/09/pdfex-major-security-flaws-in-pdf.html> (besucht am 02.01.2024).
- [54] Y. L. Jonathan Katz, *Introduction to MODERN CRYPTOGRAPHY, Third Edition* (A CHAPMAN & HALL BOOK), en. Boca Raton, Florida: CRC Press, 2021, 626 S., ISBN: 978-135-11330-36.
- [55] studyflix. „AES Verschlüsselung.“ (o. D.), Adresse: <https://studyflix.de/informatik/aes-verschlüsselung-1611> (besucht am 02.01.2024).
- [56] Baivab Kumar Jena. „What Is AES Encryption and How Does It Work?“ (2023), Adresse: <https://www.simplilearn.com/tutorials/cryptography-tutorial/aes-encryption> (besucht am 02.01.2024).
- [57] Wikipedia. „Advanced Encryption Standard.“ (2023), Adresse: [https://en.wikipedia.org/wiki/Advanced\\_Encryption\\_Standard](https://en.wikipedia.org/wiki/Advanced_Encryption_Standard) (besucht am 05.01.2024).
- [58] Prof. Norbert Pohlmann. „Was ist eine Cipher Block Chaining Mode oder CBC-Mode?“ (2022), Adresse: <https://norbert-pohlmann.com/glossar-cyber-sicherheit/cipher-block-chaining-mode-cbc-mode/> (besucht am 05.01.2024).
- [59] J. Schwenk, *Sicherheit und Kryptographie im Internet, Theorie und Praxis 5. Auflage*, de. Wiesbaden: Springer Vieweg, 2020, 519 S., ISBN: 978-3-658-29260-7. DOI: 10.1007/978-3-658-29260-7.
- [60] seald. „3 common mistakes when implementing encryption.“ (2023), Adresse: <https://www.seald.io/blog/3-common-mistakes-when-implementing-encryption> (besucht am 03.01.2024).
- [61] Oliver Helfrich, KOFAX. „30 Jahre PDF, Ein Geschenk, das uns immer wieder neu überrascht.“ (2023), Adresse: <https://www.kofax.de/learn/blog/30-years-of-pdf> (besucht am 19.12.2023).
- [62] Dipl.-Ing. Stefan Luber, Nico Litzel. „Was ist Amazon Textract?“ (2021), Adresse: <https://www.bigdata-insider.de/was-ist-amazon-textract-a-1036542/> (besucht am 20.01.2024).
- [63] Jorge Villegas. „How Good is the Claude 2 AI at Working With PDFs? Let’s Find Out.“ (2023), Adresse: <https://hackernoon.com/how-good-is-the-claude-2-ai-at-working-with-pdfs-lets-find-out> (besucht am 20.01.2024).
- [64] Adobe Inc. „Dokumentenformate: Alles, was du wissen musst.“ (o. D.), Adresse: <https://www.adobe.com/de/acrobat/resources/document-files.html> (besucht am 20.12.2023).



- [65] Promotional Blog. „Korrekturabzug.“ (o. D.), Adresse: <http://www.promotional-blog.de/glossary/korrekturabzug/> (besucht am 30.12.2023).
- [66] Kerstin Merber. „PDF Blätterkatalog erstellen und das hochwertige Ergebnis in wenigen Minuten sehen.“ (o. D.), Adresse: <https://mypdf.me/blaetterbare-pdf/pdf-blaetterkatalog/> (besucht am 01.01.2024).
- [67] Mariko Kosaka. „Same-origin policy.“ (2018), Adresse: <https://web.dev/articles/same-origin-policy> (besucht am 08.01.2024).

## Tabellenverzeichnis

## Abbildungsverzeichnis

1.1	Adobe PDF Icon [1]	2
1.2	verschachtelte PDF-Boxen [2]	24
1.3	Header und Beginn eines Bodys des PDF-Dateiformats in Notepad++	25
1.4	Header, Beginn eines Bodys mit Katalog und Binärdaten des PDF-Dateiformats in Notepad++	26
1.5	PDF Bodyauszug des PDF-Dateiformats in Notepad++	26
1.6	PDF Xref des PDF-Dateiformats in Notepad++	27
1.7	Kurzer Trailer des PDF-Dateiformats in Notepad++	27
1.8	Ende einer Xref und Trailer des PDF-Dateiformats in Notepad++	27
1.9	incremental update mit digitaler Signatur [52]	31
1.10	ISA-Methoden mit anfälligen PDF-Viewern [52]	31
1.11	SWA-Methodik [52]	32
1.12	USF-Varianten [52]	32
1.13	Direct exfiltration attack mittels subit-form OpenAction [45]	34
1.14	AddRoundKey-Schritt im AES-Algorithmus [57]	35
1.15	SubBytes-Schritt im AES-Algorithmus [57]	35
1.16	ShiftRows-Schritt im AES-Algorithmus [57]	35
1.17	MixColumns-Schritt im AES-Algorithmus [57]	36
1.18	CBC mode Verschlüsselung und Entschlüsselung [58]	36
1.19	Bytebelegung beim /Perms (extended permissions) entry in einer verschlüsselten PDF-Datei [45]	37
1.20	CBC malleability gadget mit konstruierten initialization vectors x0 und x1, um chosen plaintext einzuschleusen [60]	38
2.1	Anforderungen an den Reader, Creator, Merger und Splitter der PDF Web App	42
2.2	Anforderungen an den Editor der PDF Web App	43
2.3	Startseite der PDF Web App	44
2.4	Fehlermeldung bei einer nicht-PDF-Datei	45
2.5	Fehlermeldung bei einem verschlüsselten PDF	45
2.6	Dateibenennungsdialog des Save Buttons der PDF Web App	46
2.7	Geöffnetes PDF im Reader der PDF Web App	47
2.8	Creator GUI der PDF Web App	48
2.9	Splitter GUI der PDF Web App	49
2.10	Splitter Selector der PDF Web App	49
2.11	Merger Startseite der PDF Web App	50

2.12	Merger Dateiliste der PDF Web App mit selektierter Datei . . . . .	51
2.13	Startseite des Texteditors der PDF Web App . . . . .	53
2.14	Mehr Tools der Startseite des Texteditors der PDF Web App . . . . .	54
2.15	Benutzerdefinierte Fontliste im Texteditor der PDF Web App . . . . .	56
2.16	Color picker für die Fontfarbe des Texteditors der PDF Web App . . . . .	56
2.17	Bearbeiteter Text im Writer der PDF Web App . . . . .	57
2.18	Drawer der PDF Web App . . . . .	58
2.19	Zeichnungen im Drawer der PDF Web App . . . . .	60
2.20	Geometrieeditor der PDF Web App . . . . .	61
2.21	Mehr Tools des Geometrieeditors der PDF Web App . . . . .	62
2.22	Shapes im Geometrieeditor der PDF Web App . . . . .	63
2.23	Zeichnungen in der PDF Web App . . . . .	64
2.24	Platzierte Bilder im Bildeditor der PDF Web App . . . . .	65
2.25	Ausgeklapptes Ebenenmenu im Editor der PDF Web App . . . . .	66
2.26	Ebenen mit Elementen allen Typs im Editor der PDF Web App . . . . .	67
2.27	Teilweise gesperrte Ebenen im Editor der PDF Web App . . . . .	68
2.28	Selection Filtermenü im Editor der PDF Web App . . . . .	69
2.29	Deselection Filtermenü mit aktivierten Filtern im Editor der PDF Web App	70

Anhang

## Erklärung

Ich versichere, die von mir vorgelegte Arbeit selbstständig verfasst zu haben. Alle Stellen, die wörtlich oder sinngemäß aus veröffentlichten oder nicht veröffentlichten Arbeiten anderer oder der Verfasserin/des Verfassers selbst entnommen sind, habe ich als entnommen kenntlich gemacht. Sämtliche Quellen und Hilfsmittel, die ich für die Arbeit benutzt habe, sind angegeben. Die Arbeit hat mit gleichem Inhalt bzw. in wesentlichen Teilen noch keiner anderen Prüfungsbehörde vorgelegen.

Anmerkung: In einigen Studiengängen findet sich die Erklärung unmittelbar hinter dem Deckblatt der Arbeit.

[3cm] \_\_\_\_\_  
Köln, 04.03.2024

\_\_\_\_\_  
Unterschrift